| Nome: _____ | RA: _____ |
|---|---|

## PARTE I — ESTATÍSTICA DESCRITIVA (3,5 pts)

1 - A Análise Exploratória de Dados (AED) começa pela compreensão dos **tipos de variáveis** e pelo cálculo de **medidas numéricas** que resumem as características de um conjunto de dados. Com base no conteúdo estudado, responda:

**a)** **(0,5 pt)** Diferencie dados **qualitativos** de dados **quantitativos**. Para cada tipo, forneça dois exemplos práticos de variáveis que poderiam ser encontradas em um banco de dados de uma empresa de e-commerce.

**b)** **(0,5 pt)** Dentro dos dados quantitativos, explique a diferença entre as escalas **intervalar** e **razão**. Dê um exemplo de cada e indique por que essa distinção importa (por exemplo, para a operação de divisão).

**c)** **(0,5 pt)** Explique a diferença entre **medidas de posição** (média, mediana e moda) e **medidas de dispersão** (amplitude total e amplitude interquartil — IQR). Em que situação a mediana é preferível à média?

**d)** **(0,5 pt)** Classifique as variáveis abaixo como Qualitativa Nominal, Qualitativa Ordinal, Quantitativa Discreta ou Quantitativa Contínua:

| Variável | Classificação |
|---|---|
| Nível de satisfação do cliente (Ruim / Regular / Bom / Ótimo) | |
| Número de pedidos realizados por cliente | |
| Temperatura de armazenamento de alimentos (°C) | |
| Gênero do cliente (Masculino / Feminino / Outro) | |
| Receita mensal da empresa (R$) | |
| Código postal do endereço de entrega | |

2 - Responda:

**a)** **(0,5 pt)** Explique com suas próprias palavras o que é o **viés de sobrevivência**, usando o caso de Abraham Wald como referência (por que reforçar os aviões nos locais **sem** perfurações era a decisão correta?). Em seguida, cite **um exemplo prático moderno** em que esse viés pode comprometer uma análise de ciência de dados.

**b)** **(0,5 pt)** O **BoxPlot** sintetiza a distribuição dos dados. Identifique os **cinco elementos principais** representados nele (dos extremos inferior ao superior), associando cada um à medida estatística correspondente. O que a **altura da caixa** informa sobre os dados?

**c)** **(0,5 pt)** Uma equipe de suporte registrou o **tempo de atendimento (em minutos)** de 9 chamados:

**Tempos (min):** 11 – 5 – 14 – 6 – 9 – 4 – 11 – 5 – 8

Ordene os dados e calcule manualmente: **média**, **mediana**, **Q1**, **Q3** (use a mediana da metade inferior e da metade superior, sem incluir a mediana), **IQR** e **amplitude total**. Mostre os cálculos.

## PARTE II — TÉCNICAS DE PROGRAMAÇÃO PARA CIÊNCIA DE DADOS (1,5 pts)

3 - Uma empresa de e-commerce quer reduzir o cancelamento de clientes (**churn**). O time de dados vai conduzir o projeto seguindo o ciclo **CRISP-DM** e organizar o trabalho com **Scrum**.

**a)** **(0,5 pt)** Associe cada atividade à **fase do CRISP-DM** correspondente, escolhendo entre: Entendimento do negócio · Entendimento dos dados · Preparação dos dados · Modelagem · Avaliação · Implantação.

| Atividade do projeto | Fase do CRISP-DM |
|---|---|
| Definir com o gerente qual pergunta o projeto deve responder e qual meta será considerada sucesso | |
| Treinar um algoritmo para prever quais clientes tendem a cancelar | |
| Calcular média, mediana e quartis das variáveis e construir boxplots para conhecer os dados | |

| Atividade do projeto | Fase do CRISP-DM |
|---|---|
| Publicar o dashboard com os clientes em risco para a área de negócio | |
| Remover colunas irrelevantes e tratar os valores ausentes | |
| Verificar se o modelo atinge o recall mínimo combinado com o cliente | |

**b)** **(0,5 pt)** No Scrum, (i) diferencie **Product Backlog** de **Sprint Backlog** e (ii) cite **uma limitação** do Scrum em projetos de ciência de dados, com **uma prática** que ajuda a contorná-la.

**c)** **(0,5 pt)** O código Python abaixo usa a biblioteca pandas, cujo funcionamento é orientado a objetos:

```
import pandas as pd

df = pd.read_csv("winequality-red.csv", sep=";")
print(df.shape)
media = df["alcohol"].mean()
resumo = df.describe()
```

(i) O objeto **df** é instância de qual classe? (ii) Classifique **shape**, **mean()** e **describe()** como atributo ou método e justifique. (iii) Na analogia entre orientação a objetos e tabelas de dados, a que correspondem, em um DataFrame, um **atributo** e uma **instância (objeto)**?

## PARTE III — APLICAÇÃO PRÁTICA (5,0 pts)

### ATIVIDADE 1 — POWER BI (1,5 pts)

**Link para download:** https://go.microsoft.com/fwlink/?LinkID=521962
O arquivo contém dados de vendas fictícias com colunas: Segment (Segmento), Country (País), Product (Produto), Discount Band (Faixa de desconto), Units Sold (Unidades vendidas), Manufacturing Price (Preço de fabricação), Sale Price (Preço de venda), Gross Sales (Vendas brutas), Discounts (Descontos), Sales (Vendas), COGS (Custo dos produtos vendidos), Profit (Lucro), Date (Data), Month Number (Número do mês), Month Name (Nome do mês), Year (Ano).

**a)** **(0,5 pt)** Importe o arquivo Excel para o Power BI Desktop. No **Power Query Editor**: (1) confira e ajuste os **tipos de dados** (Units Sold e Year como número inteiro, Sale Price como moeda, Date como data); (2) crie uma **coluna personalizada** chamada **"Margem_Pct"** = **[Profit] / [Sales] * 100**. Apresente um **print** com a fórmula visível e as Etapas aplicadas. Responda: por que **Year** e **Month Number**, embora numéricos, não devem ser somados em um gráfico?

**b)** **(0,5 pt)** Usando **medidas DAX** sobre a coluna **Profit**, crie: Lucro_Media, Lucro_Mediana, Lucro_Q1 (percentil 25), Lucro_Q3 (percentil 75) e Lucro_IQR (Q3 − Q1). Exiba-as em uma **tabela visual** por **Segment**. Com base na tabela, responda: (i) qual segmento tem o **maior lucro médio**? (ii) nesse segmento a média é maior ou menor que a mediana? O que isso sugere? (iii) qual segmento apresenta a **maior dispersão** (IQR)?

**c)** **(0,5 pt)** Crie um **gráfico de barras clusterizadas** com o **lucro total (Profit)** por **Segmento** e por **País**. Crie um **segmentador** para exibir apenas o segmento **"Government"**. Responda: **qual país apresentou o maior lucro nesse segmento?** Informe o valor exato e apresente o print do relatório.

### ATIVIDADE 2 — PYTHON (2,0 pts)

**Link para download:** https://archive.ics.uci.edu/ml/machine-learning-databases/wine-quality/winequality-red.csv
O dataset contém 1.599 amostras de vinhos tintos portugueses com 11 variáveis físico-químicas (acidez, pH, álcool, sulfatos etc.) e uma variável de qualidade sensorial (**quality**).

**a)** **(0,5 pt)** Carregue o dataset no Colab com **pandas** (atenção ao separador **sep=";"**) e exiba suas dimensões. Faça a **análise descritiva** da variável **"alcohol"**. Apresente o **código** e preencha a tabela:

| Medida | Como obter (sugestão) | Resultado obtido |
|---|---|---|
| **Média** | df["alcohol"].mean() | |
| **Mediana** | df["alcohol"].median() | |
| **Moda** | df["alcohol"].mode() | |

| Medida | Como obter (sugestão) | Resultado obtido |
|---|---|---|
| **Mínimo** | df["alcohol"].min() | |
| **Máximo** | df["alcohol"].max() | |
| **Amplitude total** | máximo − mínimo | |
| **Q1 (P25)** | df["alcohol"].quantile(0.25) | |
| **Q3 (P75)** | df["alcohol"].quantile(0.75) | |
| **IQR** | Q3 − Q1 | |

**b)** **(0,5 pt)** Construa a **tabela de frequência** da variável **"quality"** (quantidade e percentual de vinhos em cada nota). Responda: (i) qual é a **moda** de quality? (ii) que percentual dos vinhos tem qualidade **maior ou igual a 7**? Apresente o código.

**c)** **(0,5 pt)** Usando **seaborn** ou **matplotlib**, crie um **boxplot** de **"alcohol"** agrupado por **"quality"**. Com base nas **medianas** e nas caixas, interprete: **vinhos de qualidade mais alta tendem a ter maior ou menor teor alcoólico?** Qual nota apresenta a maior mediana?

**d)** **(0,5 pt)** Calcule a **matriz de correlação** entre as variáveis numéricas e gere um **heatmap** com seaborn. Identifique as **duas variáveis** com maior correlação (em valor absoluto) com **"quality"**, informe o sinal e o valor de cada uma e interprete em termos práticos.

## ATIVIDADE 3 — KNIME (1,5 pts)

**Link para download:** https://raw.githubusercontent.com/datasciencedojo/datasets/master/titanic.csv
O dataset contém 891 passageiros do Titanic com: Survived (1 = sobreviveu, 0 = não), Pclass (classe da passagem: 1, 2 ou 3), Name, Sex, Age, SibSp, Parch, Ticket, Fare (tarifa), Cabin e Embarked.
**Nodes necessários nesta atividade:** CSV Reader, Statistics, GroupBy e Bar Chart.

**a)** **(0,5 pt)** Crie um workflow e leia o arquivo com o node **CSV Reader**. Execute-o e consulte a saída. Informe: (i) o número de **linhas** e de **colunas**; (ii) quantos valores **ausentes** existem em **Age**; (iii) a classificação (Qualitativa Nominal/Ordinal ou Quantitativa Discreta/Contínua) de **Pclass**, **Sex**, **Age** e **Fare**.

**b)** **(0,5 pt)** Conecte um node **Statistics** ao CSV Reader e preencha a tabela com os valores **obtidos no KNIME** (a mediana corresponde ao quantil 50%). Responda: em **Fare**, a média é maior ou menor que a mediana? O que isso indica?

| Variável | Média | Mediana | Mínimo | Máximo |
|---|---|---|---|---|
| **Age** | | | | |
| **Fare** | | | | |

**c)** **(0,5 pt)** Adicione um node **GroupBy** para calcular a **média de "Survived"** (taxa de sobrevivência) agrupada por **Pclass** e conecte um node **Bar Chart** para visualizar o resultado. Apresente um **print do workflow** (nodes executados) e do gráfico e responda: **qual classe teve a maior taxa de sobrevivência e qual foi esse valor?**

Entregáveis:
- Este documento com as respostas e prints solicitados.