ESTATÍSTICA APLICADA À CIÊNCIA DE DADOS II

Fatec 2026

Objetivo:

- Realizar análise de regressão para identificar e quantificar o efeito das variáveis independentes sobre uma variável dependente
- Aplicar técnicas de análise multivariada para explorar e entender a relação entre múltiplas variáveis
- Utilizar técnicas de análise de séries temporais para analisar e prever dados ao longo do tempo
- Interpretar e comunicar resultados estatísticos de forma clara e precisa
- Utilizar software estatístico e ferramentas computacionais para realizar análises estatísticas
- Compreender os princípios éticos e responsabilidades ao lidar com dados e resultados estatísticos

Ementa:

- Análise de regressão: Modelagem de regressão linear simples e múltipla. Avaliação de modelos de regressão
- Interpretação e previsão utilizando modelos de regressão
- Análise multivariada: Análise de correlação e covariância. Análise de componentes principais
- Análise discriminante e clustering
- Análise de séries temporais: Conceitos básicos de séries temporais
- Modelagem e previsão de séries temporais
- Decomposição de séries temporais
- Software estatístico e ferramentas computacionais: Utilização de software estatístico para análise de dados
- Implementação de técnicas estatísticas em linguagens de programação
- Ética e responsabilidade na ciência de dados: Considerações éticas no uso de dados e análises estatísticas
- Privacidade, confidencialidade e segurança dos dados. Aplicações práticas em ciência de dados: Aplicação dos conceitos estatísticos em projetos de ciência de dados
- Análise de dados reais e tomada de decisões baseadas em evidências

Avaliação

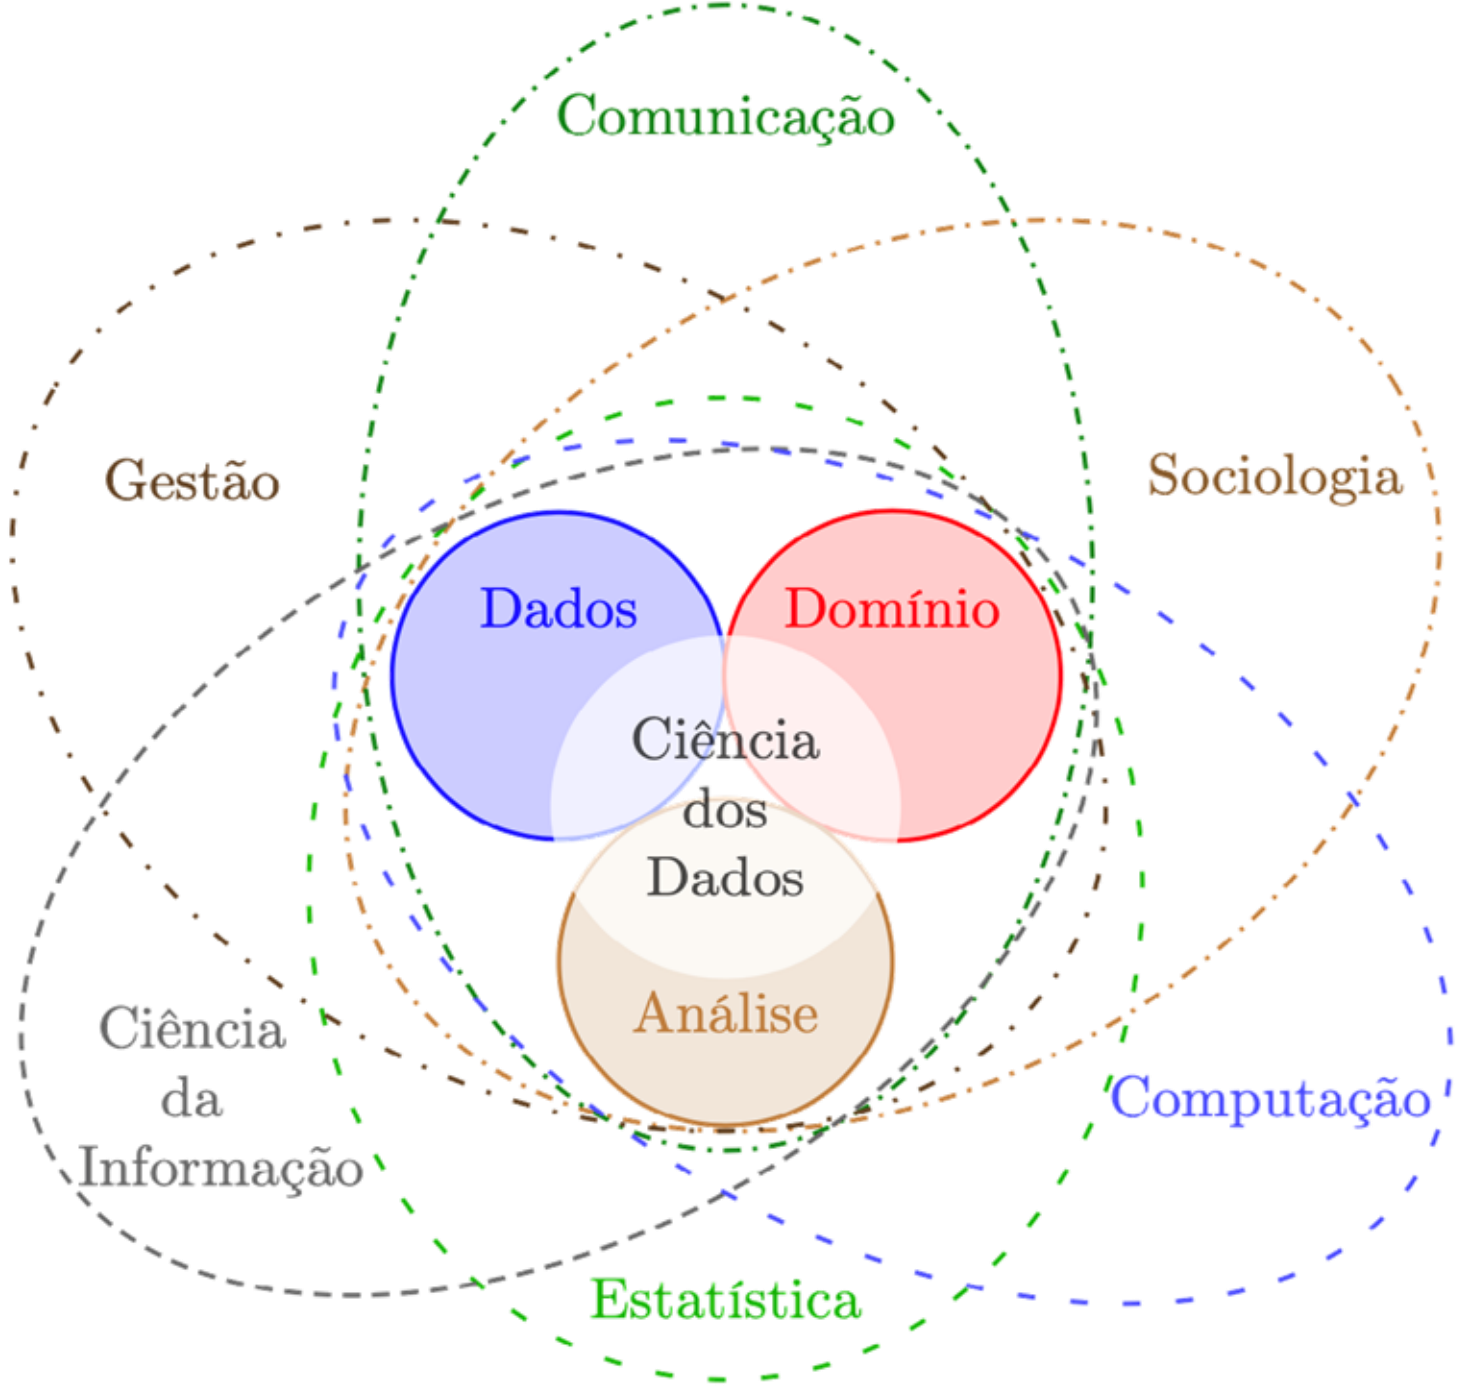
Projeto (Peso 6)
Prova bimestral(Peso 4)

Estatística, a chave da nova revolução

1. **Revolução da Agricultura** → atualmente o mundo produz mais alimentos através de cultivos, do que através de caça.
2. **Revolução Industrial** → fábricas de produção em massa deram ao mundo uma imensa variedade de opções de produtos.
3. **Revolução da Informação** → a tecnologia nos deu uma grande variedade de produtos eletrônicos, tornou a indústria mais eficiente e aumentou consideravelmente a quantidade de informação a nossa disposição.
4. **Revolução Digital** → estamos no meio desta revolução e o volume de dados gerados pela humanidade, nos traz o desafio de conseguir extrair informação útil. A análise estatística é a chave desta revolução.

Habilidades

Ciência dos Dados



O que é Analise de dados

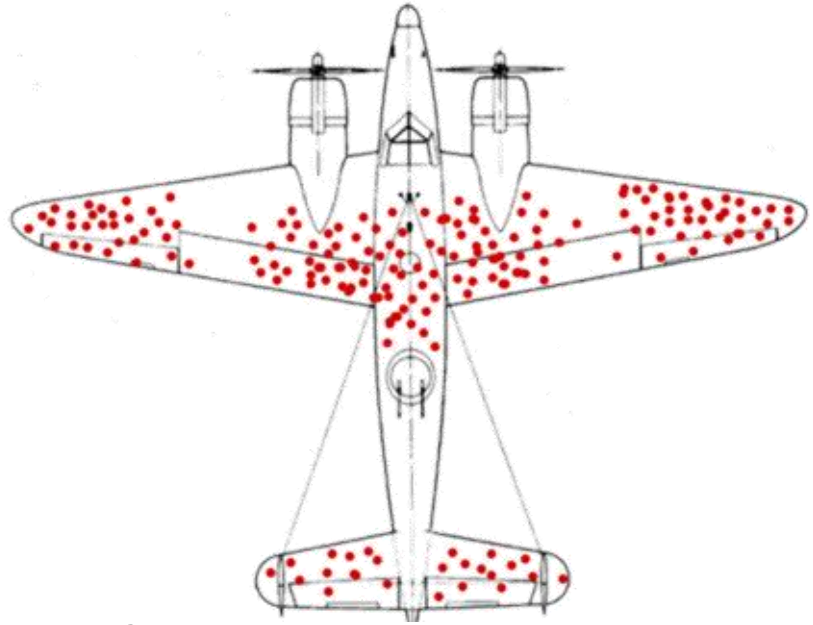
- Arte de analisar dados crus e transformá-los em informação
- O objetivo da análise é sempre otimizar os resultados de um modelo



Viés de sobrevivência **Abraham Wald – Segunda Guerra Mundial**



- Estatísticos da equipe de *Abraham Wald* analisavam todos os aviões que voltavam das batalhas
- Objetivo era identificar onde a estrutura dos aviões deveria ser reforçada da maneira mais eficiente
- Seria óbvio reforçar os locais onde há perfurações
- Mas esses aviões conseguiram voltar
- Ou seja, deve-se reforçar os locais que não tinham perfurações
- Esse caso ilustra o viés da sobrevivência (*survival bias),* um tipo de viés de seleção



viés de seleção, consiste no erro lógico de nos concentrarmos em coisas ou pessoas que sobreviveram a algum processo enquanto ignoramos aqueles que foram eliminados devido a sua falta de visibilidade

Se usarmos a única fonte de informação disponível como sendo suficiente para uma hipótese, vamos ignorar grande parte das causas dos problemas. As vezes, a resposta mais importante está na informação que está faltando

Estabelecendo Questionamentos

- Uma das tarefas mais comuns de um cientista de dados é descobrir padrões e obter insights a partir da análise exploratória de dados

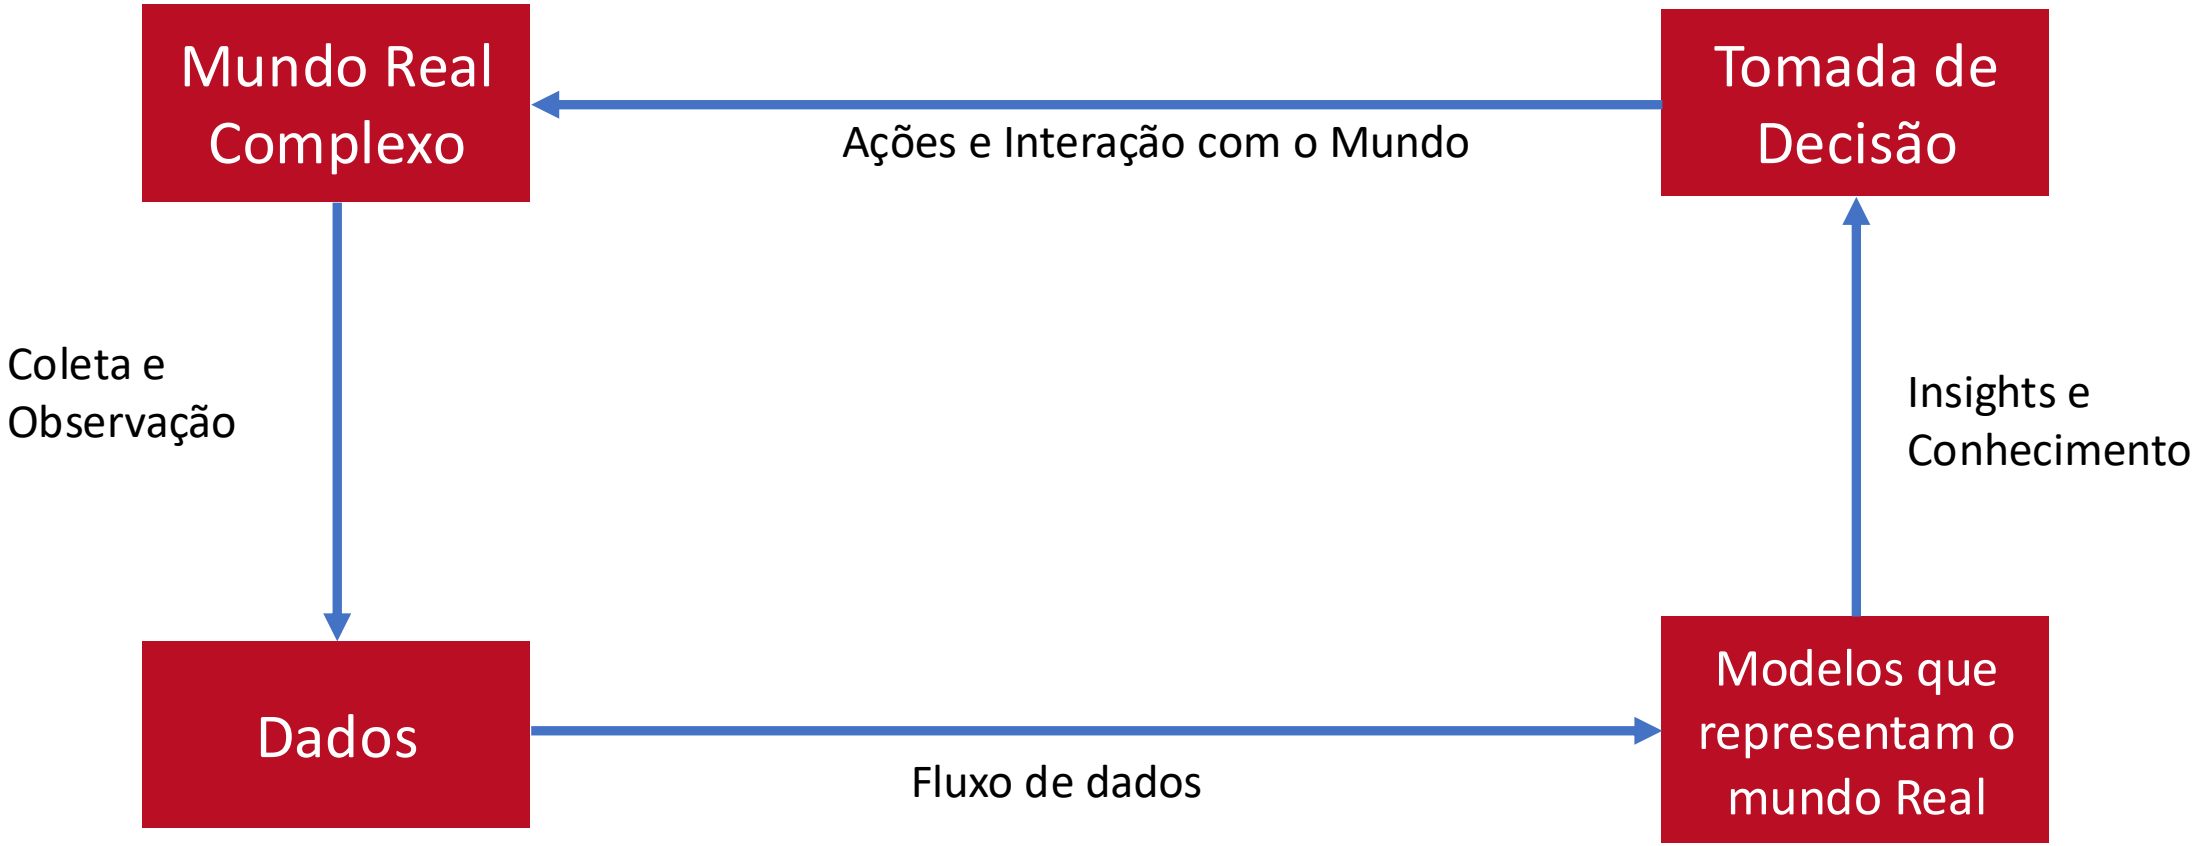
- Durante este processo, os dados são avaliados de modo a se encontrar padrões, detectar anomalias e formular hipóteses

- Normalmente as técnicas de EDA são feitas por meio da visualização analítica

- A qualidade dos achados depende da habilidade do cientista em formular as questões corretas e realizar uma sequência de análises que possibilitem respondr a elas!

Framework de Análise Exploratória

Modelo Mental



Quais são as perguntas certas?

- Formule perguntas que possibilite compreender os dados e seus processos de transformação, ao passo em que constrói um background sobre o problema
- Por onde começar?
  - **Data Scrutiny / Description**
    - Avalie a estrutura e qualidade dos dados
      - Quantos registros? Quantas variáveis?
    - Como os dados foram coletados?
    - Qual o formato dos dados? Tipos de dados?
    - Há erros nos dados? Outliers? Valores únicos?
    - Missing data?
    - Calcule as estatísticas descritivas para os dados
    - Verifique a distribuição e comportamento dos dados
  - **Interaja com os dados** (auxiliado por estatística descritiva e visualização)

a transformation can sometimes work wonders in deciphering the data

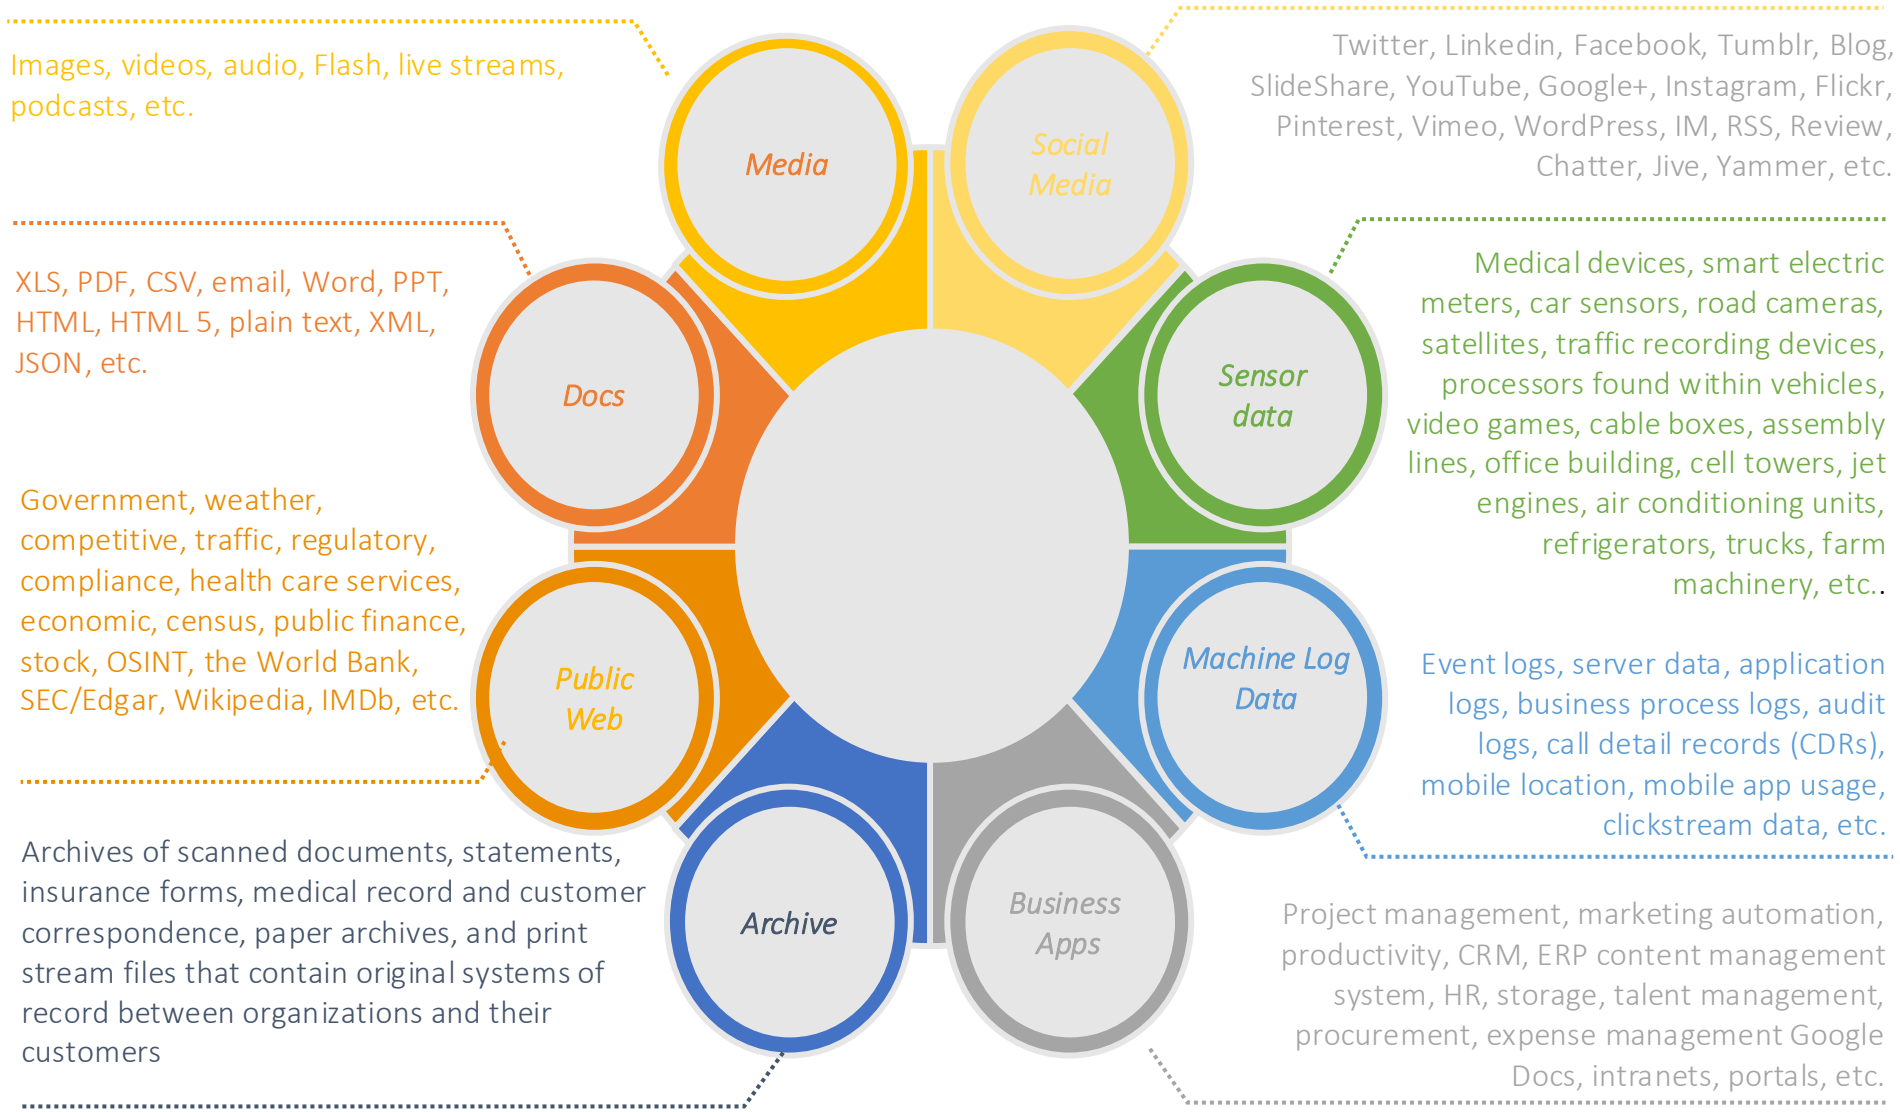
Chatfield (1985)

Estabelecendo Questionamentos

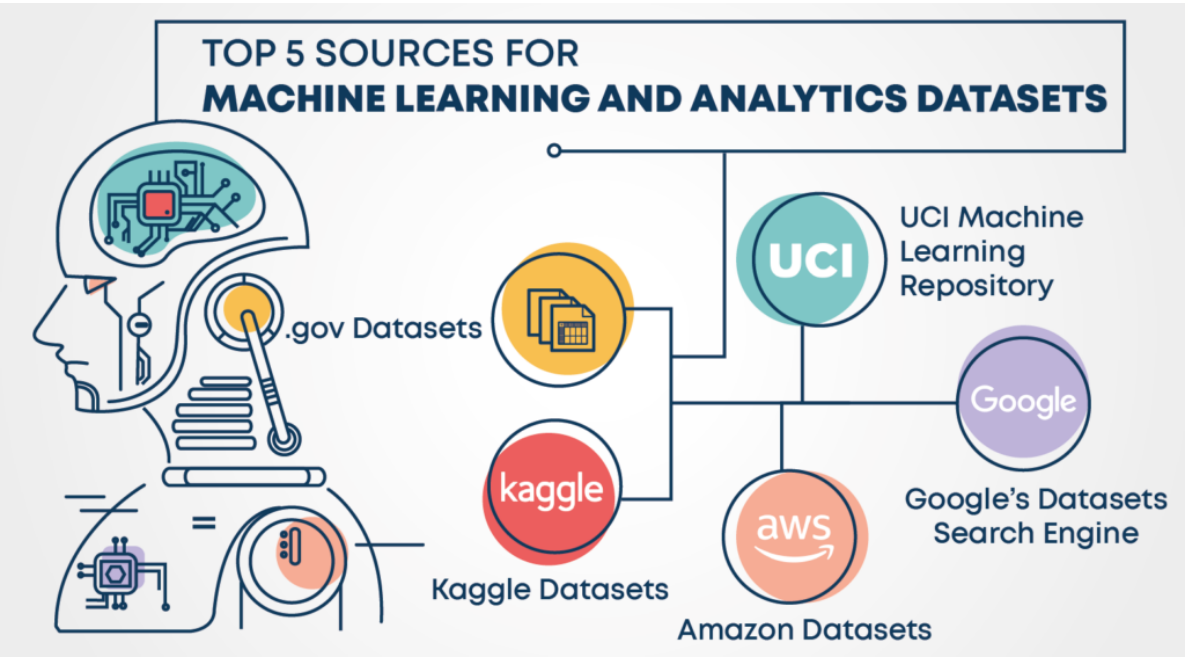
- Análise Geral
  - Qual pergunta eu quero responder com essa estatística?
  - O que esta estatística significa?
  - Com o que uma observação mediana se parece? E quanto a uma observação extrema?
  - Qual o horizonte temporal?
- Desafiando premissas:
  - Valores maiores ou menores são melhores?
  - Valores estão dentro da expectativa esperada?
  - Quais premissas estou usando?
  - Quais os vieses da coleta de dados?

Análise exploratória de dados

Fonte e formatos de dados



Dados **Repositórios, Crawling e Scraping**







Dados **Formato**

- Tabular

x	y	tempo	red	green	blue
0	0	0	255	0	0
0	1	0	200	10	6
...					
0	0	0.1	255	50	100
0	1	0.1	255	200	190
...					

Tupla,
ponto multidimensional,
Vetor,
Linha
Instância

Domínio
Variáveis independentes
Dimensões

Contradomínio
Variáveis dependentes
Medidas

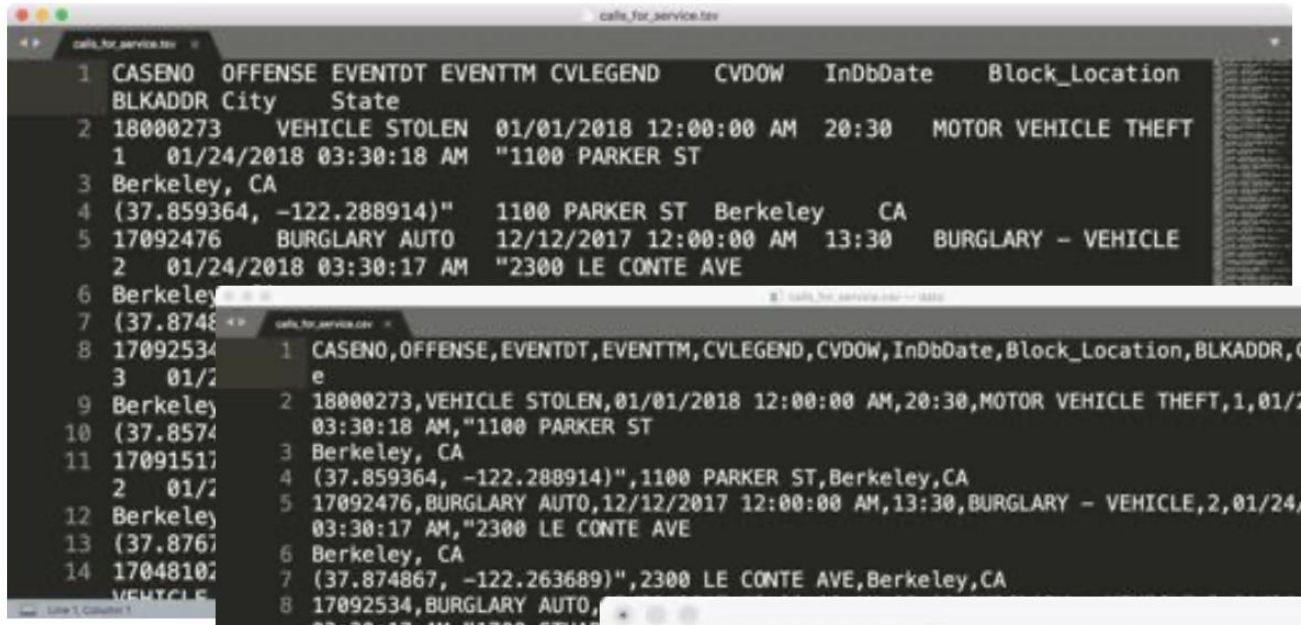
Colunas, **Variáveis**

Variáveis e observações



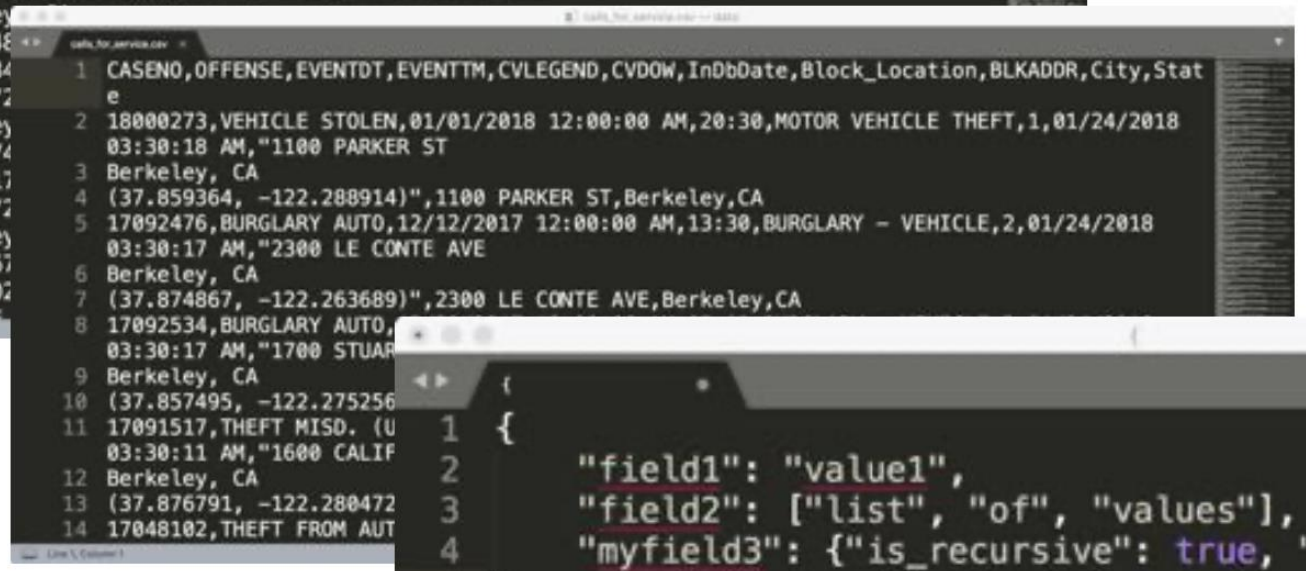
	Idade	Sexo	Peso	Cor dos olhos
Indivíduo 1	42	M	59	Verde
Indivíduo 2	34	M	54	Castanho
Indivíduo 3	56	F	89	Azul
Indivíduo 4	41	M	76	Castanho
Indivíduo 5	23	F	65	Castanho

Dados **Organização**



TSV

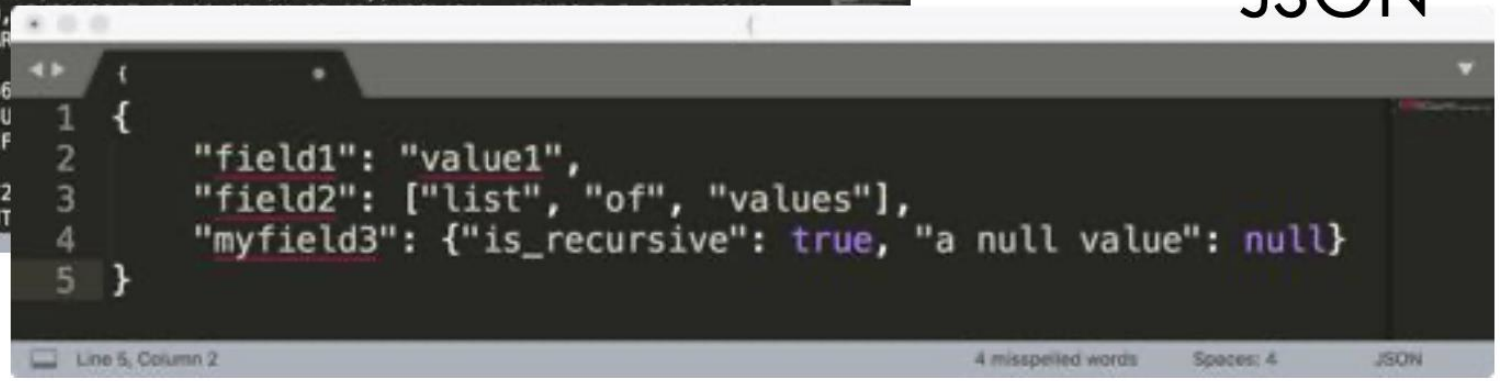
Tab separated values



CSV

Comma separated values

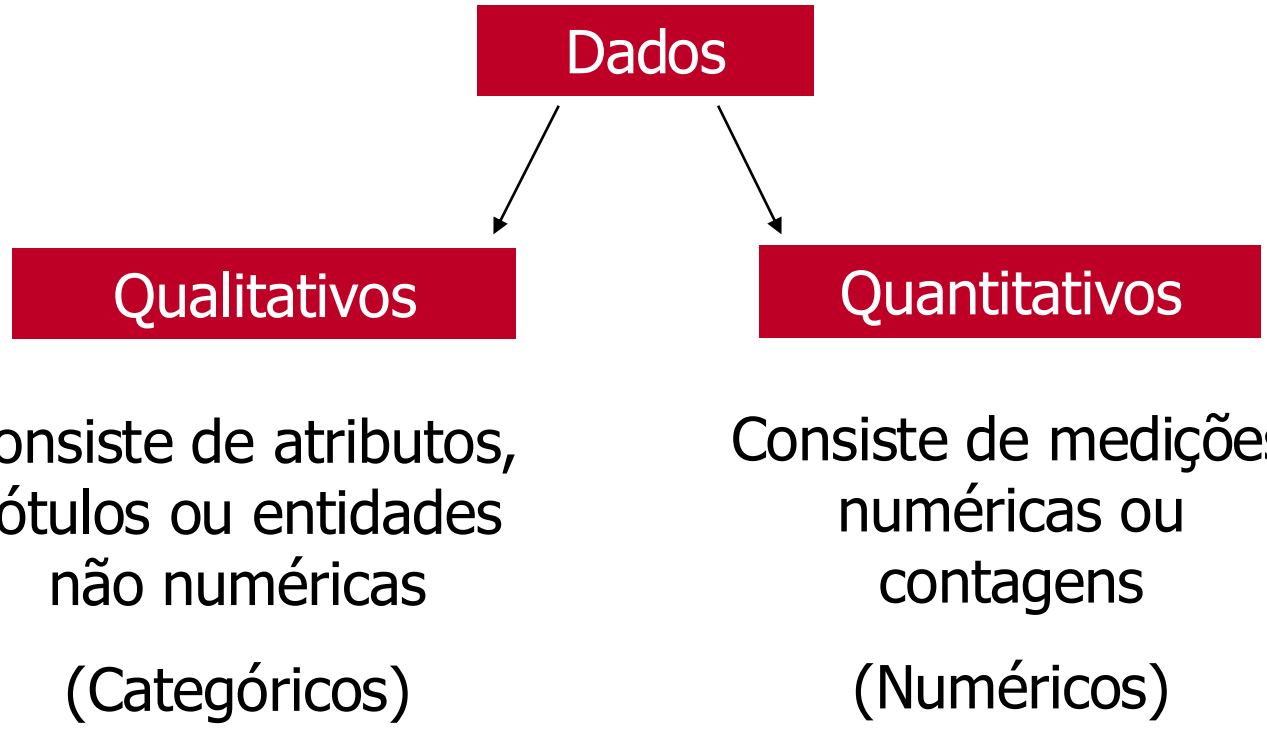
JSON



JavaScript Object Notation

Dados **Tipos de Dados**

- Os conjuntos de dados são compostos por dois tipos de dados: dados **qualitativos** e dados **quantitativos**



Dados **Tipos de Dados**

- Considere o seguinte exemplo
  - Notas de alunos em uma determinada disciplina

Aluno	Nota
Sally	3.22
Bob	3.98
Cindy	2.75
Mark	2.24
Kathy	3.84

Qualitativo

Quantitativo

Dados Quantitativos

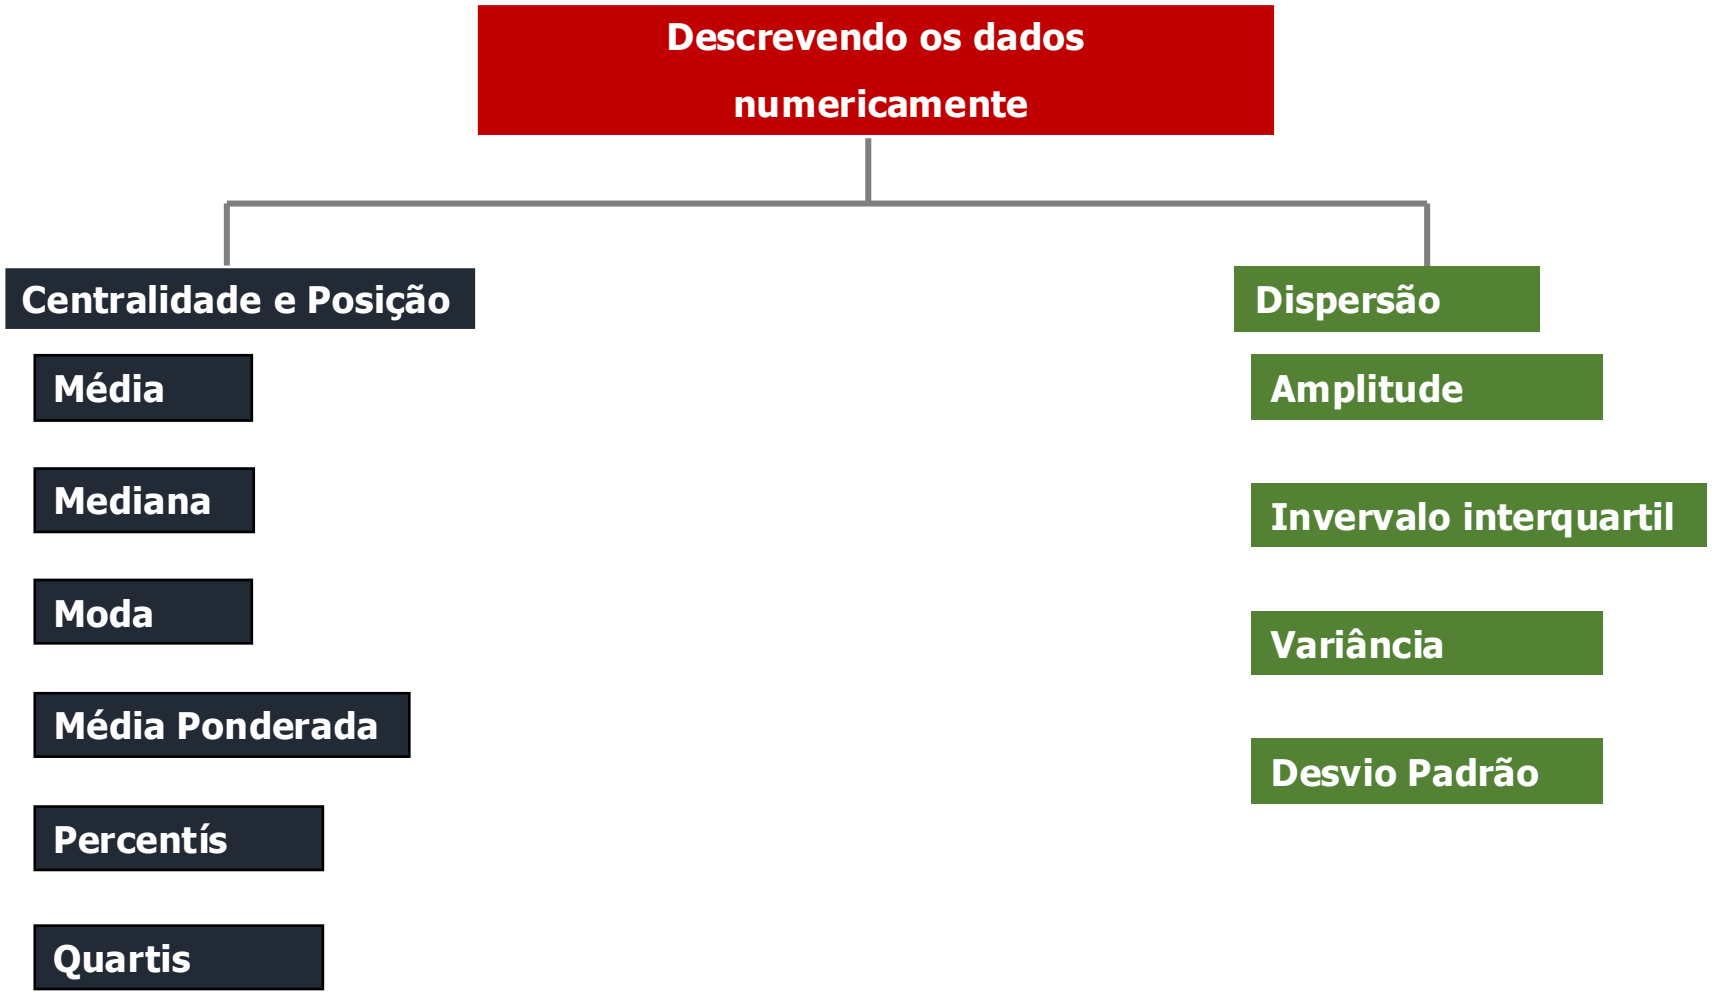
Tipos de Variáveis

Um dado classificado como "**idade**" é **quantitativo**
Ex:. 11, 15, 18, 25, 42 anos.

Entretanto, se esse dado for informado por "**faixa etária**" ele é **qualitativo** (ordinal).

Ex: 0 – 5 anos
6 – 12 anos
13 – 18 anos
19 – 28 anos

Dados Quantitativos



Tipos de variáveis Qualitativas

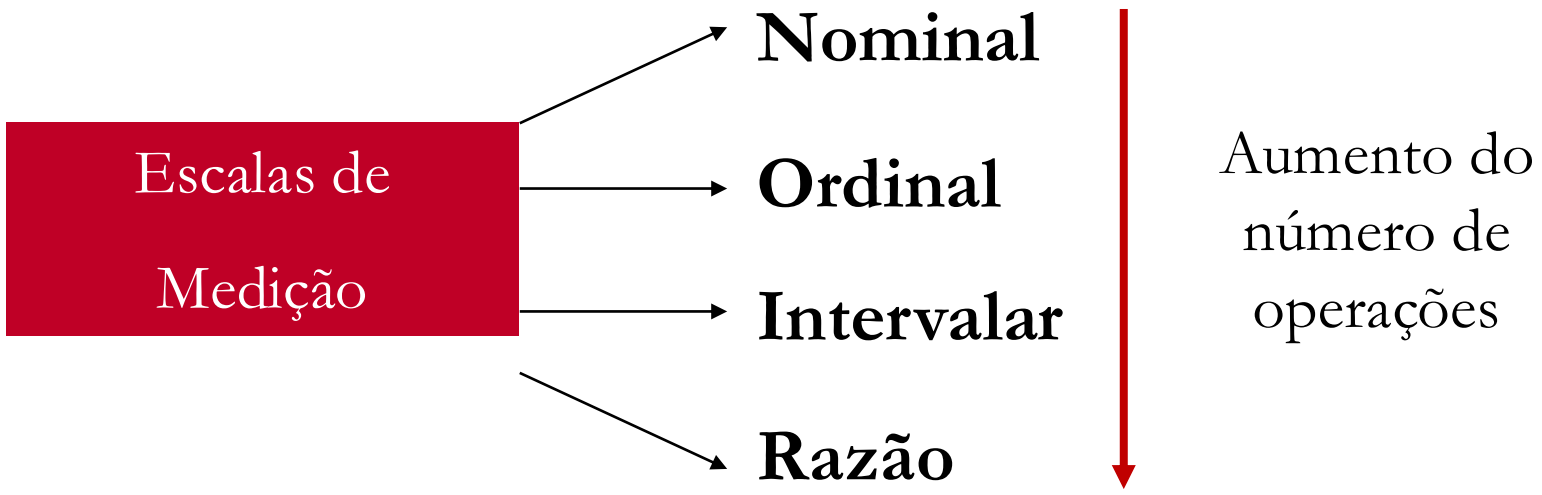
Os dados podem conter variáveis:

Qualitativas – utilizam termos **descritivos** para descrever algo de interesse. Ex: cor dos olhos, estado civil, religião, sexo, grau de escolaridade, classe social, tipo sanguíneo, cor da pele, etc...

Dados

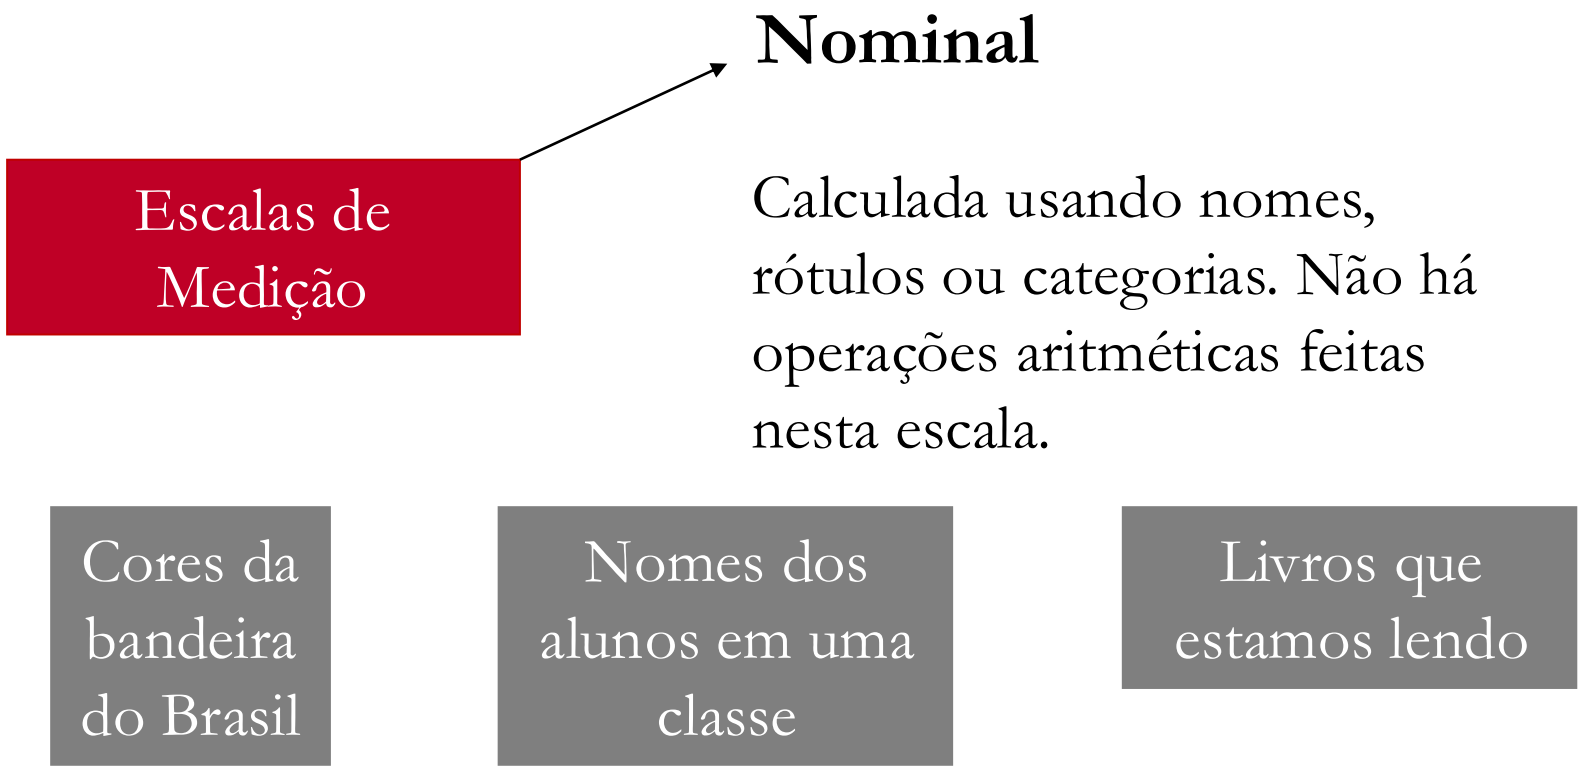
Escalas de Medição

- Há quatro escalas de medição de um dado, quais sejam:



Dados **Escala Nominal**

- Representam **categorias** que não mantém necessariamente relação entre elas
- Não é possível realizar operações aritméticas (soma, média, etc.)
- Normalmente realiza-se apenas a contagem das observações em cada categoria



Dados **Escala Ordinal**

- **Categorias** podem ser representadas por nomes, símbolos ou números, porém há uma ordenação de uma categoria em relação à outra
- A distância entre uma categoria e a outra não pode ser medida numericamente
- Além da operação de contagem, permitem operações que envolvam ordenação (maior/menor)

Escalas de Medição → **Ordinal**

Podem ser ordenadas entre si, mas não é possível diferenciá-las numericamente.

- Nível de experiência: junior, pleno e senior
- Números das camisas dos jogadores da seleção
- Top 10 músicas mais tocadas no momento

Dados

Escala Intervalar

- Escala **quantitativa**
- O valor nulo não corresponde à ausência da característica medida
- A escala possui um zero arbitrário
- Exemplo: 0 °**C** não significa ausência de temperatura (-273 °**C**)
- Operação de divisão é ilegítima em dados intervalares



Intervalar

Ordenadas, a diferença entre duas medidas pode ser calculada

Temperatura

Linha do tempo em anos

40 ° não é o dobro de 20 °C.

Veja em Fahrenheit:

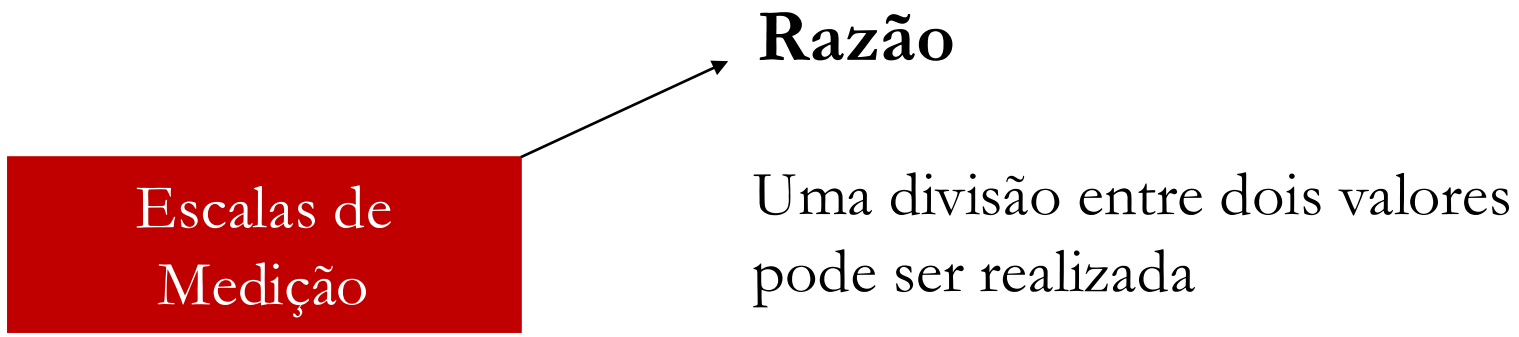
20 °C → 68°F

40 °C → 104 °F

Dados

Escala Razão

- Escala **quantitativa**
- O zero corresponde à ausência da característica medida
- É possível realizar todas as operações aritméticas em dados dessa escala



Idade | Peso | Altura | Dinheiro

Análise exploratória

Nominal	Ordinal	Discreta	Contínua
– Cor – Sexo – Estado Civil – Vale transporte (Sim ou Não) – Grau de Escolaridade	– Escala de questionário – Preferência – Faixa etária – Classe Social	– Escala de questionário (numérica) – Número de filhos – Quantidade de empregados – Quantidade de ligações	– Salário Mensal – Idade – Anos de estudo – Taxas

Análise Exploratória

Quantitativa

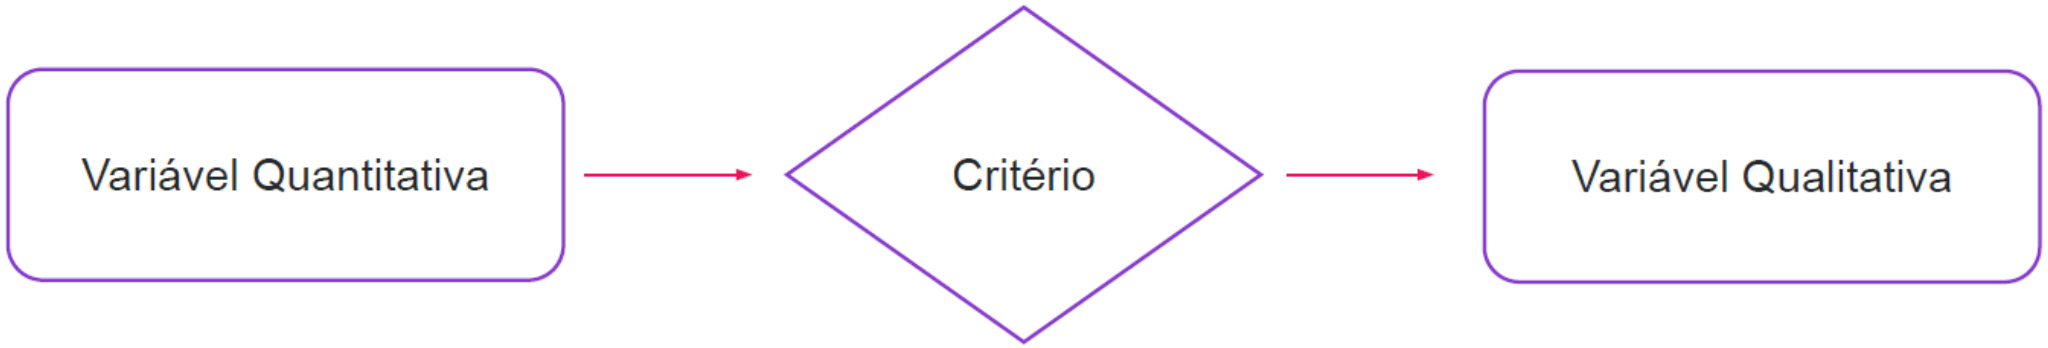


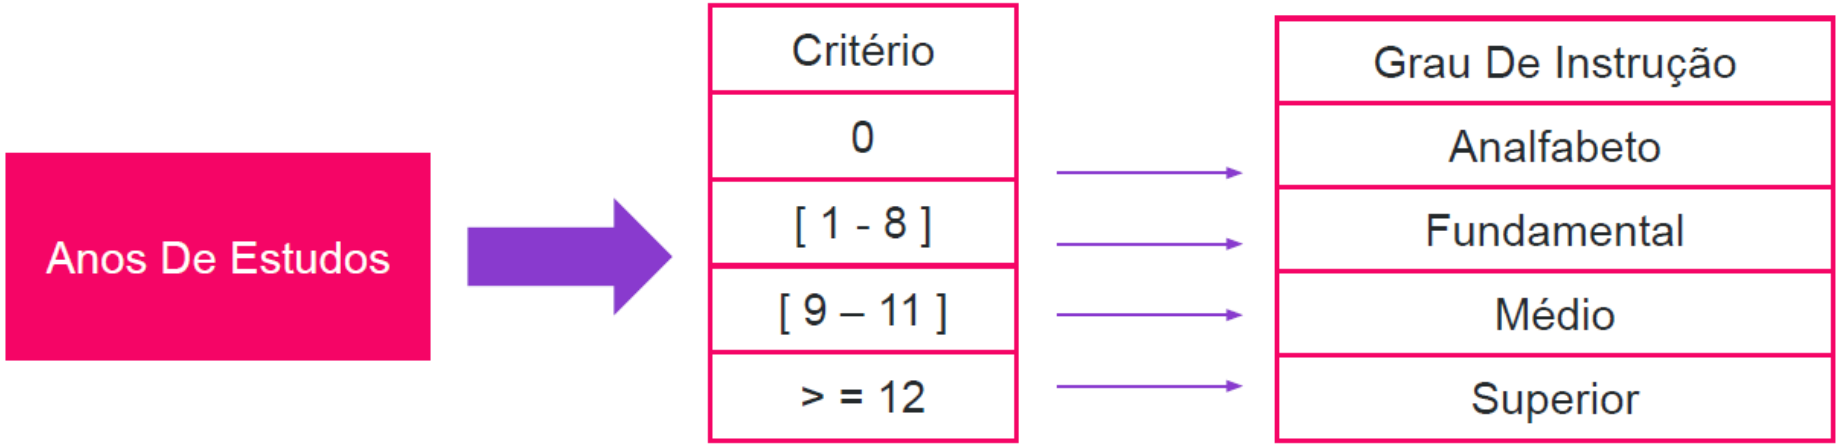
Qualitativas (categóricas)



id	sexo	idade	cor	internet	Telefone móvel	Anos de estudo	Rendimento
35000015	2	15	2	1	3	7	800
35000015	2	75	2	3	3	12	2.100
35000031	2	60	2	3	3	12	1.800
35000058	2	68	2	3	3	1	
35000058	2	48	8	3	1	5	1.000
35000058	2	42	2	3	3	6	900
35000066	2	36	2	1	3	9	1.000
35000066	2	44	2	1	1	9	1.200
35000066	2	20	2	1	3	13	300
35000066	4	26	2	1	3	12	1.900
35000074	4	14	2	1	3	8	700
35000074	4	71	2	3	3	5	450
35000090	4	20	2	1	1	12	1.890
35000090	2	19	8	1	3	12	620
35000090	4	42	2	3	1	12	300
35000090	4	17	2	1	1	11	1.100
35000090	4	25	2	1	1	12	433
35000090	2	49	6	1	3	16	400
35000104	2	38	2	3	1	6	600

Transformando





Recapitulando...

- **O papel da Estatística:** Como ela se tornou a "chave" para extrair valor no meio da Revolução Digital
- **Habilidades do Cientista de Dados:** A importância de equilibrar Computação, Estatística e o Domínio do problema
- **Pensamento Crítico e Vieses:** O caso de Abraham Wald nos ensinou que o que não vemos nos dados pode ser a resposta mais importante
- **Tipagem de Dados e Escalas:** Como classificar variáveis em Qualitativas e Quantitativas
- **Ciclo de Vida de Análise:** Do entendimento do problema à comunicação dos resultados através da Análise Exploratória de Dados