ESTATÍSTICA APLICADA À CIÊNCIA DE DADOS II

Fatec 2026 – Análise exploratória

Medidas de posições relativas

Posição relativa

Os dados podem ser medidos em termos de posição relativa, que compara a posição de um valor, em relação a outro valor dentro do conjunto de dados.

Percentil e **quartil** são as medidas mais comuns de posição relativa

Percentil x Porcentagem

Percentil e Porcentagem **não** são a mesma coisa.

Percentil $\neq$ Porcentagem

Porcentagem (%): Proporção calculada em relação a uma grandeza de cem unidades. A porcentagem pode ser encontrada multiplicando o valor numérico por 100.

Percentil: É o ponto da distribuição dos resultados ordenados da amostra (por ordem crescente dos dados) em 100 partes de igual amplitude.. Por exemplo, um resultado no percentil 90 significa que 90% dos resultados se situam nesse ponto ou abaixo dele.

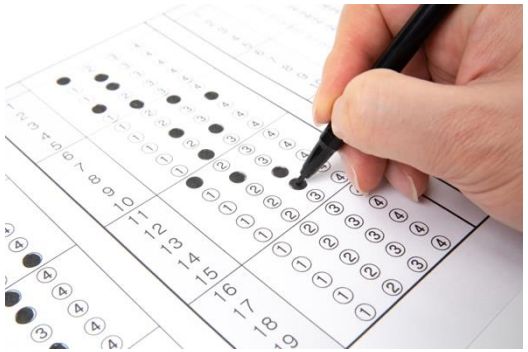
Percentil

A maneira mais fácil de informar a posição relativa é por meio do uso do **percentil**

Percentil



Percentil x Porcentagem



Suponha que um aluno tenha conseguido nota **36** em um exame de admissão em uma universidade, cujo valor máximo era **45**

Supondo que além de informar a você que o aluno conseguiu nota 36, eu dissesse que ele ficou em

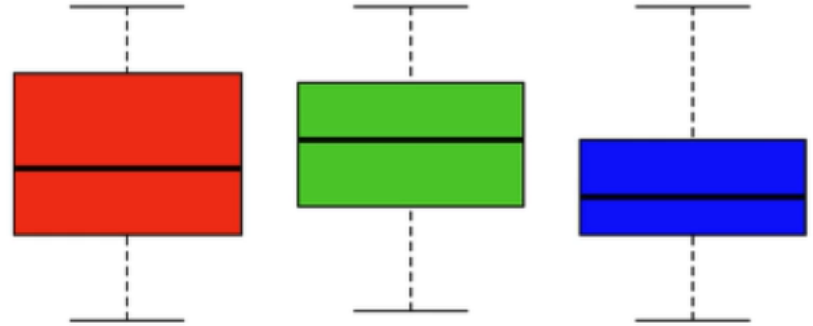
97º percentil

Isso significa que o aluno foi melhor que **97%** dos outros alunos que prestaram o mesmo exame

Perceba que se dividirmos **36/45**, o aluno teve um aproveitamento de **80%**

Esta informação **NÃO** é a mesma coisa que o **percentil**

Quartil



Quartil é simplesmente um específico percentil de interesse

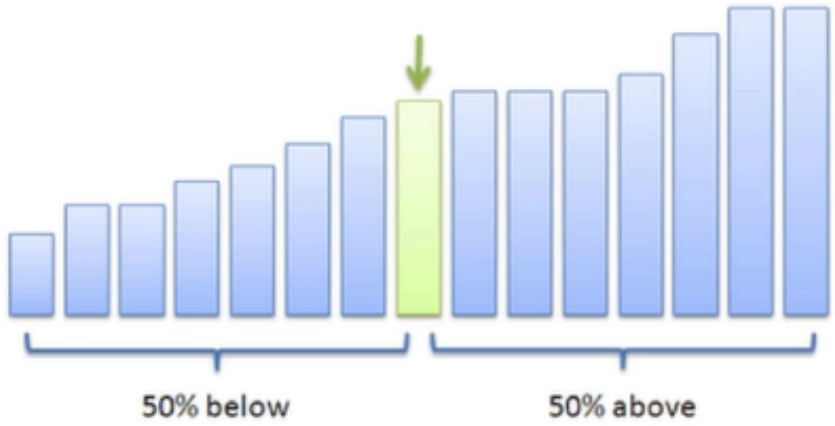
Quartis são valores que dividem uma tabela de dados em quatro partes iguais:

O **primeiro quartil** é o valor que constitui **25% percentil**.
O **segundo quartil** é o valor que constitui **50% percentil**.
O **terceiro quartil** é o valor que constitui **75% percentil**.
O **quarto quartil** é o valor que constitui **100% percentil**.

Quartil e mediana

Perceba que o **segundo quartil** é a **mediana,** ou seja,

50º percentil



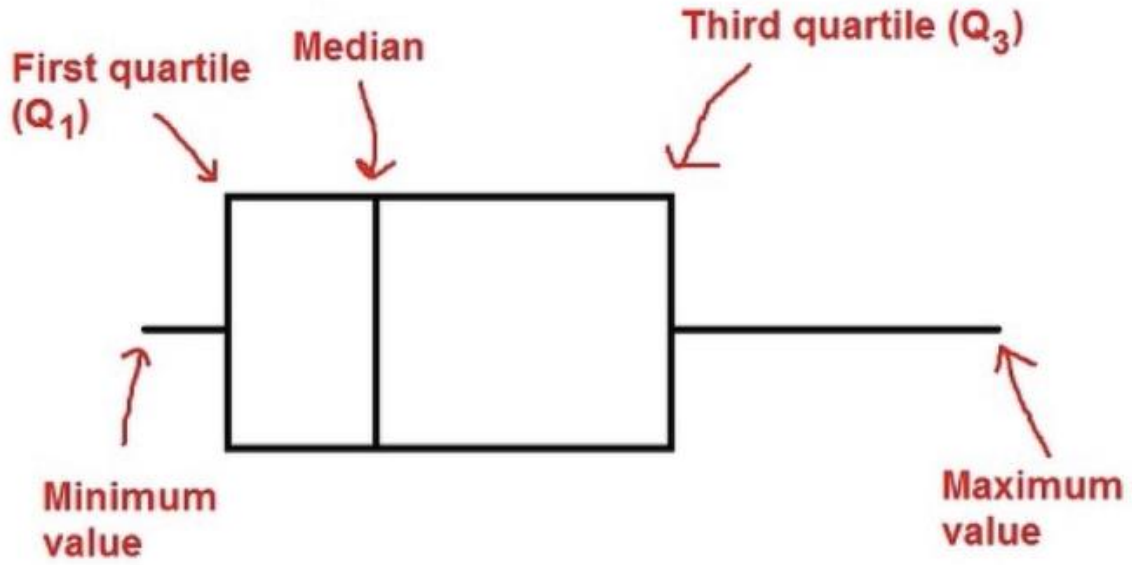
Quartil - intervalos

Temos ainda os intervalos interquartis:

- Intervalo interquartil → $Q_3 - Q_1$
- Intervalo semi-interquartil → $(Q_3 - Q_1)/2$
- Quartil médio → $(Q_3 + Q_1)/2$

Quartil e BoxPlot

Os intervalos interquartis são fundamentais para saber interpretar um boxplot:



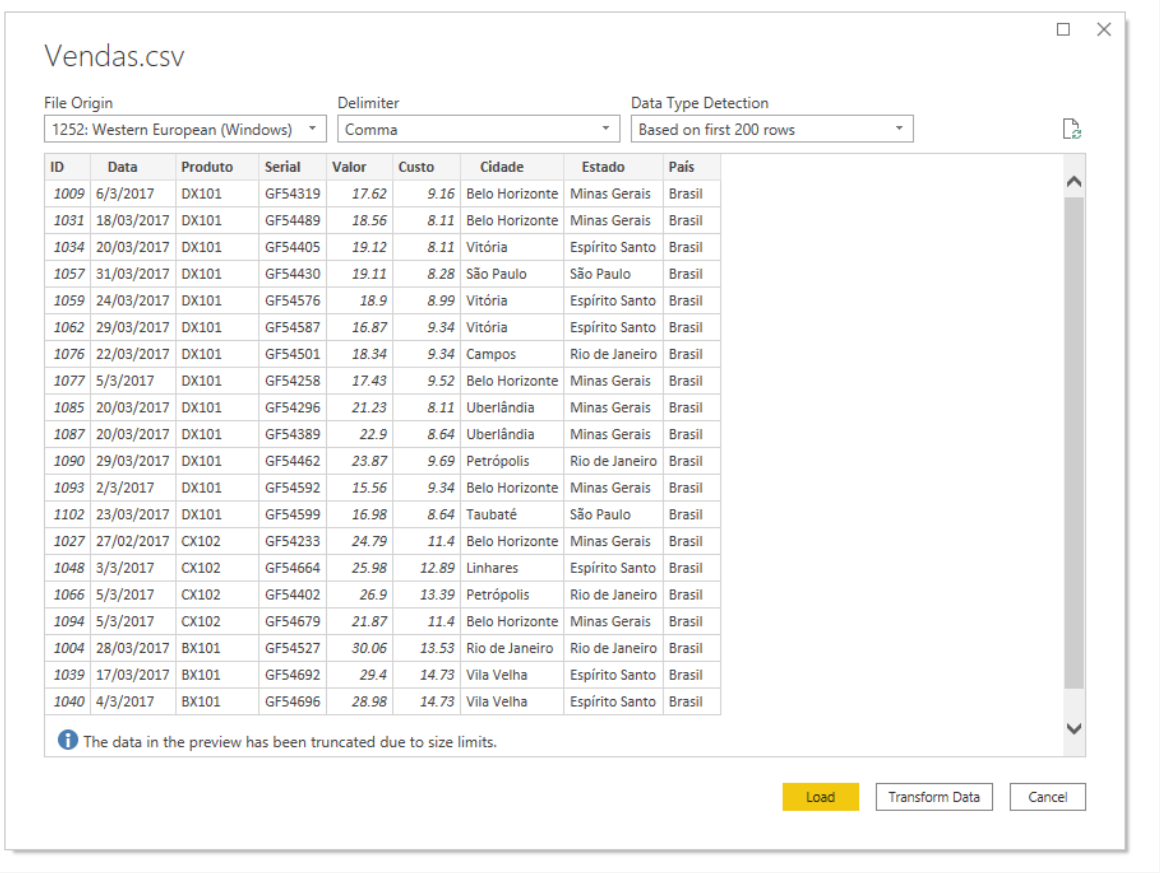
No PBI, baixe o visual: Box and Whisker Chart by MAQ Software

Percentis em Dax

- `Max_Value = MAX (Vendas[Valor] )`
- `Q3_Value = PERCENTILEX.INC (Vendas, Vendas[Valor], 0.75 )`
- `Median_Value = MEDIAN ( Vendas[Valor] )`
- `Q1_Value = PERCENTILEX.INC (Vendas,Vendas[Valor], 0.25 )`
- `Min_Value = MIN (Vendas[Valor] )`

Usando percentil com PBI

Use o arquivo “vendas.csv”



ID	Data	Produto	Serial	Valor	Custo	Cidade	Estado	País
1009	6/3/2017	DX101	GF54319	17.62	9.16	Belo Horizonte	Minas Gerais	Brasil
1031	18/03/2017	DX101	GF54489	18.56	8.11	Belo Horizonte	Minas Gerais	Brasil
1034	20/03/2017	DX101	GF54405	19.12	8.11	Vitória	Espírito Santo	Brasil
1057	31/03/2017	DX101	GF54430	19.11	8.28	São Paulo	São Paulo	Brasil
1059	24/03/2017	DX101	GF54576	18.9	8.99	Vitória	Espírito Santo	Brasil
1062	29/03/2017	DX101	GF54587	16.87	9.34	Vitória	Espírito Santo	Brasil
1076	22/03/2017	DX101	GF54501	18.34	9.34	Campos	Rio de Janeiro	Brasil
1077	5/3/2017	DX101	GF54258	17.43	9.52	Belo Horizonte	Minas Gerais	Brasil
1085	20/03/2017	DX101	GF54296	21.23	8.11	Uberlândia	Minas Gerais	Brasil
1087	20/03/2017	DX101	GF54389	22.9	8.64	Uberlândia	Minas Gerais	Brasil
1090	29/03/2017	DX101	GF54462	23.87	9.69	Petrópolis	Rio de Janeiro	Brasil
1093	2/3/2017	DX101	GF54592	15.56	9.34	Belo Horizonte	Minas Gerais	Brasil
1102	23/03/2017	DX101	GF54599	16.98	8.64	Taubaté	São Paulo	Brasil
1027	27/02/2017	CX102	GF54233	24.79	11.4	Belo Horizonte	Minas Gerais	Brasil
1048	3/3/2017	CX102	GF54664	25.98	12.89	Linhares	Espírito Santo	Brasil
1066	5/3/2017	CX102	GF54402	26.9	13.39	Petrópolis	Rio de Janeiro	Brasil
1094	5/3/2017	CX102	GF54679	21.87	11.4	Belo Horizonte	Minas Gerais	Brasil
1004	28/03/2017	BX101	GF54527	30.06	13.53	Rio de Janeiro	Rio de Janeiro	Brasil
1039	17/03/2017	BX101	GF54692	29.4	14.73	Vila Velha	Espírito Santo	Brasil
1040	4/3/2017	BX101	GF54696	28.98	14.73	Vila Velha	Espírito Santo	Brasil

Carregue o arquivo Vendas.CSV

Clique no data view e crie as medidas (modelagem)

Calculando a media das 20% maiores vendas

Calcule a media das vendas entre as top 20, ou seja, 20% das maiores vendas, calcule a media.

Structure | Formatting | Properties | Calculations

```
1 MediaTop20 = CALCULATE( AVERAGE(Vendas[Valor]), FILTER(Vendas, Vendas[Valor] >= PERCENTILE.EXC(Vendas[Valor], 0.8)))
```

ID	Data	Produto	Serial	Valor	Custo	Cidade	Estado	País
1009	6/3/2017	DX101	GF54319	$17.62	$9.16	Belo Horizonte	Minas Gerais	Brasil
1031	18/03/2017	DX101	GF54489	$18.56	$8.11	Belo Horizonte	Minas Gerais	Brasil
1034	20/03/2017	DX101	GF54405	$19.12	$8.11	Vitória	Espírito Santo	Brasil

Retorna tudo EXCluindo o percentil

Consulte daxpattern.com/statistical-patterns

Exercício

Use o arquivo com dados de pacientes e crie uma tabela de análise descritiva no Power BI com a média, mediana e moda da idade, altura e peso dos pacientes.

Além disso, responda:

- Qual a moda do tipo sanguíneo?
- Qual a moda do estado civil?



Use o arquivo “dados_pacientes.csv”

Medidas de posição

```python
import pandas as pd
```

```python
# Carregar os dados
df = pd.read_csv("/content/dados_pacientes.csv")
```

```python
# Selecionar a coluna de interesse
peso = df['peso(kg)']
```

```python
# Cálculos
media = peso.mean()
mediana = peso.median()
moda = peso.mode()[0]  # .mode() retorna uma série, pegamos o primeiro valor
```

```python
print(f"Média: {media:.2f} kg")
print(f"Mediana: {mediana} kg")
print(f"Moda: {moda} kg")
```

Mostrar saída oculta

Medidas de posição

Resumo Estatístico Rápido
O método `.describe()` do pandas é a forma mais rápida de obter várias medidas de posição de uma só vez para todas as colunas numéricas

```
resumo = df[['idade(anos)', 'altura(cm)', 'peso(kg)']].describe()
print(resumo)
```

Moda em Python

```python
import statistics
scores = [1, 2, 2, 2, 3, 4, 4, 4, 5, 6]
# A função multimode() retorna uma lista com todos os valores da moda
moda = statistics.multimode(scores)
print(f"A(s) moda(s) é(são): {moda}")
```

```python
import pandas as pd
scores = [1, 2, 2, 2, 3, 4, 4, 4, 5, 6]
# Converte a lista para uma Series do pandas
scores_series = pd.Series(scores)
# O método .mode() de uma Series retorna todos os valores da moda
moda = scores_series.mode()
# O resultado é uma Series que deve ser convertida para lista(melhor visualização)
print(f"A(s) moda(s) é(são): {moda.tolist()}")
```

Tabela de frequência em Python

[1]
```python
import pandas as pd

# Leitura do arquivo CSV com o pandas
# O encoding também foi ajustado
usuarios = pd.read_csv("Usuarios.csv", sep=",", decimal=".", encoding="windows-1252")
print("Nomes das colunas:")
print(usuarios.columns)
print("-" * 30)
print("Estrutura do DataFrame:")
usuarios.info()
print("-" * 30)
print("Resumo estatístico:")
print(usuarios.describe())
```

[2]
```python
freq = usuarios['grau_instrucao'].value_counts()
print(freq)
```

[3]
```python
# Para obter a frequência relativa com .value_counts(), usamos o argumento normalize=True
freq_rel = usuarios['grau_instrucao'].value_counts(normalize=True)
print(freq_rel)
```

[5]
```python
# Simplesmente multiplicamos a frequência relativa por 100
p_freq_rel = usuarios['grau_instrucao'].value_counts(normalize=True) * 100
print(p_freq_rel)
```

```python
# Em pandas, podemos adicionar uma nova linha ao final da Series
freq['Total'] = freq.sum()
freq_rel['Total'] = freq_rel.sum()
p_freq_rel['Total'] = p_freq_rel.sum()
# O nome da última linha da 'freq' já foi definido como 'Total',
# não sendo necessário renomear as outras, pois faremos a junção em um novo DataFrame.
```

[7]
```python
tabela_final = pd.DataFrame({
    'freq': freq,
    'freq_rel': freq_rel,
    'p_freq_rel': p_freq_rel
})
print(tabela_final)
```

Boxplot com python e PBI: Análise de preços de imóveis por Bairro

- O objetivo é analisar a distribuição dos preços por metro quadrado (Preco_m2) em três bairros diferentes para identificar variações de mercado, valores centrais e possíveis *outliers* (imóveis com preços muito acima ou abaixo da média do bairro)
- Comparação de mercados:
  - Analise como a mediana e a amplitude variam entre os bairros
- Identificação de outliers:
  - Aponte os pontos individuais no Sacomã e nos Jardins. Discuta como o boxplot ajuda a isolar esses casos para uma investigação
- Vantagens da visualização em Python
  - O seaborn permite o uso dos swarmplot (pontos individuais) no boxplot



Use o arquivo “MercadoImobiliario.csv”

Boxplot com python e PBI: Análise de preços de imóveis por Bairro

- **Carregar Dados:** Leia o arquivo MercadoImobiliario.csv
- **Adicionar Visual Python:** Clique no ícone **Visual de script do Python** no painel "Visualizações”
- **Configurar Campos:** Arraste os campos **'Bairro'** e **'Preco_m2'** para a área "Valores" do visual
  - Isso cria o DataFrame
  - Não esqueça de colocar “não resumir” para o campo Preco_m2
- **Escrever o Script:** No editor de script Python, codifique o código python

Análise de preços de imóveis por Bairro

```
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
# O Power BI cria o DataFrame 'dataset' com os campos selecionados
# Configura o estilo visual do seaborn
sns.set_theme(style="whitegrid")
# Cria o boxplot
# x define as categorias (Bairro)
# y define a variável numérica (Preco_m2)
# palette define as cores
plt.figure(figsize=(10, 6)) # Define o tamanho da figura
ax = sns.boxplot(x='Bairro', y='Preco_m2', data=dataset, palette="Set2")

# Adiciona pontos individuais (swarmplot) sobre o boxplot
#para mostrar a densidade dos dados
sns.swarmplot(x='Bairro', y='Preco_m2', data=dataset, color=".25", size=4)

# Personaliza títulos e rótulos
plt.title('Distribuição de Preço/m² por Bairro em São Paulo', fontsize=14)
plt.xlabel('Bairro', fontsize=12)
plt.ylabel('Preço por m² (R$)', fontsize=12)

# Exibe o gráfico no Power BI
plt.show()
```

Medidas de dispersão

Medidas de dispersão

Uma maneira de descrever um conjunto de dados, é através de **medidas de dispersão**. Elas descrevem a amplitude dos dados, ou seja, quão espalhados os dados estão dentro de um conjunto.

Medidas de dispersão: variância

A **variância** mede a amplitude (variabilidade) dos dados em relação à média.

Medidas de dispersão: desvio padrão

O **desvio padrão** é usado para medir a variabilidade entre os números em um conjunto de dados. Assim como o nome sugere, o desvio padrão é um padrão de desvio (distância) da média.

É a raíz quadrada da variância

Exemplo: Anderson x Patrícia

Anderson – cursa 6 disciplinas na faculdade de Estatística e obteve as seguintes notas no exame final:

Disciplinas	Notas
Disciplina 1	100
Disciplina 2	100
Disciplina 3	100
Disciplina 4	50
Disciplina 5	50
Disciplina 6	50

Média final = 75

Média para aprovação = 60

Exemplo: Anderson x Patrícia

Patrícia – também cursa 6 disciplinas na faculdade de Estatística e obteve as seguintes notas no exame final:

Disciplinas	Notas
Disciplina 1	75
Disciplina 2	74
Disciplina 3	76
Disciplina 4	77
Disciplina 5	75
Disciplina 6	74

Média final = 75

Qual a diferença destas 2 distribuições ?

Exemplo Anderson x Patricia em Python

```python
import pandas as pd
```

```python
# Criar as Series (equivalente aos arrays do numpy)
anderson = pd.Series([100, 100, 100, 50, 50, 50])
patricia = pd.Series([75, 74, 76, 77, 75, 74])
```

```python
# Calcular e imprimir as médias
media_anderson = anderson.mean()
media_patricia = patricia.mean()
print(f"Média de Anderson: {media_anderson}")
print(f"Média de Patrícia: {media_patricia}")
print("-" * 30)
```

```python
 #Calcular e imprimir as variâncias
var_anderson = anderson.var()
var_patricia = patricia.var()
print(f"Variância de Anderson: {var_anderson:.4f}")
print(f"Variância de Patrícia: {var_patricia:.4f}")
print("-" * 30)
```

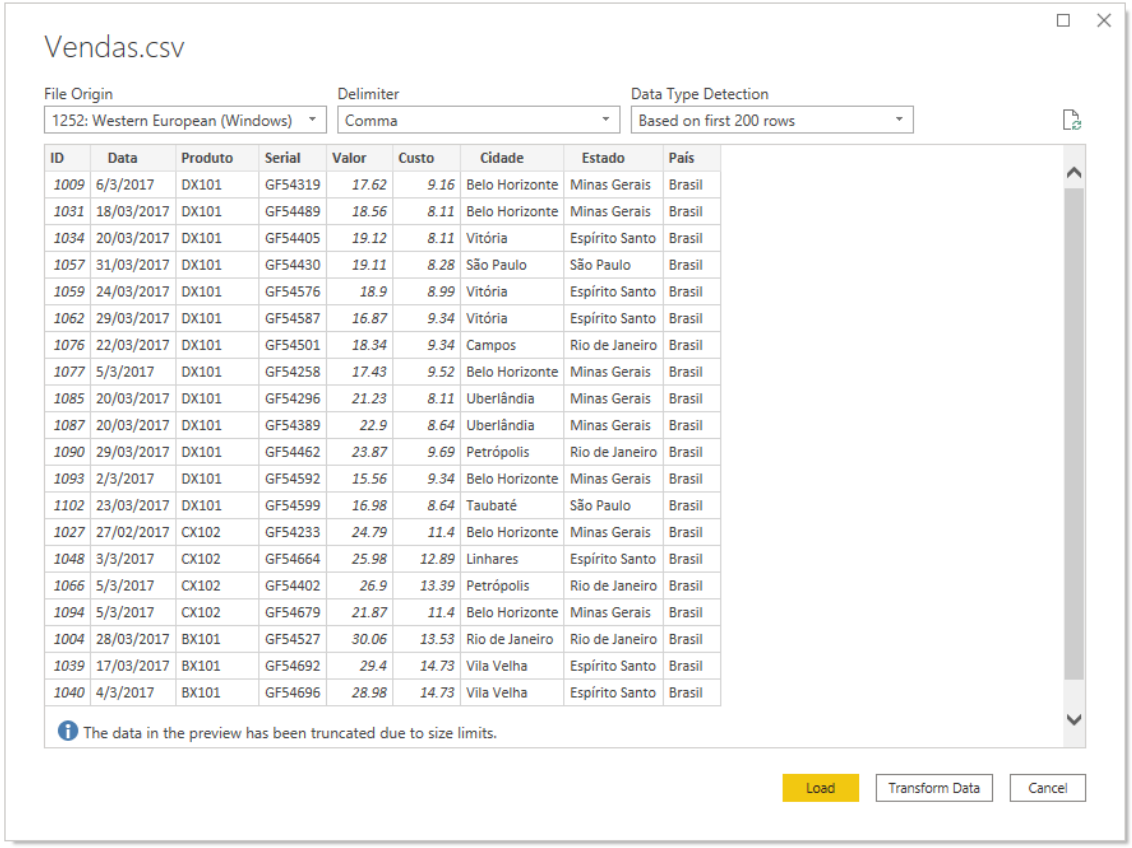
```python
# Calcular e imprimir os desvios padrão
dp_anderson = anderson.std()
dp_patricia = patricia.std()
print(f"Desvio Padrão de Anderson: {dp_anderson:.4f}")
print(f"Desvio Padrão de Patrícia: {dp_patricia:.4f}")
```

Veja a variabilidade da amostra





Calculando posições com Power BI



ID	Data	Produto	Serial	Valor	Custo	Cidade	Estado	País
1009	6/3/2017	DX101	GF54319	17.62	9.16	Belo Horizonte	Minas Gerais	Brasil
1031	18/03/2017	DX101	GF54489	18.56	8.11	Belo Horizonte	Minas Gerais	Brasil
1034	20/03/2017	DX101	GF54405	19.12	8.11	Vitória	Espírito Santo	Brasil
1057	31/03/2017	DX101	GF54430	19.11	8.28	São Paulo	São Paulo	Brasil
1059	24/03/2017	DX101	GF54576	18.9	8.99	Vitória	Espírito Santo	Brasil
1062	29/03/2017	DX101	GF54587	16.87	9.34	Vitória	Espírito Santo	Brasil
1076	22/03/2017	DX101	GF54501	18.34	9.34	Campos	Rio de Janeiro	Brasil
1077	5/3/2017	DX101	GF54258	17.43	9.52	Belo Horizonte	Minas Gerais	Brasil
1085	20/03/2017	DX101	GF54296	21.23	8.11	Uberlândia	Minas Gerais	Brasil
1087	20/03/2017	DX101	GF54389	22.9	8.64	Uberlândia	Minas Gerais	Brasil
1090	29/03/2017	DX101	GF54462	23.87	9.69	Petrópolis	Rio de Janeiro	Brasil
1093	2/3/2017	DX101	GF54592	15.56	9.34	Belo Horizonte	Minas Gerais	Brasil
1102	23/03/2017	DX101	GF54599	16.98	8.64	Taubaté	São Paulo	Brasil
1027	27/02/2017	CX102	GF54233	24.79	11.4	Belo Horizonte	Minas Gerais	Brasil
1048	3/3/2017	CX102	GF54664	25.98	12.89	Linhares	Espírito Santo	Brasil
1066	5/3/2017	CX102	GF54402	26.9	13.39	Petrópolis	Rio de Janeiro	Brasil
1094	5/3/2017	CX102	GF54679	21.87	11.4	Belo Horizonte	Minas Gerais	Brasil
1004	28/03/2017	BX101	GF54527	30.06	13.53	Rio de Janeiro	Rio de Janeiro	Brasil
1039	17/03/2017	BX101	GF54692	29.4	14.73	Vila Velha	Espírito Santo	Brasil
1040	4/3/2017	BX101	GF54696	28.98	14.73	Vila Velha	Espírito Santo	Brasil

Carregue o arquivo Vendas.CSV

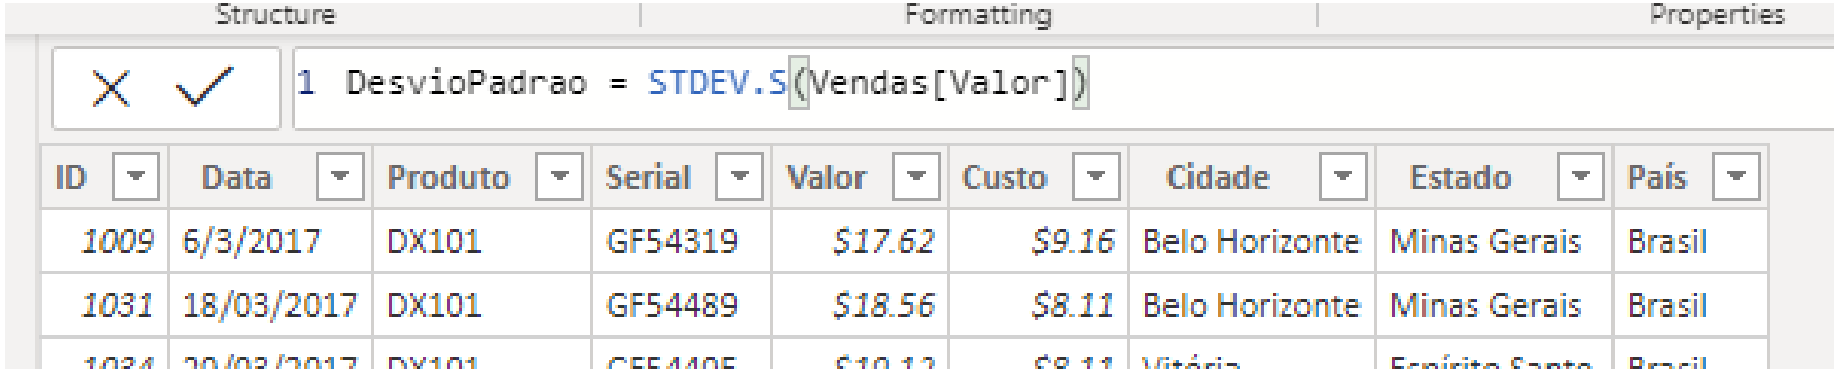
Clique no data view e crie as medidas (modelagem)

Desvio padrão

Standard Deviation

You can use standard DAX functions to calculate the standard deviation of a set of values.

- **STDEV.S**: returns the standard deviation of values in a column representing a sample population.
- **STDEV.P**: returns the standard deviation of values in a column representing the entire population.
- **STDEVX.S**: returns the standard deviation of an expression evaluated over a table representing a sample population.
- **STDEVX.P**: returns the standard deviation of an expression evaluated over a table representing the entire population.



ID	Data	Produto	Serial	Valor	Custo	Cidade	Estado	País
1009	6/3/2017	DX101	GF54319	$17.62	$9.16	Belo Horizonte	Minas Gerais	Brasil
1031	18/03/2017	DX101	GF54489	$18.56	$8.11	Belo Horizonte	Minas Gerais	Brasil

A escolha depende de quanto você quer ser preciso e do quanto de dados você realmente tem à sua disposição
Se você tem "todos os dados", use .P; se você tem "apenas alguns", use .S.

Usar a função `.S` quando se tem uma amostra é matematicamente importante porque ela inclui uma pequena correção para compensar o fato de que uma amostra tende a ter menos variação do que a população real, evitando conclusões otimistas e errôneas

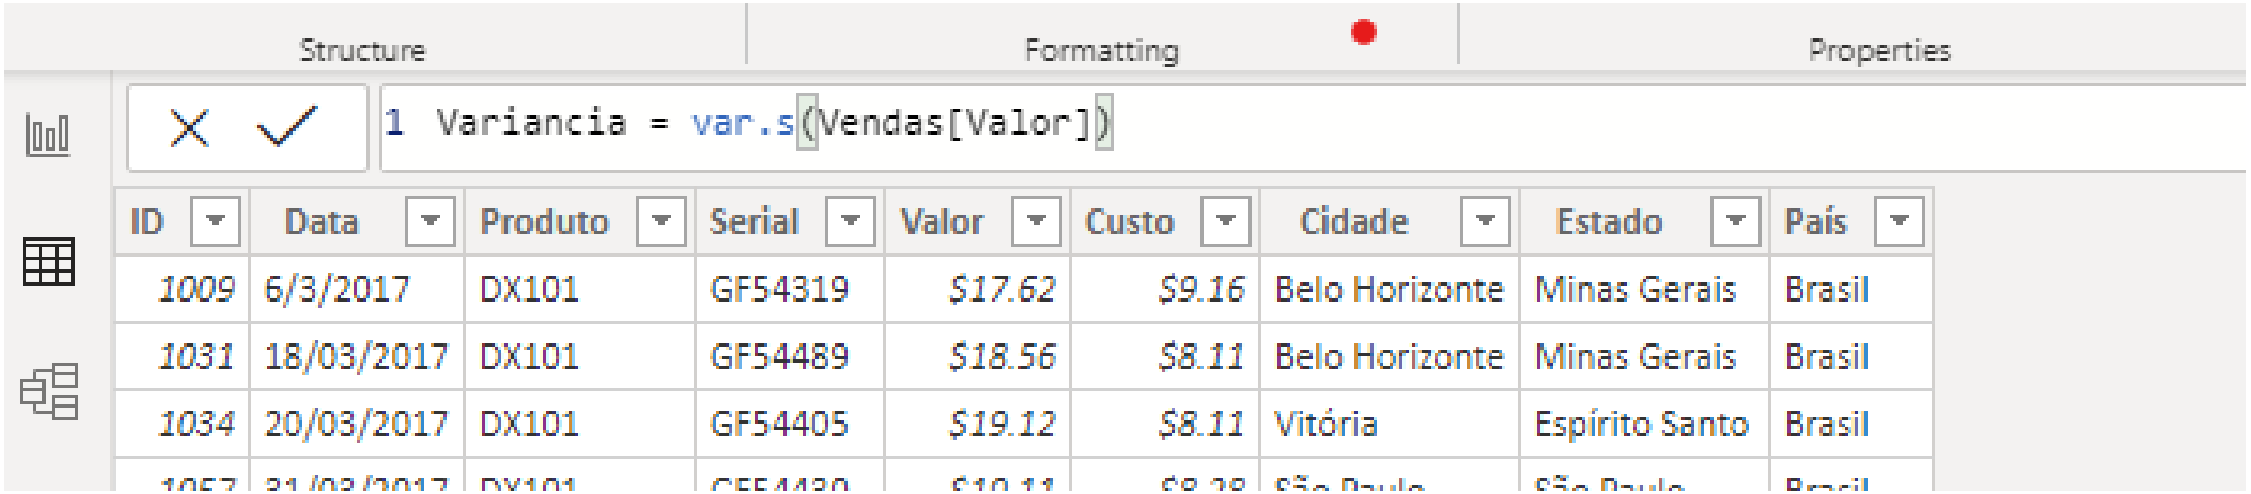
Fonte: daxpatterns.com

Variância

Variance

You can use standard DAX functions to calculate the variance of a set of values.

- **VAR.S**: returns the variance of values in a column representing a sample population.
- **VAR.P**: returns the variance of values in a column representing the entire population.
- **VARX.S**: returns the variance of an expression evaluated over a table representing a sample population.
- **VARX.P**: returns the variance of an expression evaluated over a table representing the entire population.



ID	Data	Produto	Serial	Valor	Custo	Cidade	Estado	País
1009	6/3/2017	DX101	GF54319	$17.62	$9.16	Belo Horizonte	Minas Gerais	Brasil
1031	18/03/2017	DX101	GF54489	$18.56	$8.11	Belo Horizonte	Minas Gerais	Brasil
1034	20/03/2017	DX101	GF54405	$19.12	$8.11	Vitória	Espírito Santo	Brasil

Fonte: daxpatterns.com