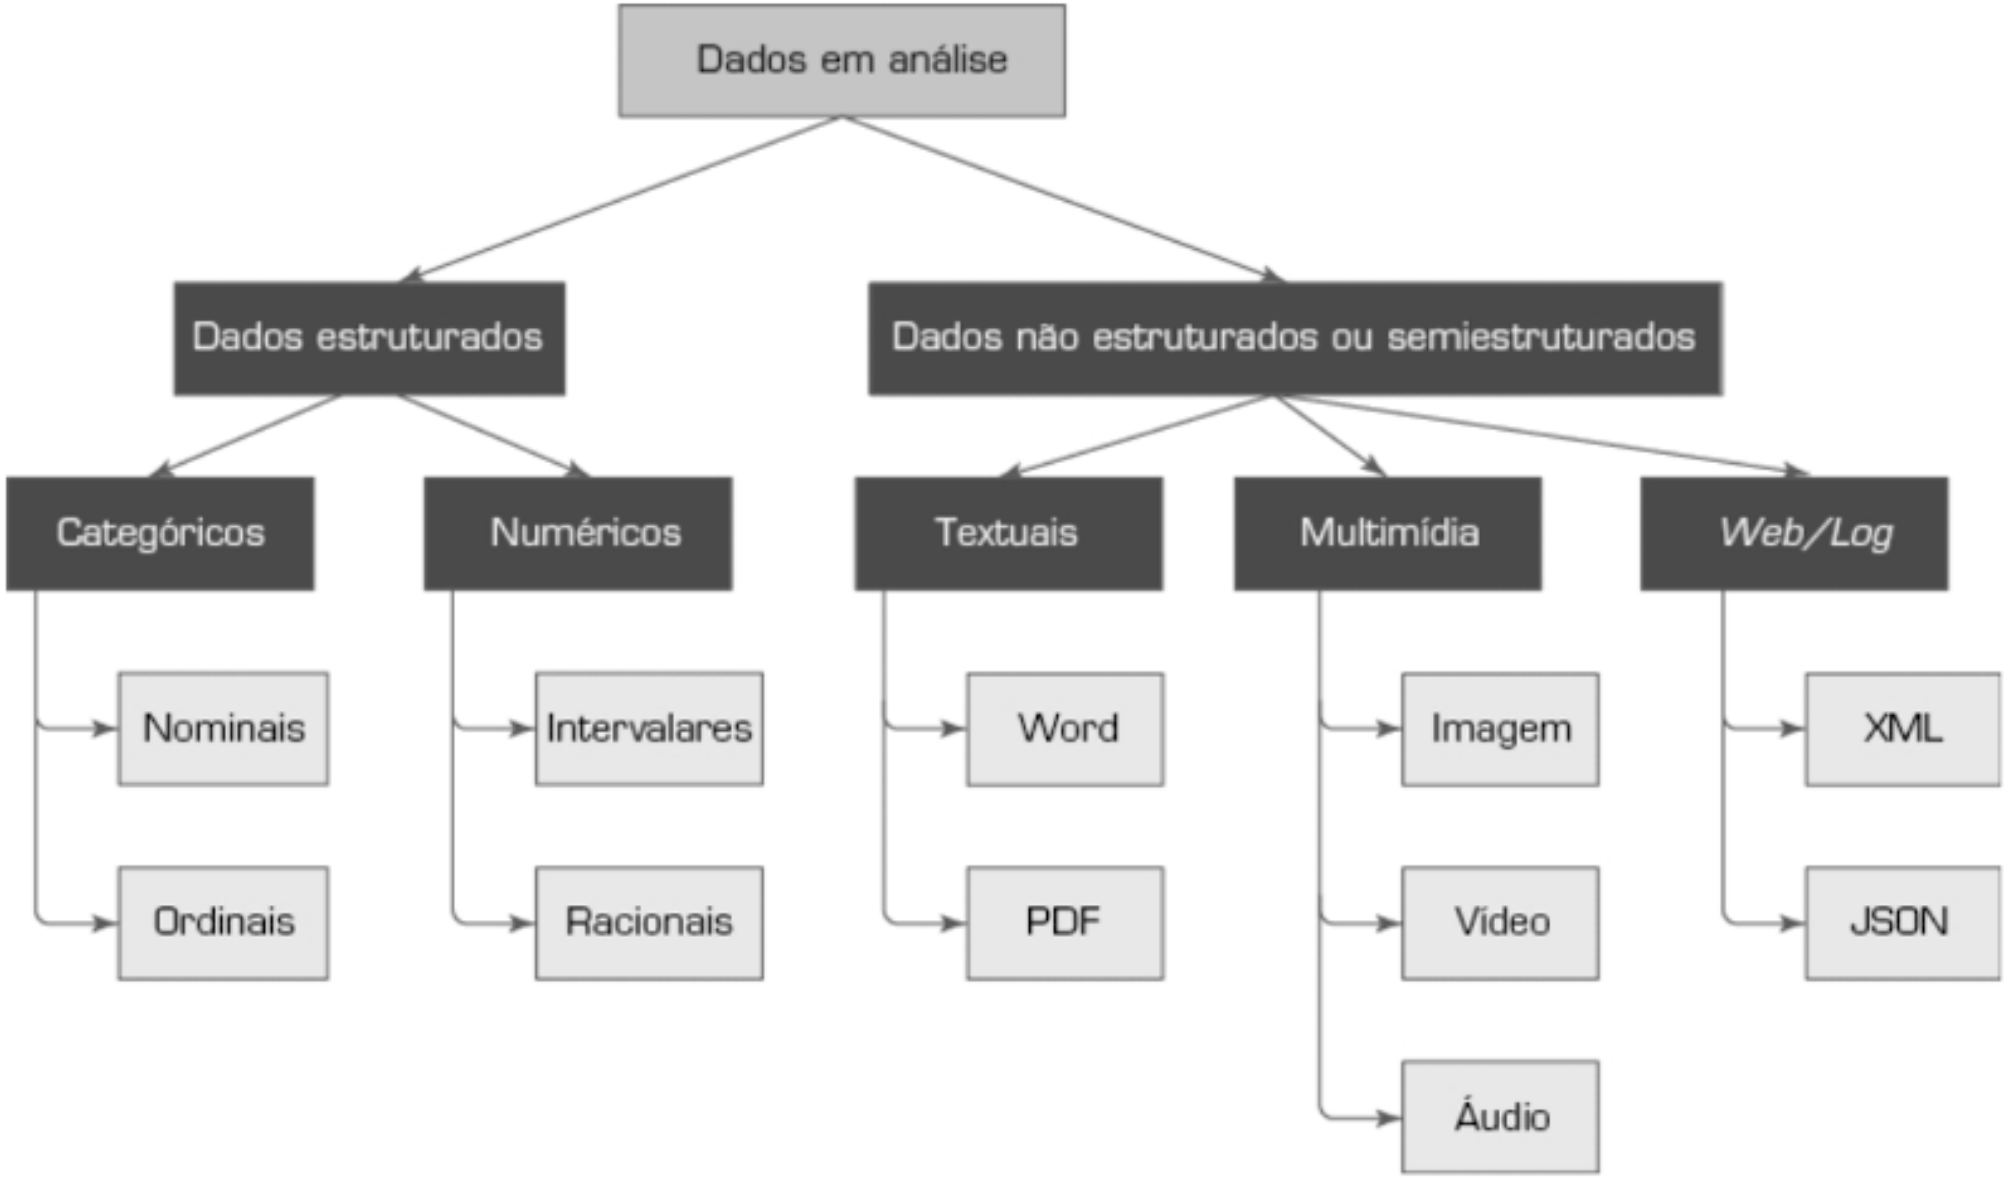
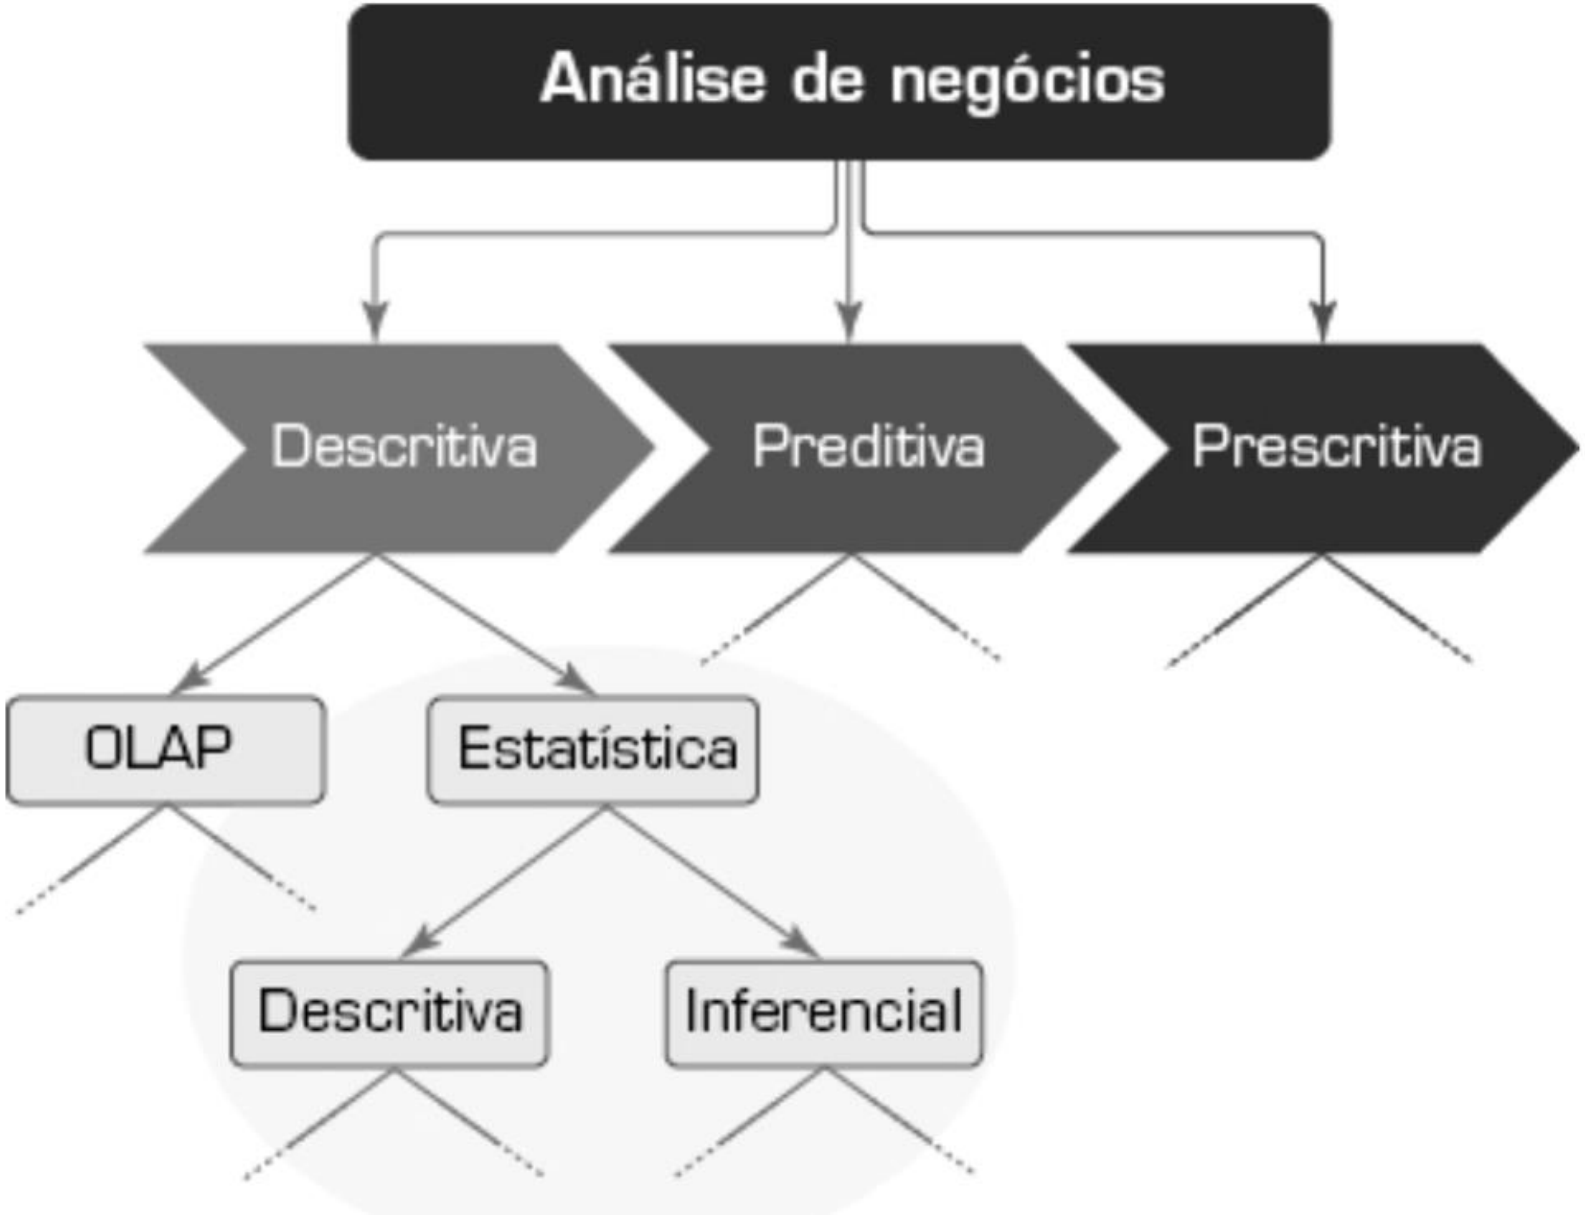
ESTATÍSTICA APLICADA À CIÊNCIA DE DADOS II

Fatec 2026 – Análise exploratória

Taxonomia dos dados



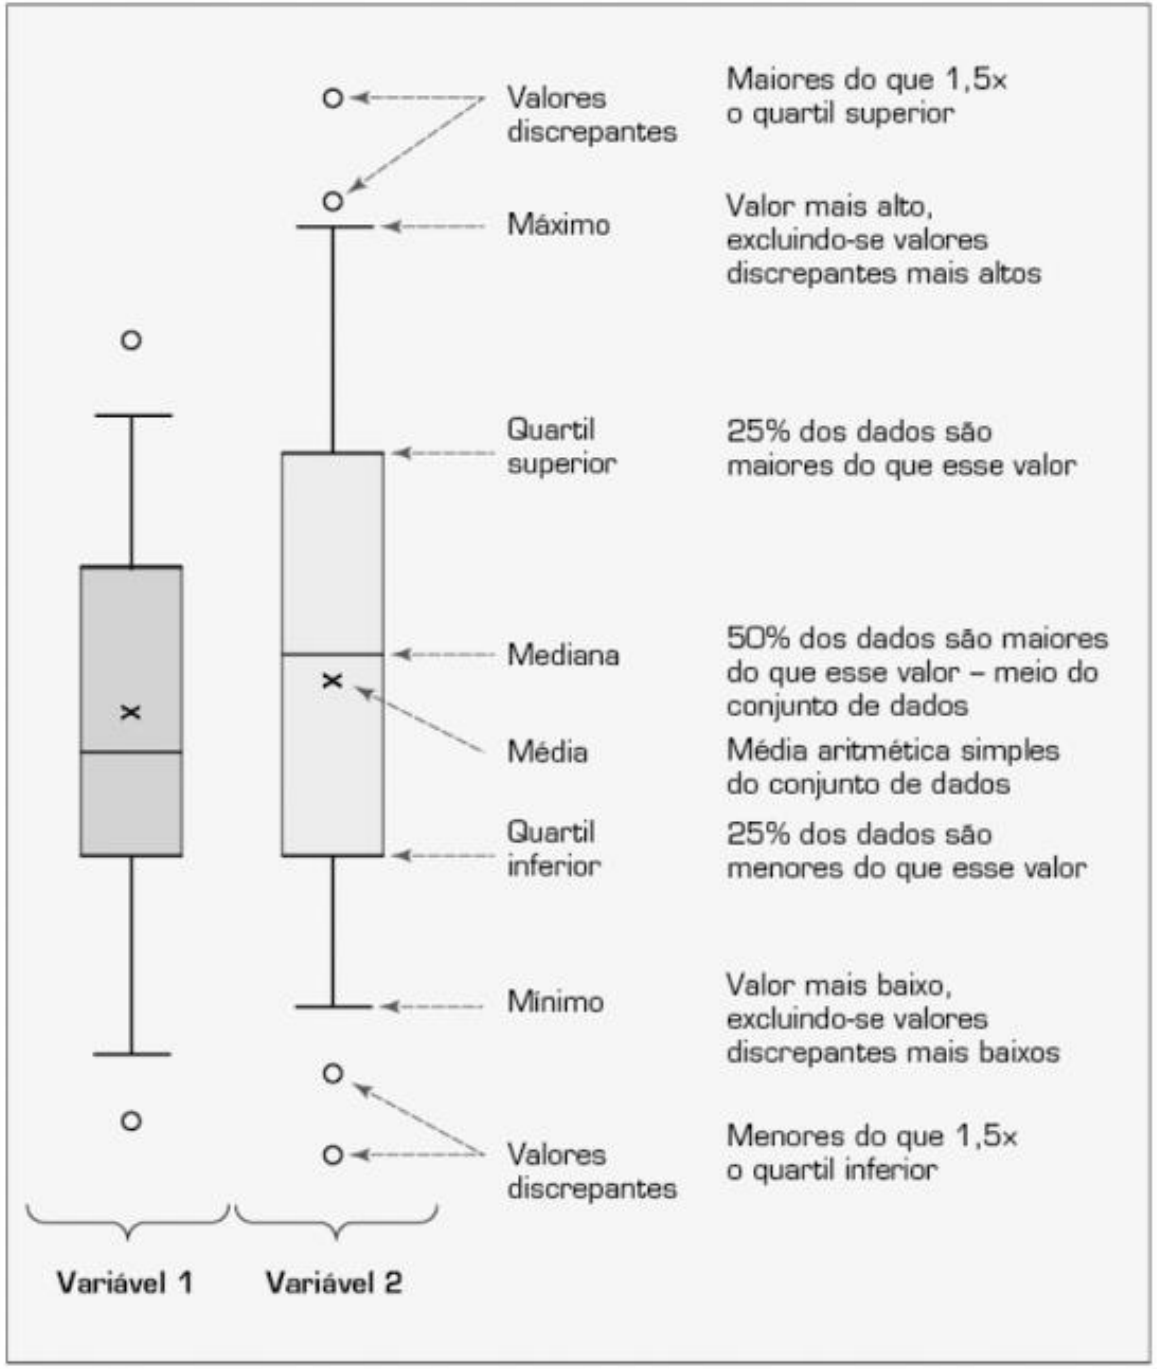
Modelagem estatística para análise de negócios



BoxPlot

Exibe

- Centralidade
- Dispersão
- Amplitudes (bigodes)
- Valores discrepantes (outliers)
- Simetria dos dados em relação à media



Identificando outliers(1)

```python
import numpy as np
import seaborn as sns
import matplotlib.pyplot as plt

dados = [501, 504, 493, 499, 497, 503, 525, 495, 506, 502]
```

```python
media = np.mean(dados)
variancia = np.var(dados, ddof=1) # Variância amostral
valor_maximo = np.max(dados)
valor_minimo = np.min(dados)
mediana = np.median(dados)
desvio = np.std(dados, ddof=1)
quartis = np.percentile(dados, [25, 50, 75])
print("--- Análise Estatística ---")
print(f"Dados: {dados}")
print(f"Média: {media:.2f}")
print(f"Mediana: {mediana}")
print(f"Desvio Padrão: {desvio:.2f}")
print(f"Variância: {variancia:.2f}")
print(f"Valor Mínimo: {valor_minimo}")
print(f"Valor Máximo: {valor_maximo}")
print(f"Quartis (P25, P50, P75): {quartis}")
```

Identificando outliers(2)

```
plt.figure(figsize=(12, 8))
# Cria um eixo x para o gráfico de dispersão (índice de cada dado)
indices = range(len(dados))
# Cria o gráfico de dispersão
ax = sns.scatterplot(x=indices, y=dados, s=100, label='Dados')
# Adiciona as linhas horizontais para cada métrica
# ax.axhline() para linhas horizontais
ax.axhline(media, color='red', linestyle='--', label=f'Média ({media:.2f})')
ax.axhline(mediana, color='green', linestyle='-', label=f'Mediana ({mediana})')
ax.axhline(valor_minimo, color='gray', linestyle=':', label=f'Mínimo ({valor_minimo})')
ax.axhline(valor_maximo, color='gray', linestyle=':', label=f'Máximo ({valor_maximo})')
# Adiciona linhas para os quartis 1 e 3
ax.axhline(quartis[0], color='orange', linestyle='-.', label=f'1º Quartil (P25) ({quartis[0]})')
ax.axhline(quartis[2], color='purple', linestyle='-.', label=f'3º Quartil (P75) ({quartis[2]})')
# Adiciona um título e rótulos
ax.set_title('Gráfico de Dispersão com Métricas Estatísticas', fontsize=16)
ax.set_xlabel('Índice do Dado', fontsize=12)
ax.set_ylabel('Valores', fontsize=12)
#ax.legend() # Mostra a legenda com os rótulos das linhas
# Exibe o gráfico
plt.grid(True, linestyle='--', alpha=0.6) # Adiciona uma grade para melhor visualização
plt.show()
```

Identificando outliers(3)

```
# 1. Calcular Q1 e Q3 (percentis 25 e 75)
q1 = np.percentile(dados, 25)
q3 = np.percentile(dados, 75)
# 2. Calcular o IQR
iqr = q3 - q1
# 3. Calcular os limites para detecção de outliers
limite_inferior = q1 - 1.5 * iqr
limite_superior = q3 + 1.5 * iqr
# Imprimir os resultados
print("--- Análise de Outliers com IQR ---")
print(f"Dados: {sorted(dados)}") # Mostra os dados ordenados
print(f"Primeiro Quartil (Q1): {q1}")
print(f"Terceiro Quartil (Q3): {q3}")
print(f"IQR (Amplitude Interquartil): {iqr:.2f}")
print("-" * 35)
print(f"Limite Inferior para Outliers: {limite_inferior:.2f}")
print(f"Limite Superior para Outliers: {limite_superior:.2f}")
# 4. Identificar os outliers
outliers = [] # Cria uma lista vazia
for ponto in dados:
    if ponto < limite_inferior or ponto > limite_superior:
        outliers.append(ponto) # Adiciona o ponto à lista se for um outlier

print(f"\nOutliers identificados: {outliers}")
```

Outliers na base da vazão do Rio Nilo(1)

```python
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt

# Link  para o arquivo CSV
url = 'https://vincentarelbundock.github.io/Rdatasets/csv/datasets/Nile.csv'
# Lendo os dados com o pandas
nile_df = pd.read_csv(url)
print( nile_df.head())
# A coluna de interesse é a 'value', que corresponde à vazão do Nilo é copiada para uma variável
vazao_nilo = nile_df['value']
print("--- Informações da Base de Dados ---")
nile_df.info()
print("\n--- Primeiras 5 linhas da vazão ---")
print(vazao_nilo.head())
```

Outliers na base da vazão do Rio Nilo(2)

```
# Define o tamanho da figura
plt.figure(figsize=(12, 6))
# Plota os dados
plt.plot(nile_df['time'], vazao_nilo)
# Customiza os eixos
plt.xticks(np.arange(1871, 1971, 20)) # Eixo X (anos)
plt.yticks(np.arange(400, 1500, 100)) # Eixo Y (vazão)
# Adiciona rótulos e título
plt.xlabel("Ano")
plt.ylabel("Vazão do Nilo")
plt.title("Vazão Anual do Rio Nilo (1871-1970)")
plt.grid(True, linestyle='--', alpha=0.6)
plt.show()
```

```
# --- Análise de Outliers com Boxplot ---
plt.figure(figsize=(6, 8))
plt.boxplot(vazao_nilo)
plt.ylabel("Vazão do Nilo")
plt.title("Boxplot da Vazão do Rio Nilo")
plt.grid(True, linestyle='--', alpha=0.6)
plt.show()
```

Outliers na base da vazão do Rio Nilo(3)

```
print("\n--- Análise de Outliers ---")
Q1 = vazao_nilo.quantile(0.25)
Q3 = vazao_nilo.quantile(0.75)
IQR = Q3 - Q1
limite_inferior = Q1 - 1.5 * IQR
limite_superior = Q3 + 1.5 * IQR

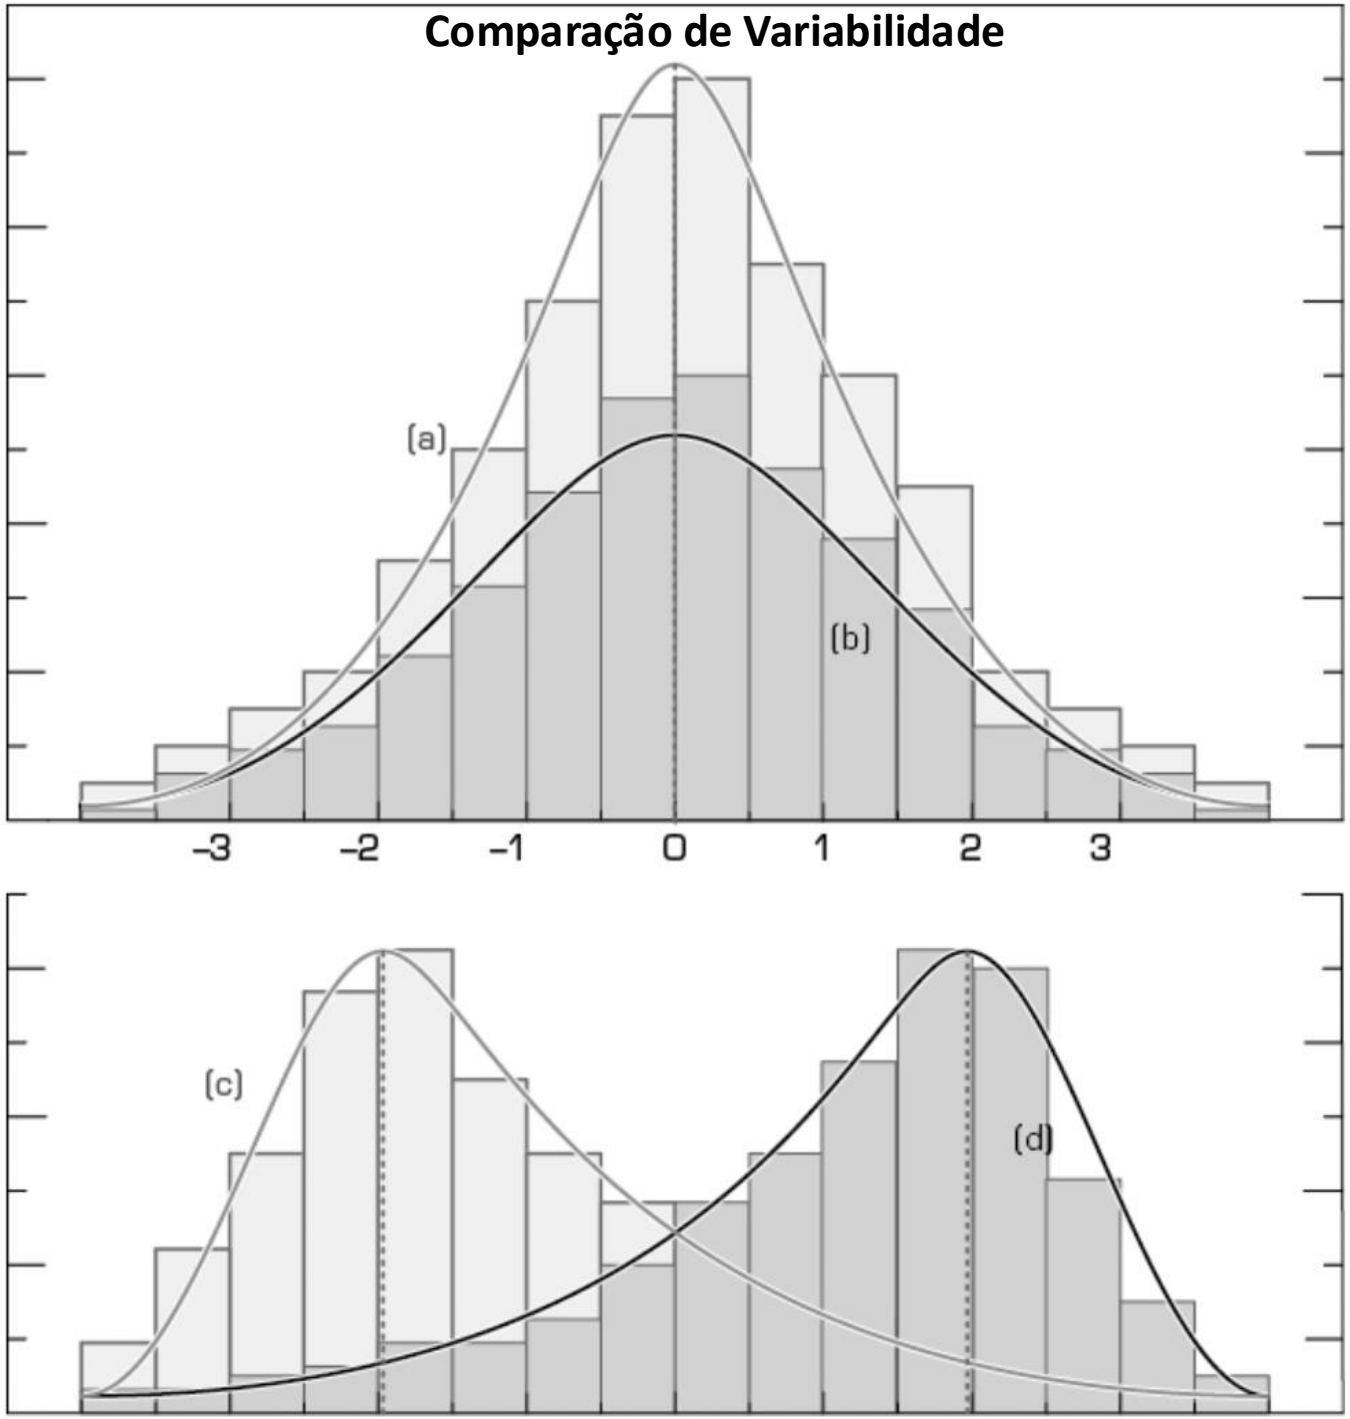
# Filtra os dados para encontrar os outliers
outliers = vazao_nilo[(vazao_nilo < limite_inferior) | (vazao_nilo > limite_superior)]

print(f"\nLimite inferior para outliers: {limite_inferior:.2f}")
print(f"Limite superior para outliers: {limite_superior:.2f}")

if not outliers.empty:
    print("\nOutliers identificados:")
    print(outliers)
else:
    print("\nNenhum outlier identificado pelo método IQR.")
```

O formato de uma distribuição

- Distribuição é a frequência dos pontos de dados contados e plotados ao longo de um compartimento
- Y= frequência
- X= compartimento em ordem de pontuação

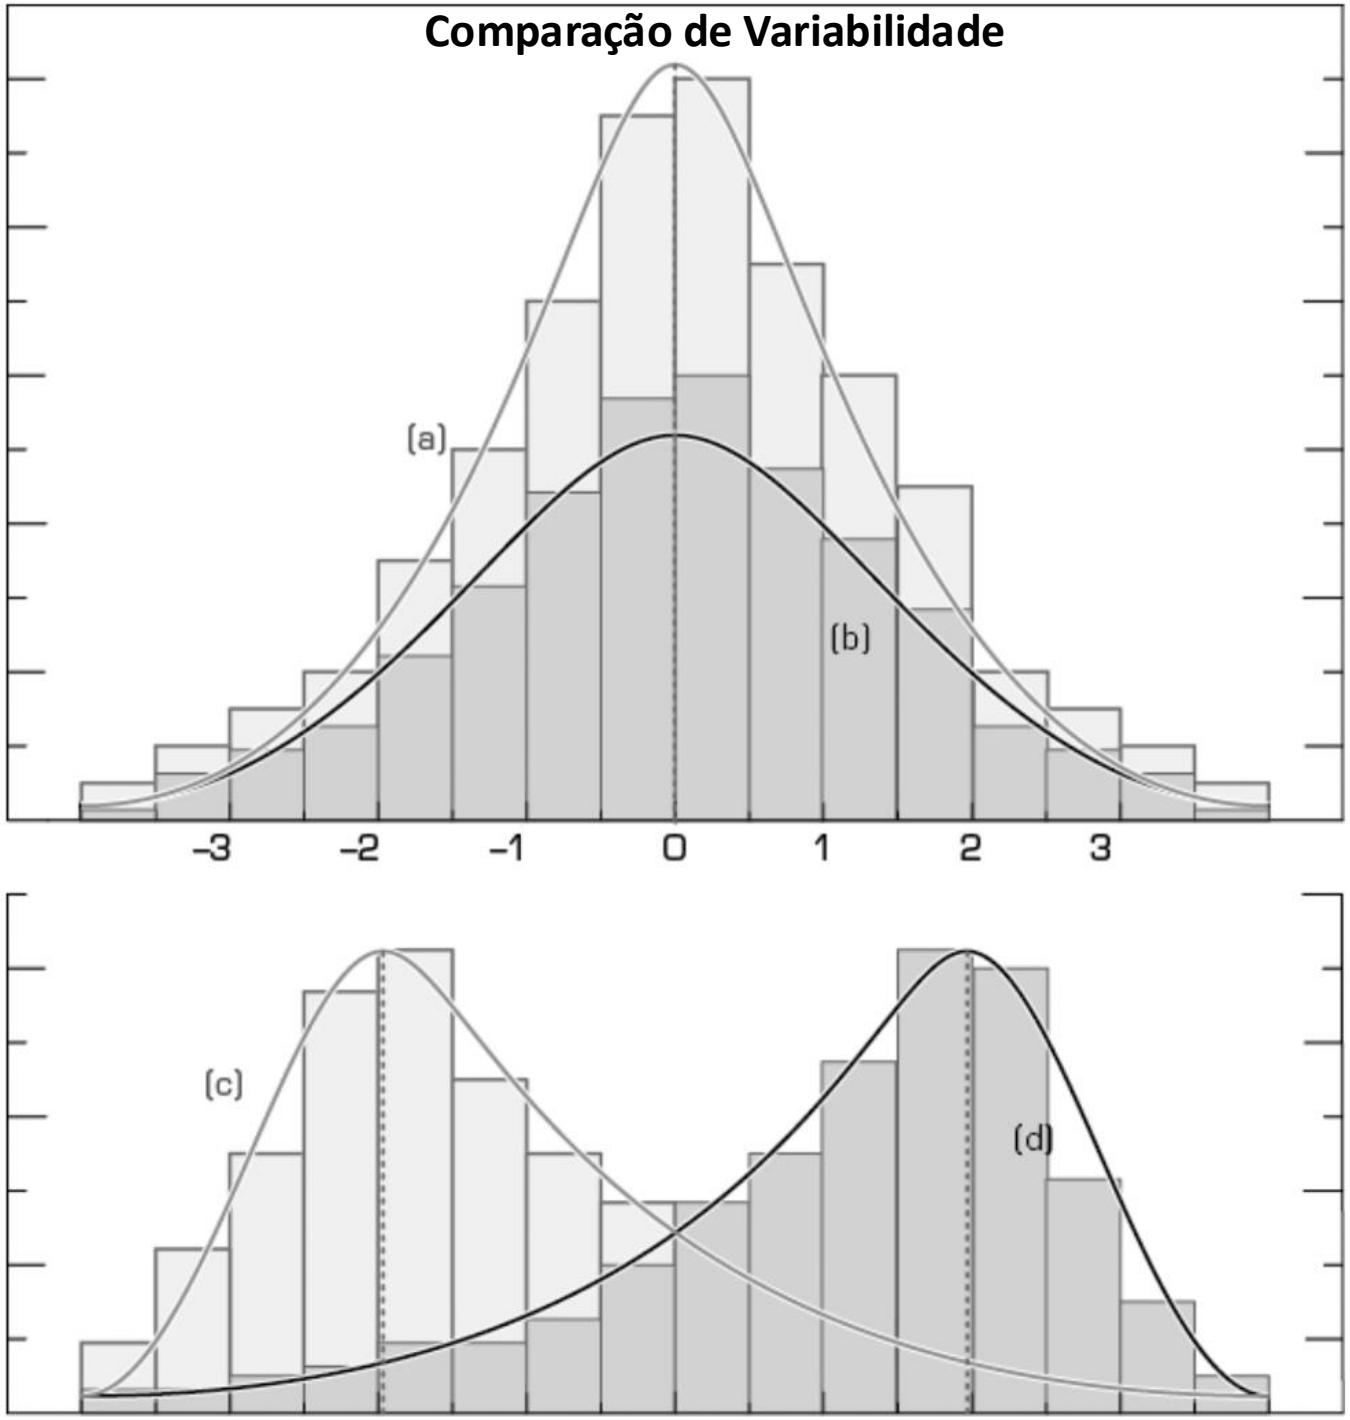


O formato de uma distribuição

Ambas as distribuições estão centralizadas no mesmo ponto (média = 0), mas diferem na "largura”

•**(a) Distribuição de Baixa Variância:** Esta curva é mais alta e estreita. Isso indica que a maioria dos dados está fortemente concentrada em torno da média. O desvio padrão (σ) é pequeno.

•**(b) Distribuição de Alta Variância:** A curva é mais "achatada" e espalhada. Isso mostra que os dados têm uma dispersão maior em relação à média; ou seja, há uma probabilidade maior de encontrar valores distantes do centro.

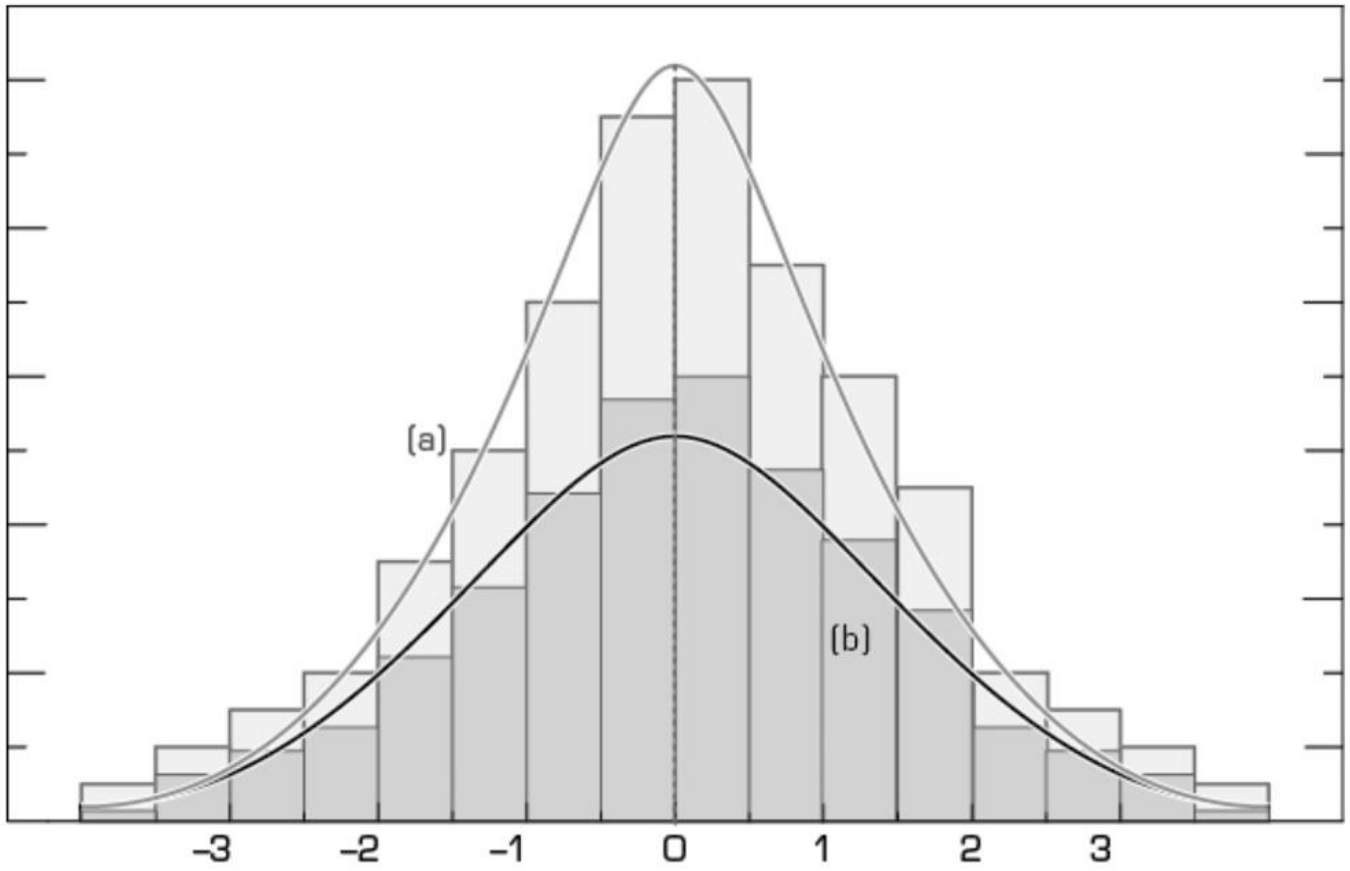


O formato de uma distribuição

Aqui, o formato das curvas (a dispersão) é semelhante, mas a posição delas no eixo horizontal mudou.

(c) Distribuição com Média Negativa: O pico da curva (a moda/média) está deslocado para a esquerda (aproximadamente em -2). Representa um grupo de dados onde os valores centrais são menores.

(d) Distribuição com Média Positiva: O pico está deslocado para a direita (aproximadamente em +2). Representa um grupo de dados com valores centrais maiores.



Comparação de Localização



Correlação

Análise de correlação

- Permite estudar a relação entre 2 conjuntos de valores
- Quantifica-se o quanto um conjunto de valores está relacionado com outro
- Determina a intensidade e a direção dessa relação
- Com que intensidade os valores de uma variavem aumentam ou diminuem enquanto os valores da outra variável aumenta ou diminuem?

Exemplo para correlação

- Um restaurante deseja comparar a quantidade de vendas do prato Feijoada (FJ) e da bebida caipirinha (CP), no decorrer dis nesses de novembro a julho, que ocorrem conforme a tabela:

Mês	11	12	1	2	3	4	5	6	7
FJ	24	27	29	30	32	58	64	64	65
CP	10	25	20	36	28	38	50	60	69

- A correlação encontrada é alta e positiva
- Quando a feijoada tem mais procura,
- Vende-se mais caipirinha.

```python
import numpy as np
# Cria os vetores como arrays do NumPy
fj = np.array([24, 27, 29, 30, 32, 58, 64, 64, 65])
cp = np.array([10, 25, 20, 36, 28, 38, 50, 60, 69])
# A função np.corrcoef() retorna uma matriz de correlação
matriz_correlacao = np.corrcoef(fj, cp)
print(matriz_correlacao)
# Extrai o valor da correlação (A correlação entre fj e cp estará na posição [0, 1] da matriz
correlacao = matriz_correlacao[0, 1]
print(f"A correlação de Pearson entre os dois vetores é: {correlacao:.4f}")
```