Séries Temporais

Fatec 2026

Definição

- dados coletados em intervalos regulares de tempo
  - Década, ano, mês, dia, hora, minuto, segundo
  - Dependência de ordem

Uma série temporal é um conjunto sequencial de pontos de dados, medido tipicamente em tempos sucessivos

- Usado para:
  - Compreender um fenômeno
  - Prever eventos

Diferença entre Análise e Previsão

Análise de Séries Temporais (Descritiva):

- • Busca entender o comportamento dos dados ao longo do tempo
- • Identifica **tendências** (crescimento ou queda ao longo do tempo), **sazonalidades** (padrões que se repetem, como estações do ano) e **ruído**
  - • **Ruído**: variações aleatórias ou imprevisíveis nos dados que não seguem um padrão claro. Exemplo: flutuações inesperadas nas vendas por causa de um evento não planejado

• Previsão (Forecasting):

- • Objetivo é estimar **valores futuros** com base nos dados passados
- • O futuro não pode ser observado diretamente, então usamos os dados históricos para **extrapolar**
  - • **Extrapolação**: processo de usar tendências observadas nos dados atuais para prever valores fora do intervalo conhecido (ou seja, no futuro)

Previsão de séries temporais – Modelagem Preditiva

- A previsão envolve ajustar os modelos aos dados históricos e usá-los para prever observações futuras
- Os modelos descritivos podem emprestar para o futuro (ou seja, para suavizar ou remover o ruído), eles apenas procuram melhor descrever os dados
- Uma distinção importante na previsão é que o futuro está completamente indisponível e só deve ser estimado a partir do que já aconteceu
- Portanto, temos objetivos diferentes, dependendo de estarmos interessados em entender um conjunto de dados ou fazer previsões

São séries temporais

Evasão de alunos no mês

Internações por dia

Mortes por problemas cardíacos no ano

Índice pluviométrico mensal

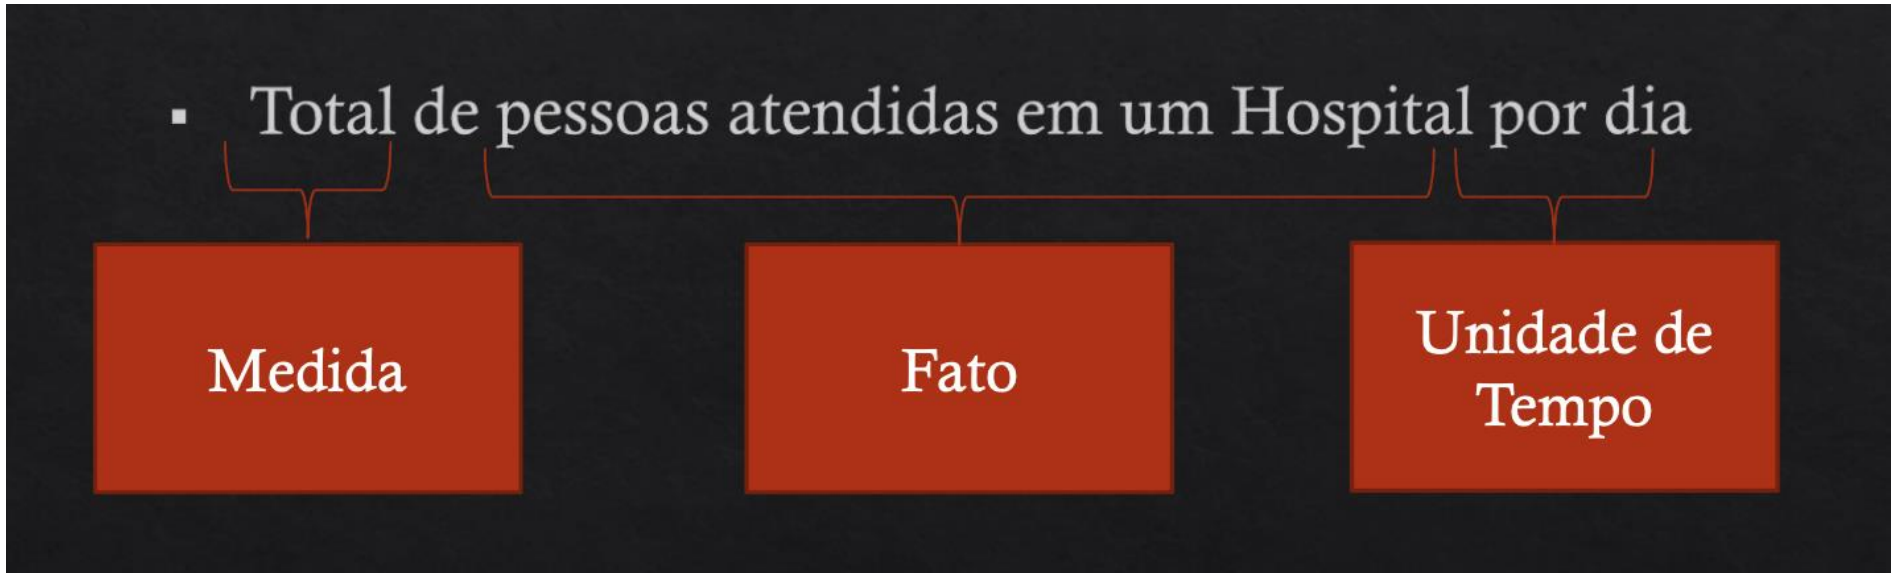
Cotação da bolsa por minuto

Manchas solares no mês

Toneladas de soja colhidas no semestre

Carros que passam pelo pedágio da CCR-Sorocabana no dia

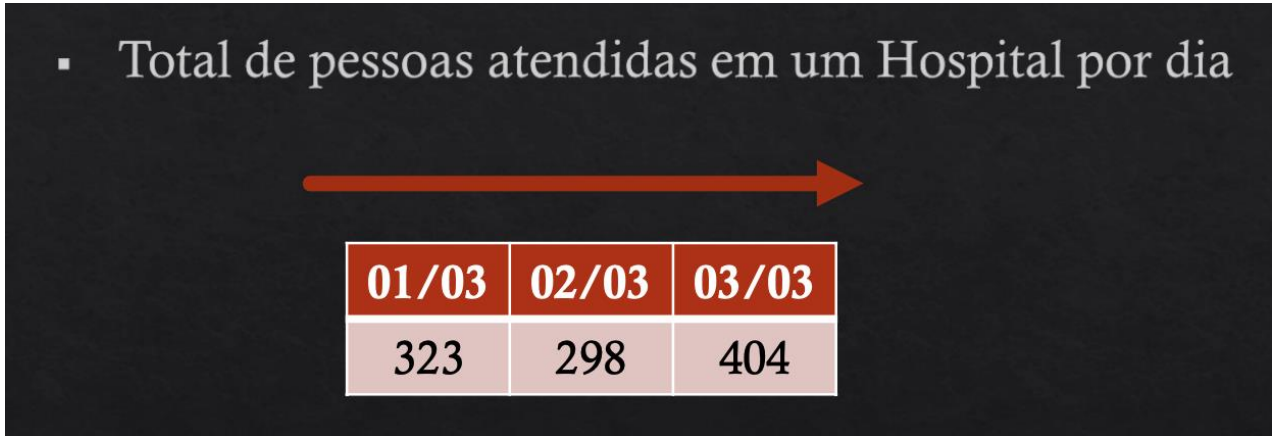
Anatomia de uma Série temporal (modelo de dados)



- **Fato (Evento de Negócio):** Ocorrência de atendimento hospitalar.
- **Medida (Métrica Quantitativa):** Quantidade / Volume de pessoas atendidas.
- **Unidade de Tempo (Granularidade da Série):** Periodicidade diária com intervalos regulares e sequenciais.

Uma série temporal em BI é simplesmente uma **métrica de fato** distribuída ao longo de uma **dimensão de tempo** regular

Dependência da ordem



- **Autocorrelação (Dependência Temporal):**
  - O valor de hoje depende diretamente do que aconteceu ontem e nos dias anteriores
  - A sequência $t-1 \rightarrow t \rightarrow t+1$carrega a dinâmica do fenômeno
- **Diferença para Dados Tabulares Comuns:**
  - Em tabelas tradicionais (ex.: clientes ou produtos), a ordem das linhas não altera o resultado
  - Em séries temporais, se você embaralhar as datas, a série perde todo o sentido estatístico
- **Impacto e erros comuns com o Power BI:**
  - **Cuidado com a ordenação dos gráficos:** nunca ordene o eixo X por "valor decrescente" em visuais temporais;
  - o eixo X **deve sempre respeitar a cronologia**.
  - **Cálculos de variação:** métricas como Média Móvel, *MoM* (Mês a Mês) e algoritmos preditivos (como ETS) exigem que a linha do tempo seja contínua e sequencial.

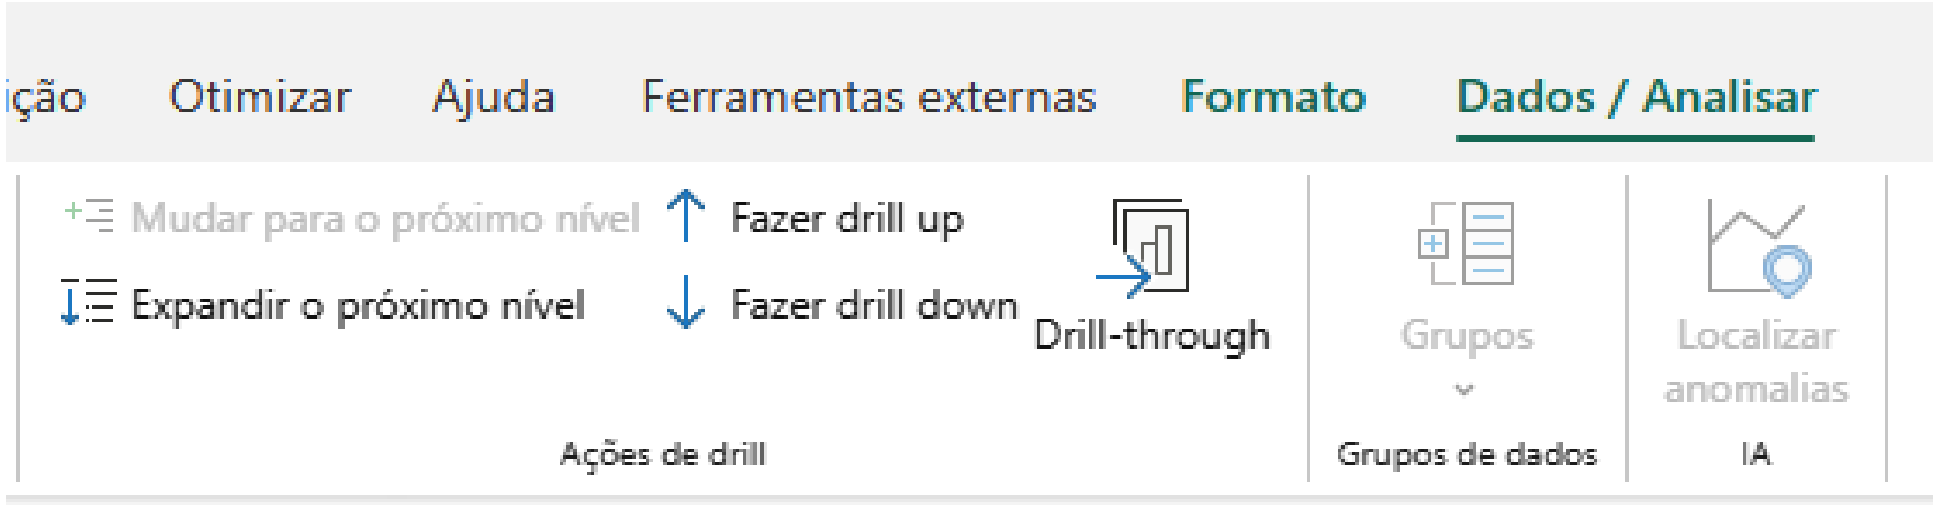
Produção-2018-2023.xslx

Séries temporais no Power BI

- Identificar a série temporal
  - Qual o fator tempo?
  - Qual o fenômeno?
  - Formato da data
  - Qual o Período de tempo?
- Analisar a produção ao longo do tempo

Séries temporais no Power BI

- Power Query detectou corretamente a data?
  - Senão, use Localidade
- Gráfico de barras ou de linhas?
- Hierarquia de datas
  - Nível mais alto: ano, mais baixo: dia
  - Mudança de nível (de agregação) – olhar de maneira isolada (só ano, só mês)
  - Expansão de nível (considera toda a hierarquia)

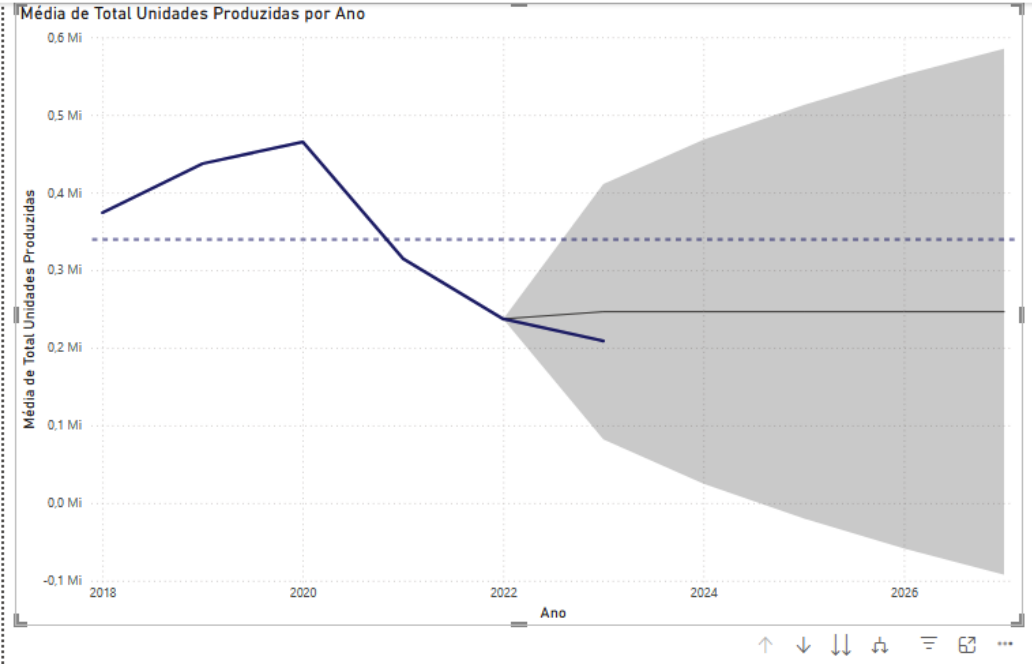


Séries temporais no Power BI

- Predição em série temporal
- **modelo ETS (Exponential Triple Smoothing ou Suavização Exponencial Tripla)** para gerar previsões

  ETS é uma técnica de modelagem de séries temporais que combina três componentes principais:

  1. **Erro (E):** aleatoriedade dos dados.
  2. **Tendência (T):** direção geral ao longo do tempo (ex: crescimento ou queda).
  3. **Sazonalidade (S):** padrões que se repetem (mensal, semanal, etc).



Cuidado com a Granularidade(Histórico insuficiente):

De 2018 a 2023, o modelo enxerga apenas 6 observações no eixo X

Algoritmos de séries temporais precisam de volume histórico para aprender ciclos e padrões

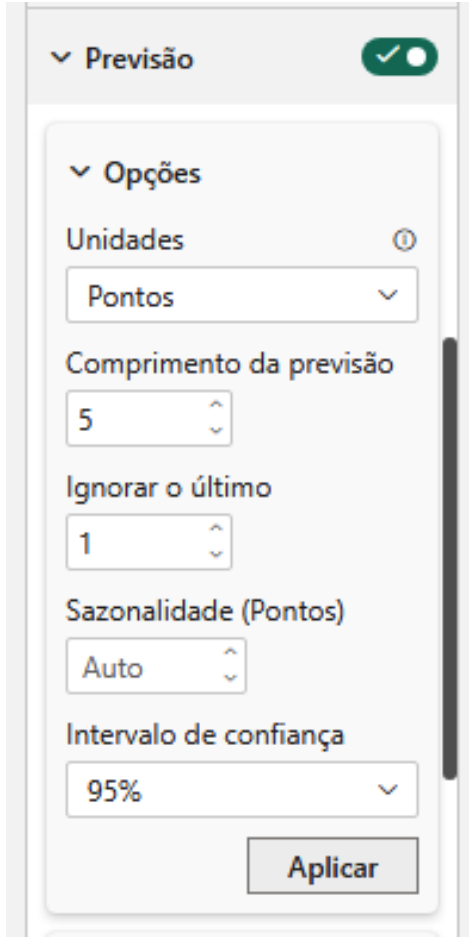
Impacto na Previsão:

Explosão da incerteza: o intervalo de confiança se abre drasticamente, chegando a projetar valores negativos

Linha reta (inércia): com dados anuais, perde-se a sazonalidade e o modelo tende a projetar quase uma constante

Boa prática:

Reduzir a agregação para **Mês** ou **Trimestre** permitindo capturar sazonalidades reais ao longo do ano



Parâmetros

- Interpolação de série de correspondência:
  - Power BI vai **preencher (interpolar)** os valores ausentes para cada produto individualmente, permitindo uma previsão mais contínua e precisa para **cada linha concorrente**.
  - Tipo de interpolação:
  - • • linear

  - Suave - Usa **curvas suaves** (interpolação por spline) entre os pontos para criar uma linha arredondada.
  - Etapa: Conecta os pontos em forma de **escada**, ou seja, mantém o valor até o próximo ponto, depois sobe ou desce de repente.

  - Tensão:

Se a linha **parecer exageradamente ondulada**, aumente a tensão.

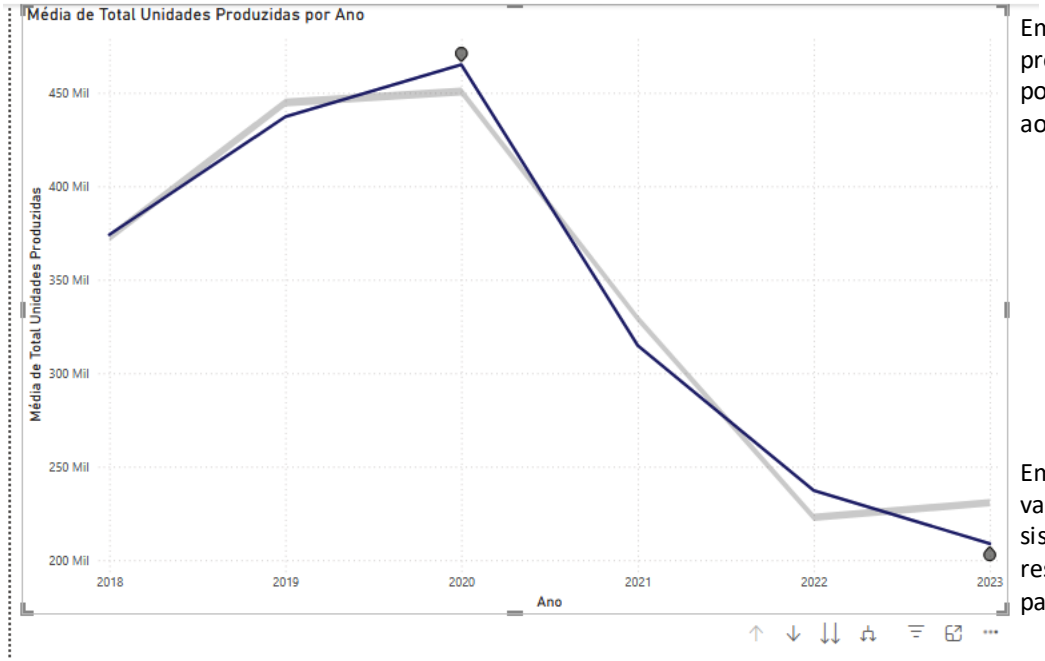
• Se a linha **ficar muito dura e "quebrada"**, diminua a tensão.

• • Testar entre **30% e 70%** costuma gerar bons resultados visuais.

Séries temporais no Power BI

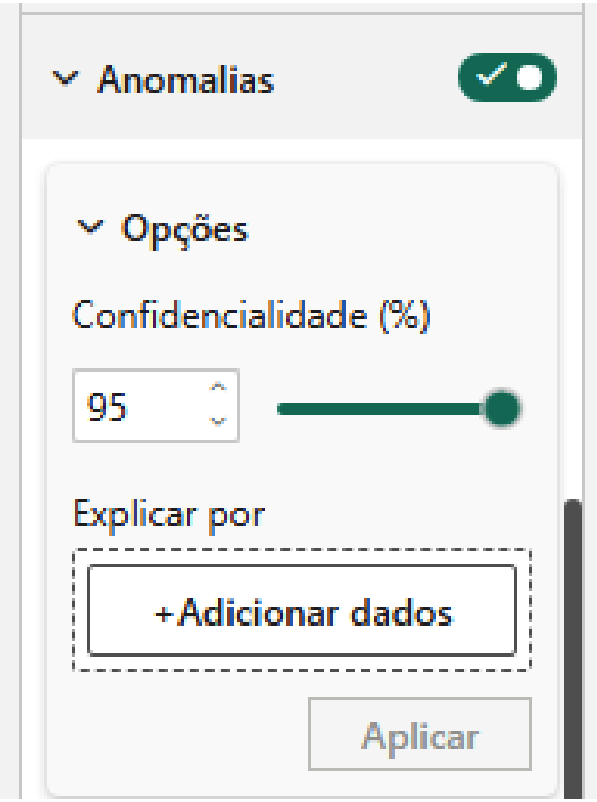
Produção -2018-2023.xslx

- Detecção de anomalias



Em 2020, o valor real deu um salto acima dessa projeção. O algoritmo de detecção marcou este ponto porque o crescimento foi desproporcional ao histórico de 2018-2019.

Embora a tendência já fosse de queda desde 2021, o valor de 2023 está abaixo da linha cinza de suporte. O sistema sinaliza que, mesmo esperando-se uma queda, o resultado final foi pior do que o modelo estatístico previa para aquele ano.



Dimensão tempo: tabela Calendário

- Criar uma tabela de dimensão de calendário dedicada (dCalendario) é um dos pilares fundamentais da modelação dimensional
- Garantir o funcionamento correto do Time Intelligence no DAX
- Permite filtrar múltiplas tabela Fato
- Otimização de memória de desempenho do modelo
  - Cada coluna data cria uma tabela de hierarquia (interno)
- Flexibilidade de atributos e classificação temporal
  - Concentra todos os níveis de análise temporal num único local

```
dCalendario =
VAR DataInicio = DATE(2018, 1, 1)
VAR DataFim = DATE(2026, 12, 31)

RETURN
    ADDCOLUMNS(
        CALENDAR(DataInicio, DataFim),
        "Ano", YEAR([Date]),
        "MesNum", MONTH([Date]),
        "MesNome", FORMAT([Date], "mmmm"),
        "MesAbrev", FORMAT([Date], "mmm"),
        "AnoMesNum", YEAR([Date]) * 100 + MONTH([Date]),
        "AnoMes", FORMAT([Date], "yyyy/mm"),
        "Trimestre", "T" & FORMAT([Date], "q"),
        "AnoTrimestre", FORMAT([Date], "yyyy") & " - T" & FORMAT([Date], "q"),
        "Dia", DAY([Date]),
        "DiaSemanaNum", WEEKDAY([Date], 2),
        "DiaSemanaNome", FORMAT([Date], "dddd")
    )
```

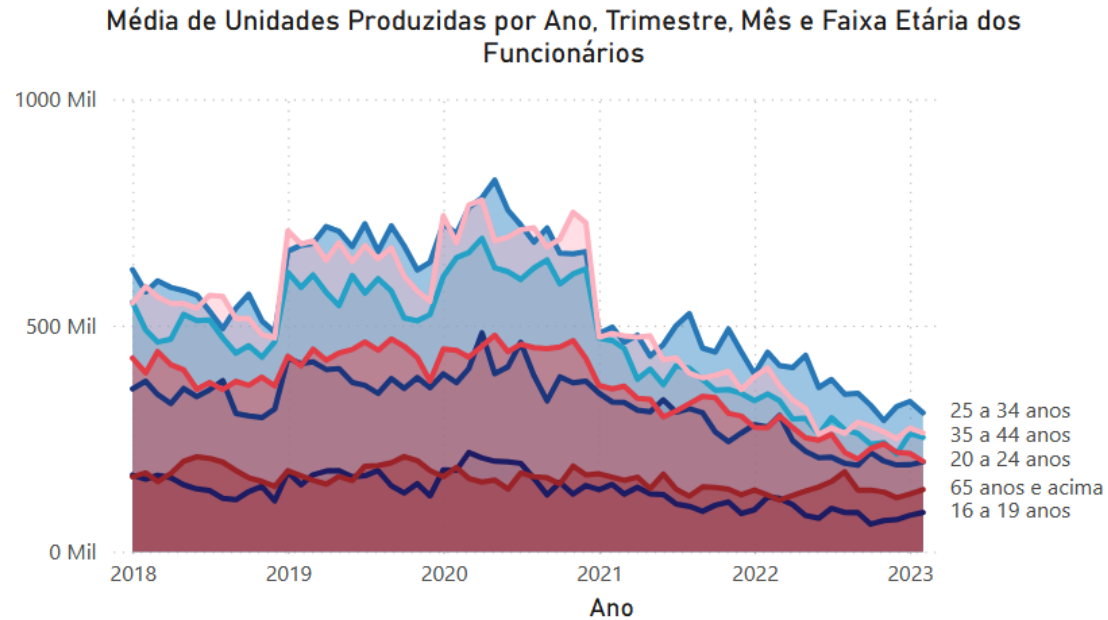
Fatec Parafusos - Produção

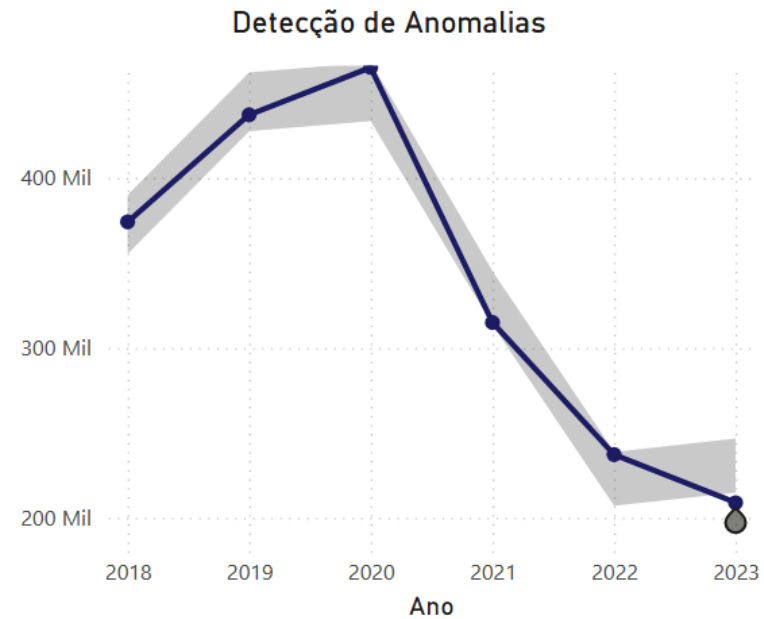
Turno

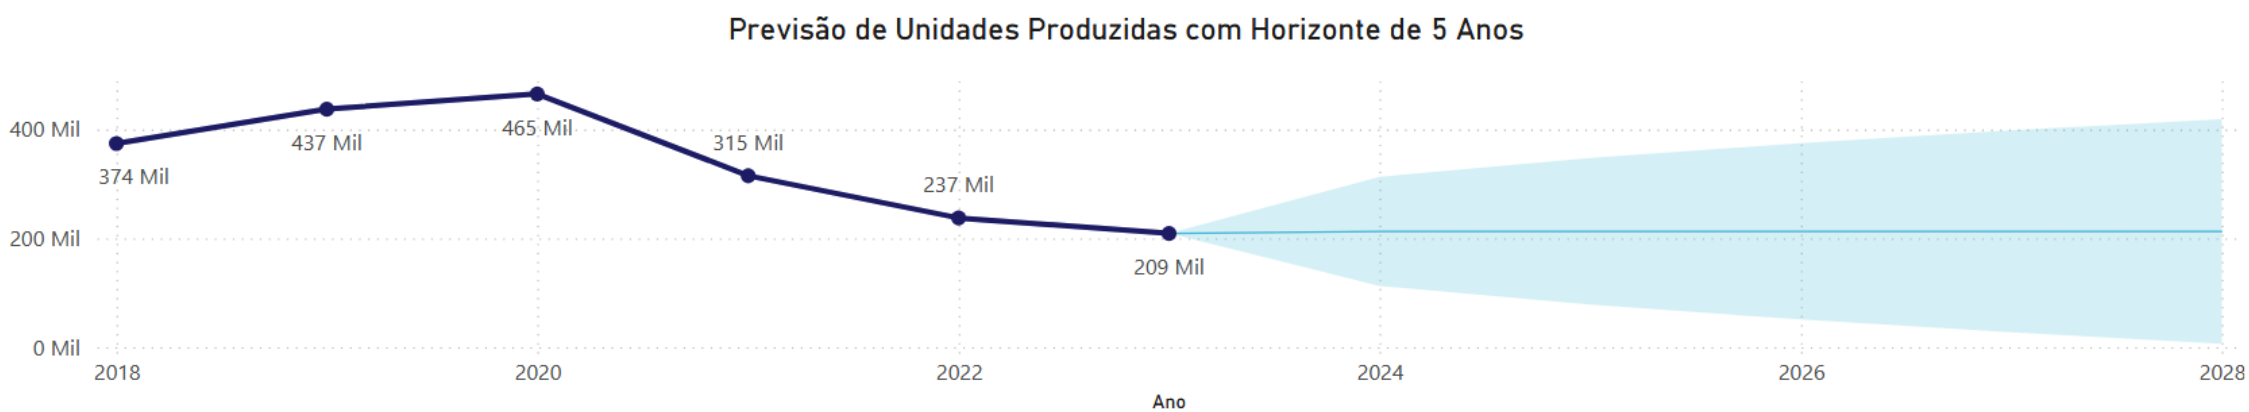
- [ ] Manhã
- [ ] Tarde

Falxa Etária

- [ ] 16 a 19 anos
- [ ] 20 a 24 anos
- [ ] 25 a 34 anos
- [ ] 35 a 44 anos
- [ ] 45 a 54 anos
- [ ] 55 a 64 anos
- [ ] 65 anos e acima

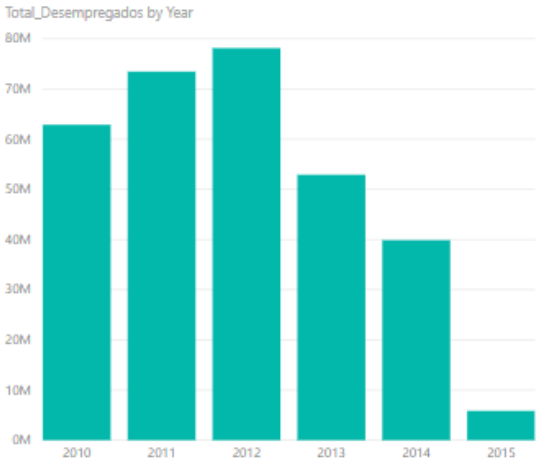


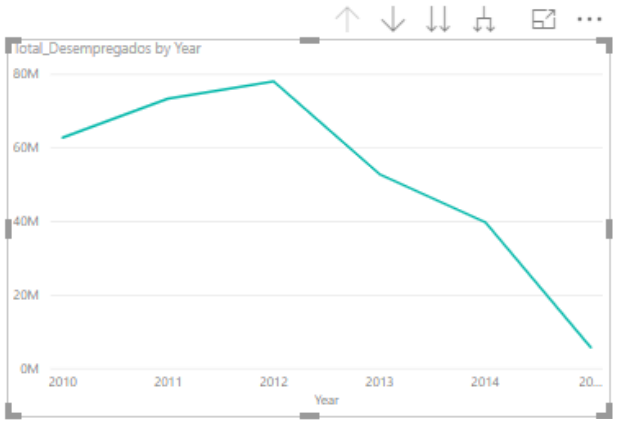


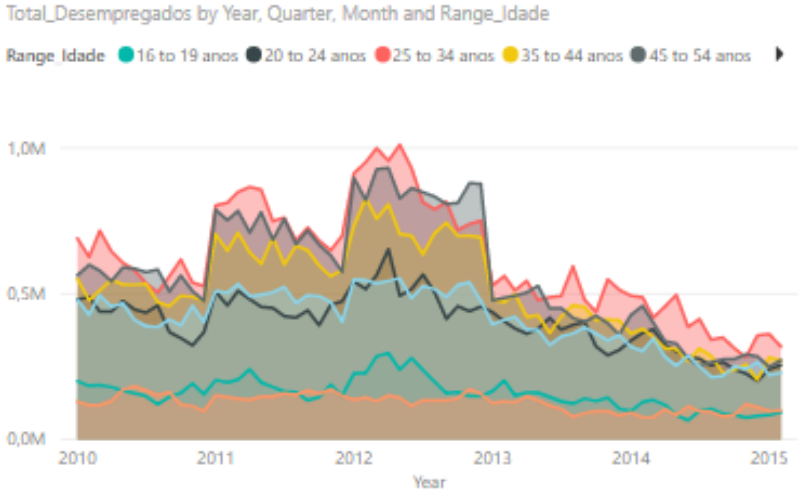


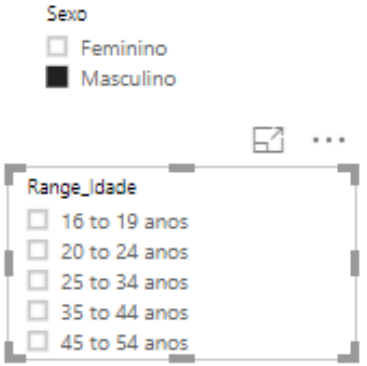
Atividade: Dados (fictícios) de desemprego

Use: desemprego Narnia 2005-2015.xlsx









Atividades:

- Crie uma tabela calendário;
- Marque esta tabela como tabela de data (menu calendários em ferramentas da tabela)
- Relacione com a tabela fato;
- Crie os gráficos de barra e de linha;
- Use segmentadores pela faixa etária e por sexo
- Identifique as possíveis anomalias

Base de dados

- Air Passengers:
- https://raw.githubusercontent.com/facebook/prophet/main/examples/example_air_passengers.csv

- Shampoo sales:
- https://raw.githubusercontent.com/jbrownlee/Datasets/master/shampoo.csv