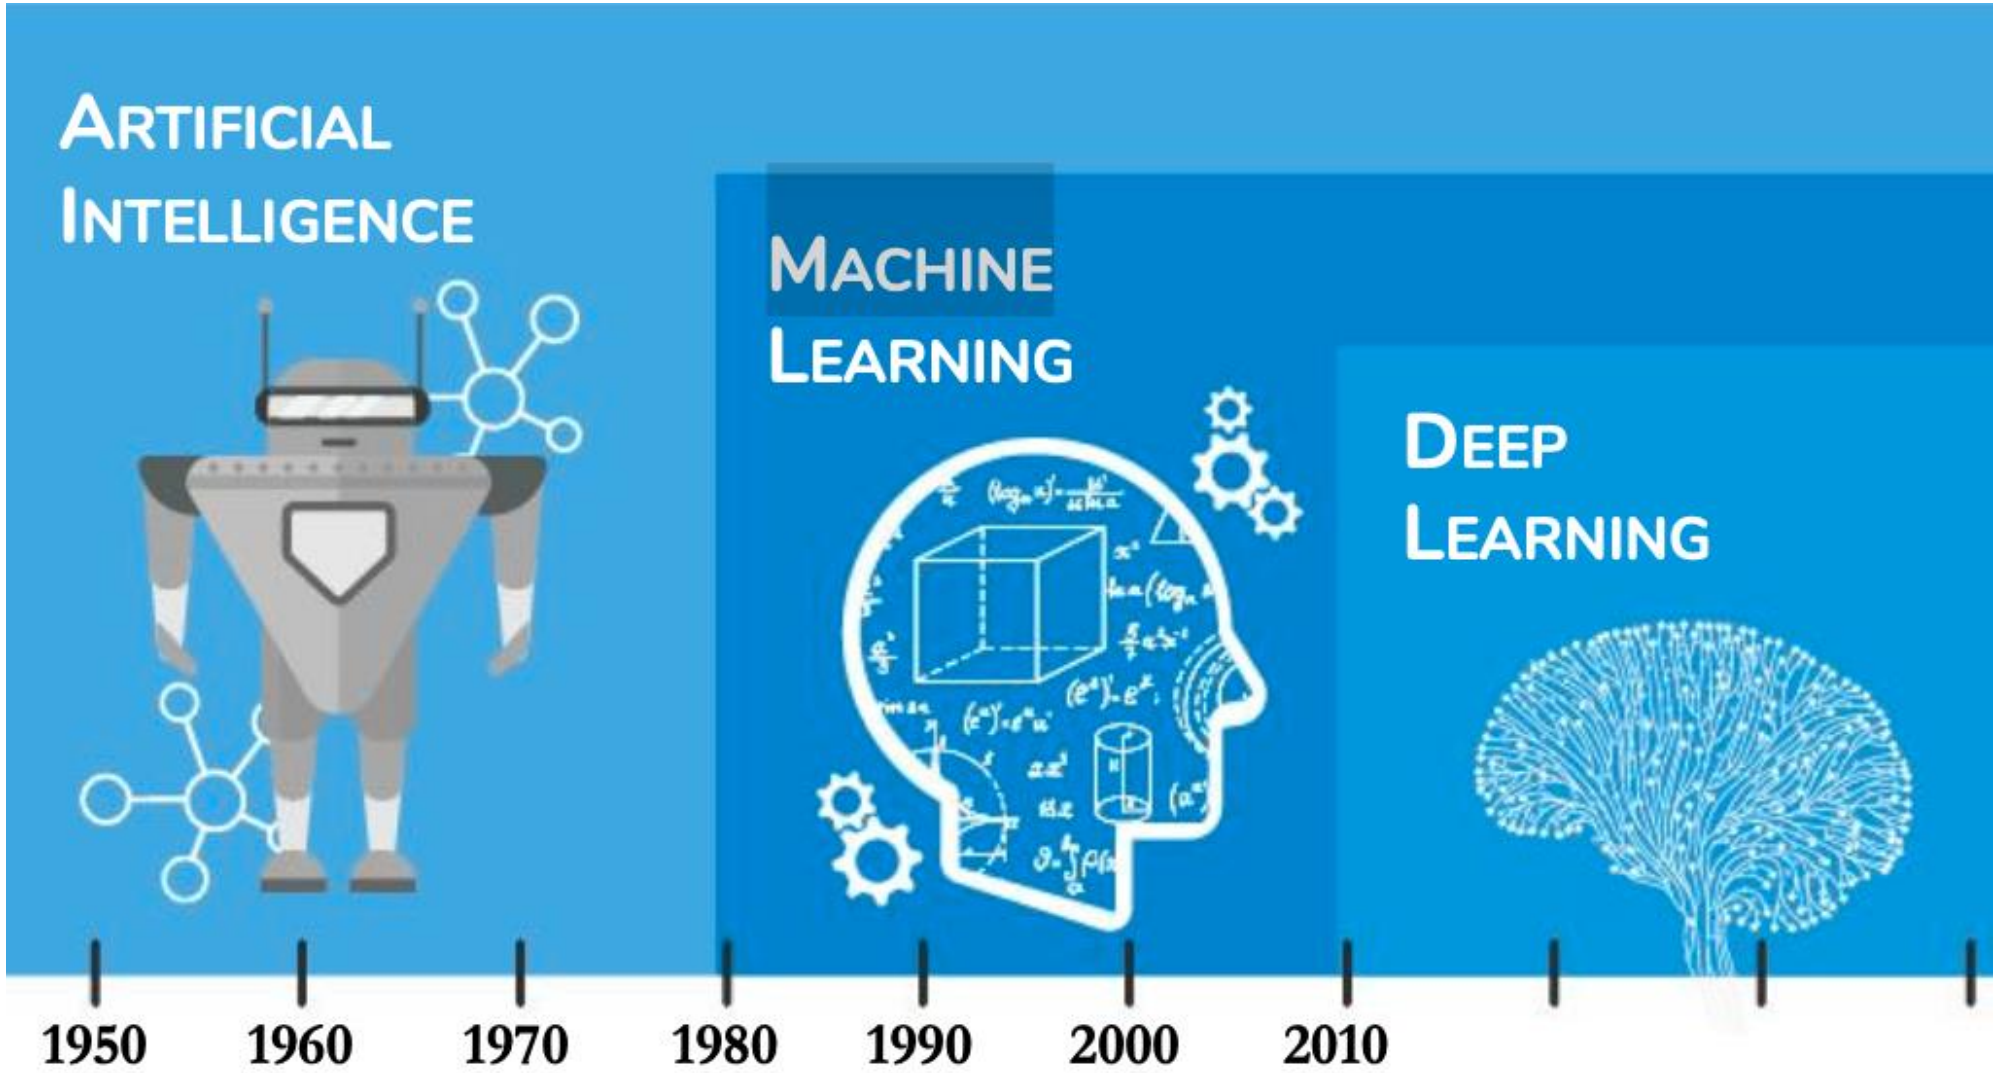
Regressão linear com Power BI

Fatec 2026

Contexto


ARTIFICIAL INTELLIGENCE
MACHINE LEARNING
DEEP LEARNING
1950
1960
1970
1980
1990
2000
2010

Aprendizado de máquina

"Aprendizado de Máquina é a ciência (e a arte) de se programar computadores para que eles aprendam a partir dos dados."

[Aurélien Géron, 2017]

"Área de estudo que dá aos computadores a habilidade de aprender sem que sejam explicitamente programados"

[Arthur Samuel, 1959]

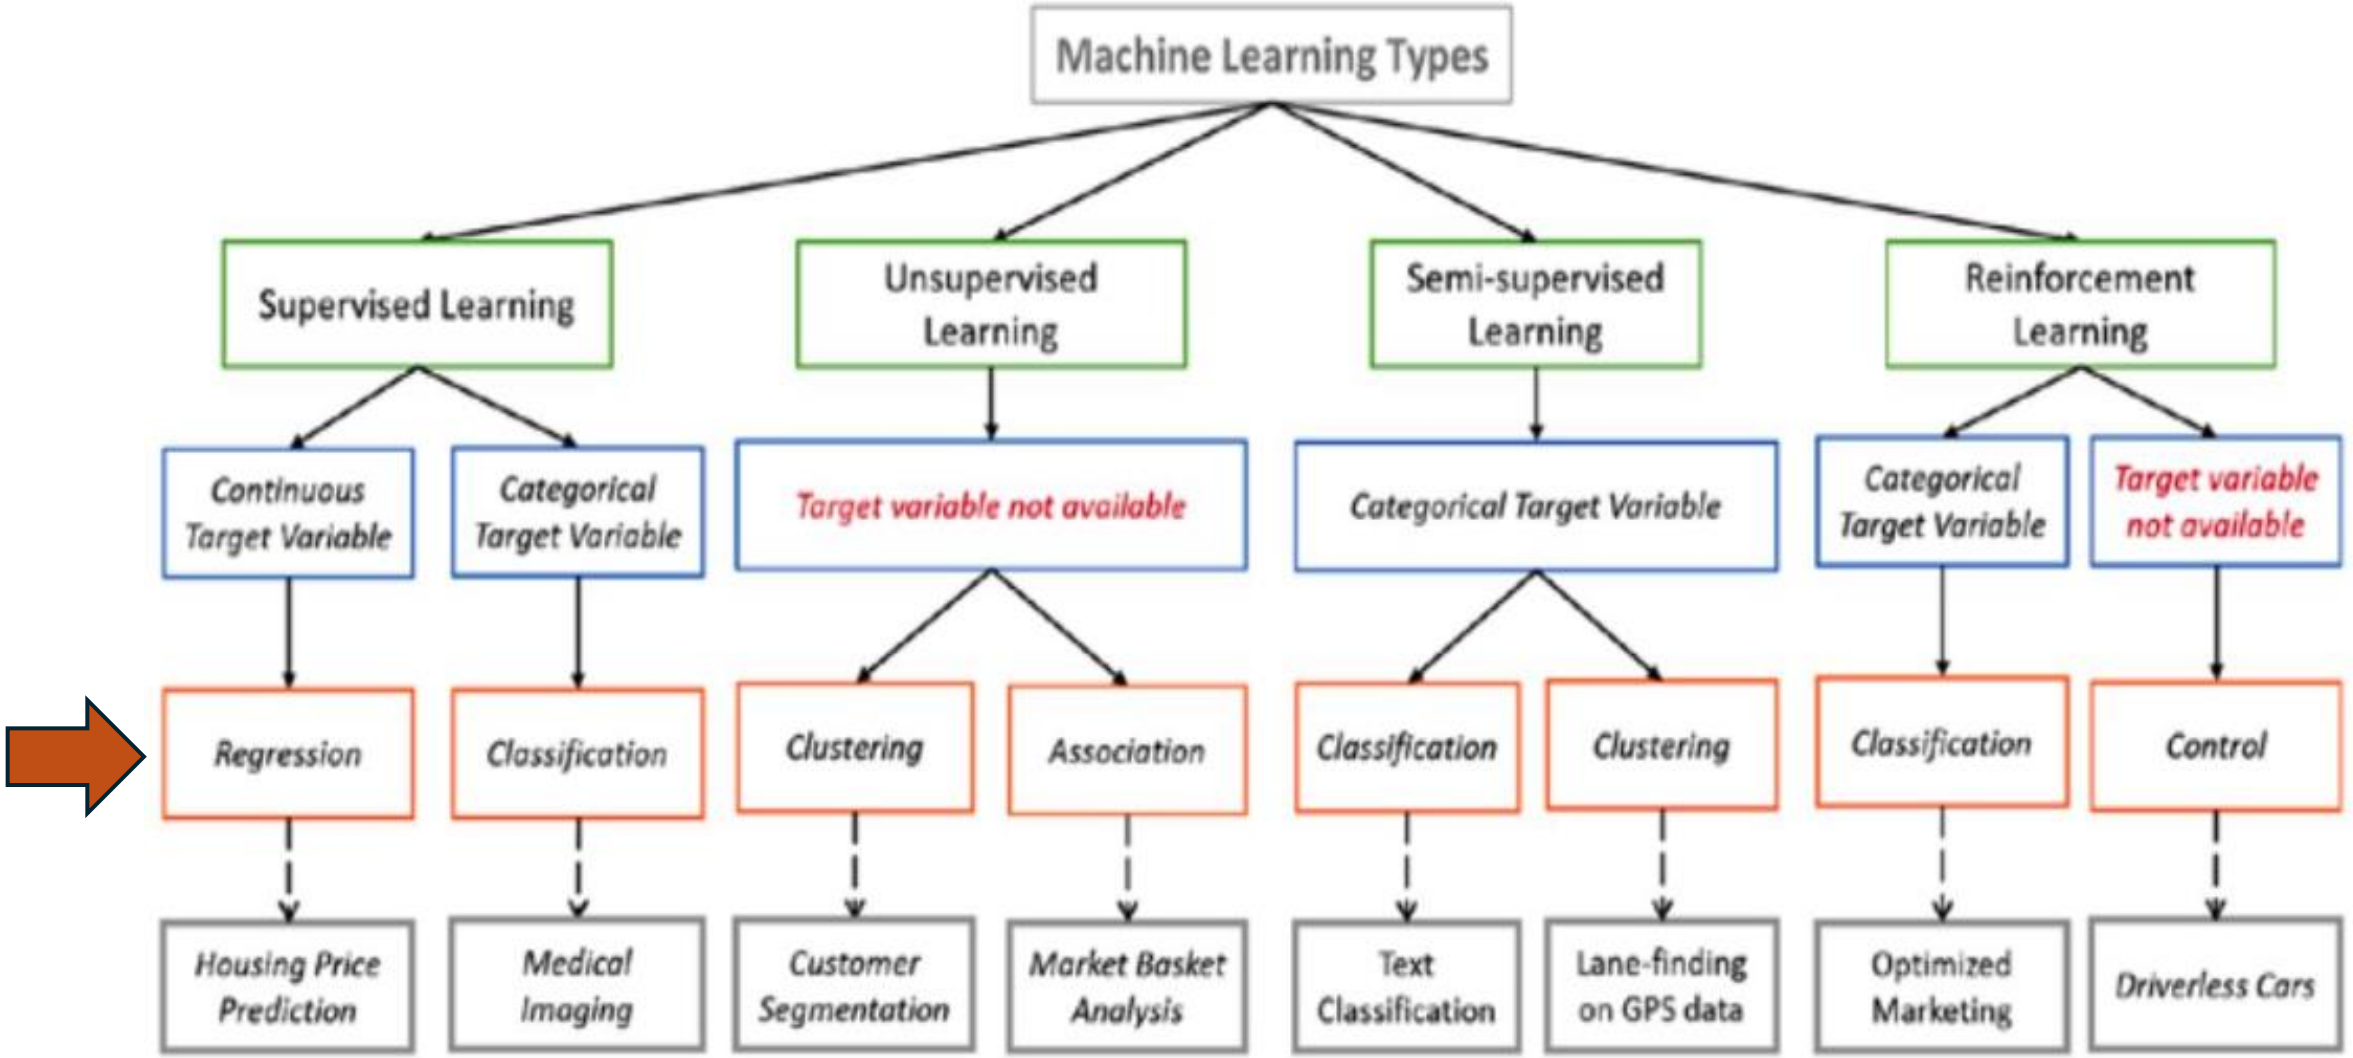
"Um programa de computador aprende a partir de uma experiência E com respeito a uma tarefa T e uma métrica de performance P, se a sua performance em T, medida por P, melhora com a experiência E."

[Tom Mitchell, 1997]

Tipos de aprendizado de máquina

Tipo de Aprendizado	Como funciona	Tem resposta certa nos dados?	Exemplo prático
Supervisionado	Aprende com dados que já têm rótulos (respostas certas)	✅ Sim	Classificar e-mails como spam ou não
Não supervisionado	Encontra padrões em dados sem rótulos	❌ Não	Agrupar clientes por comportamento
Semi-supervisionado	Usa poucos dados rotulados e muitos sem rótulo para aprender melhor	🌓 Parcial	Identificar doenças com base em poucos exames rotulados
Por Reforço	Aprende com recompensas ou penalidades após cada açâc (tentativá e erro)	🔄 Parcial (por feedback)	Treinar um agente para jogar videogame ou contrólar robós

Tipos de aprendizado de máquina





- Classificação é usada para predizer valores discretos
- Regressão é usada para predizer valores contínuos

Predição de preço de imóveis (Regressão)



$ 70 000

Predição de preço de imóveis (Regressão)



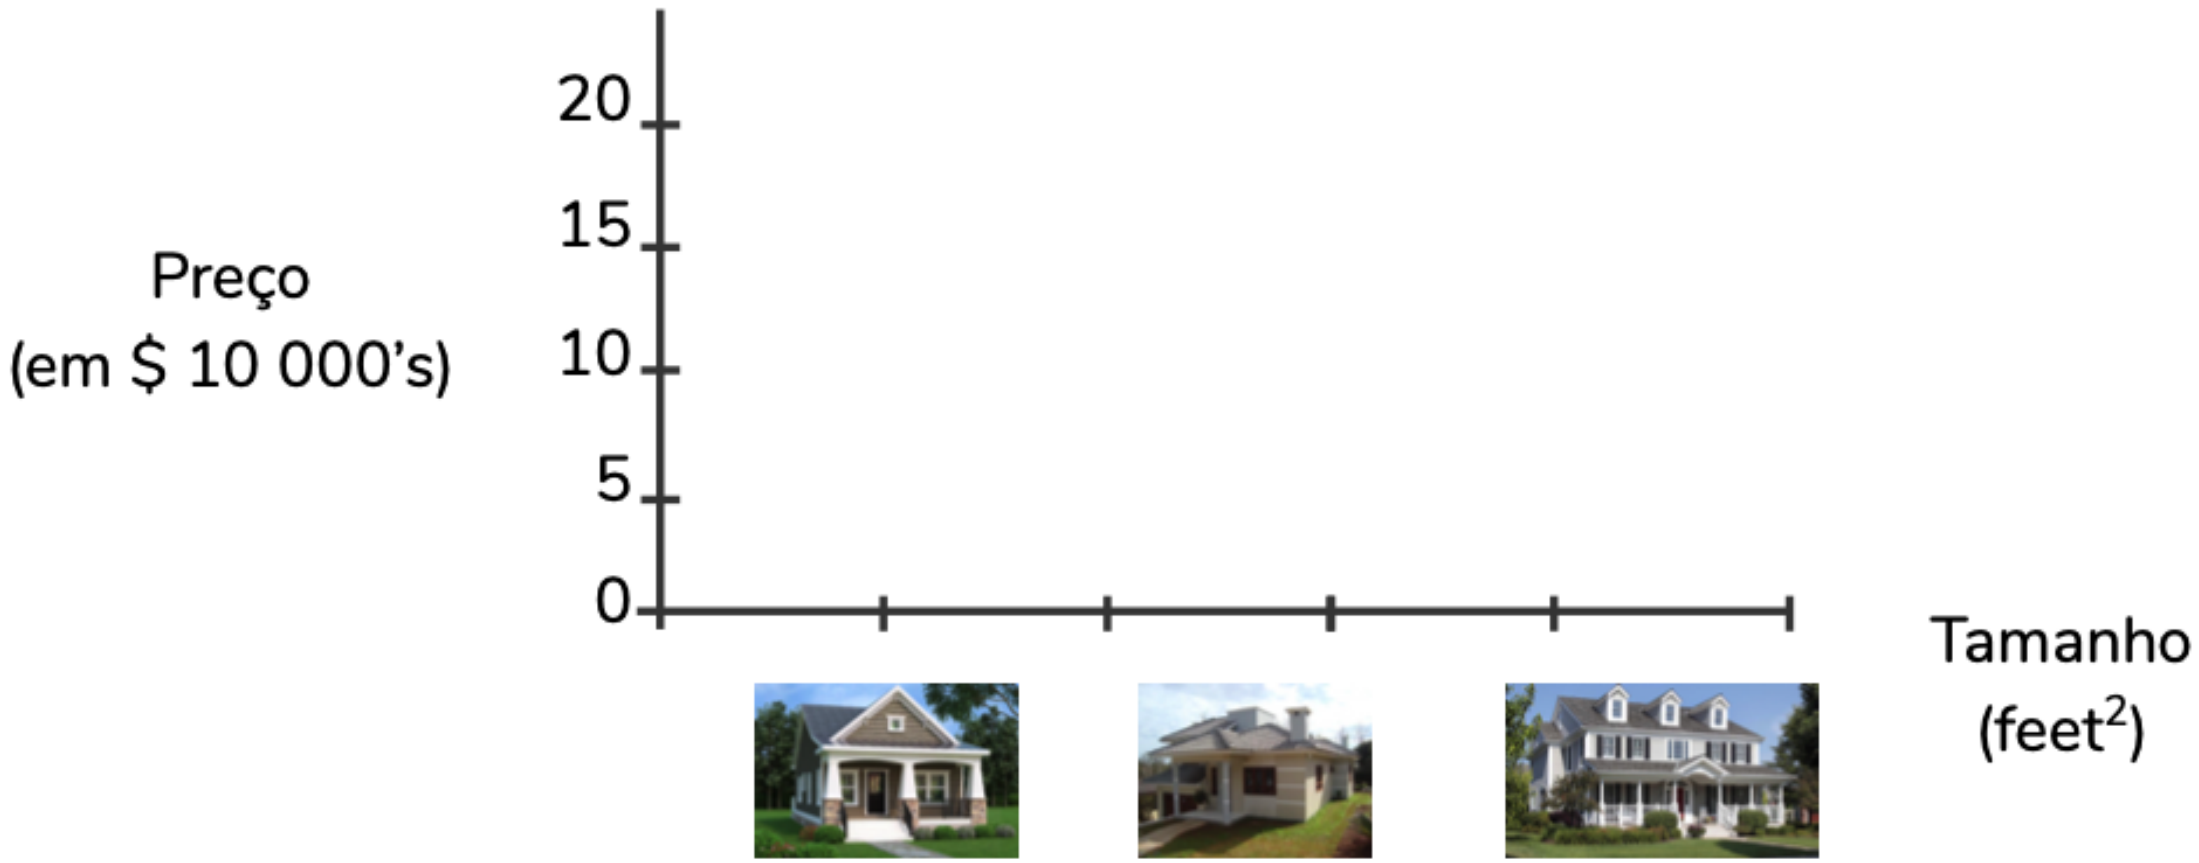
$ 160 000

Predição de preço de imóveis (Regressão)

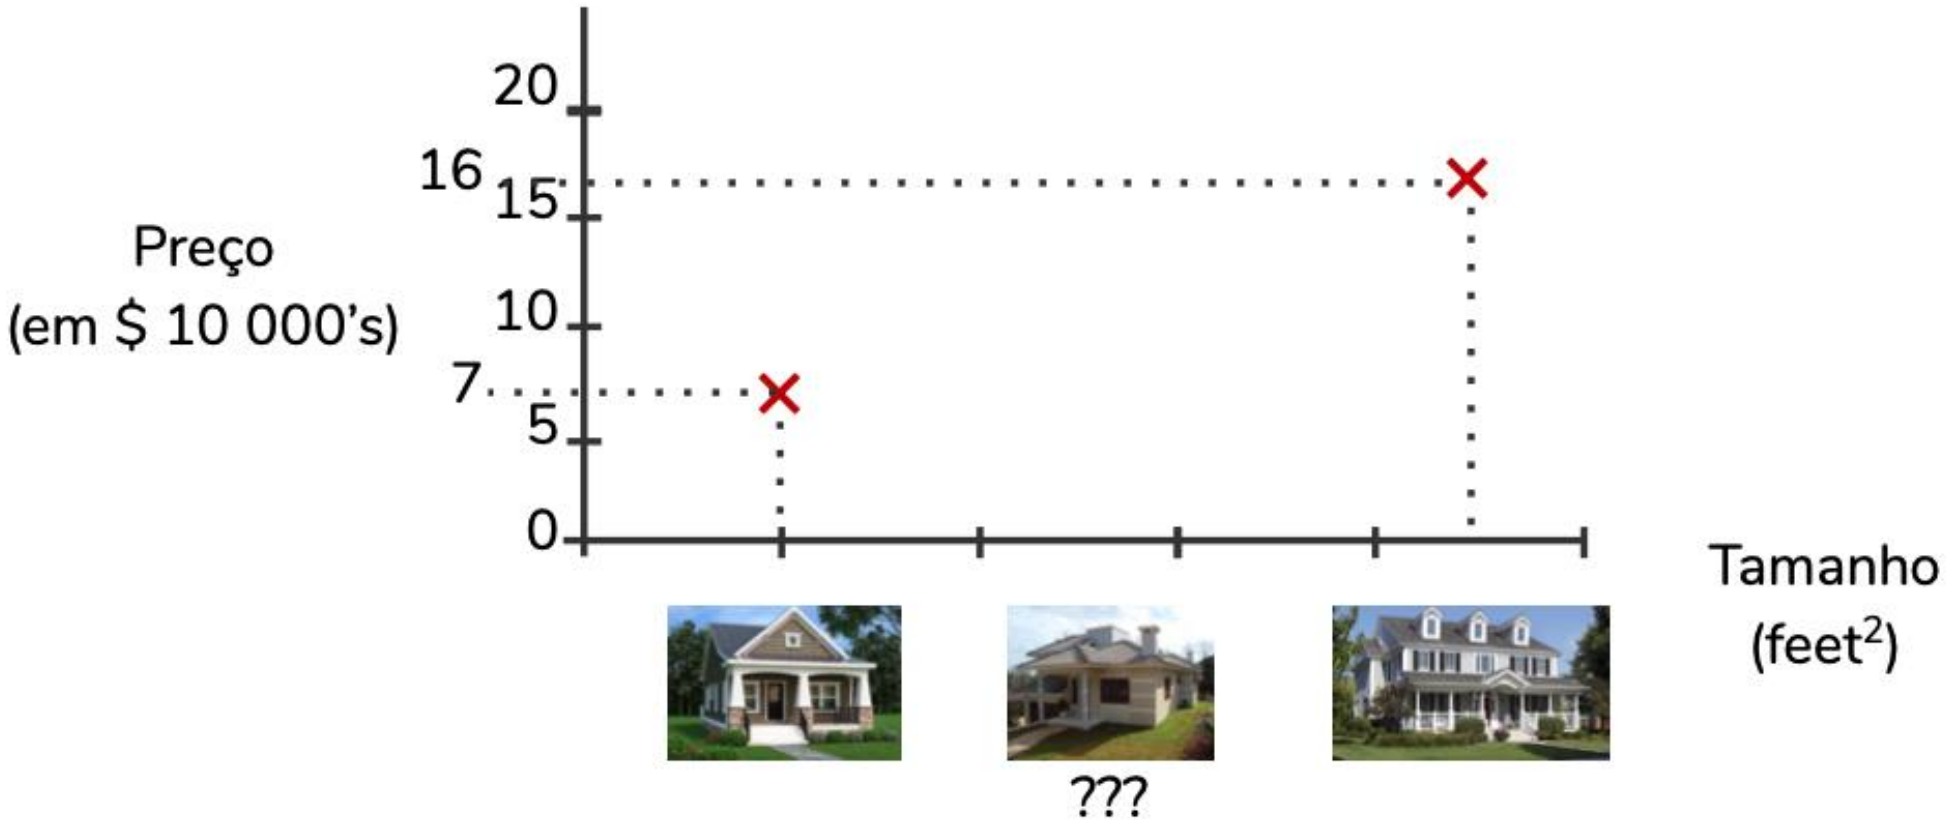


???

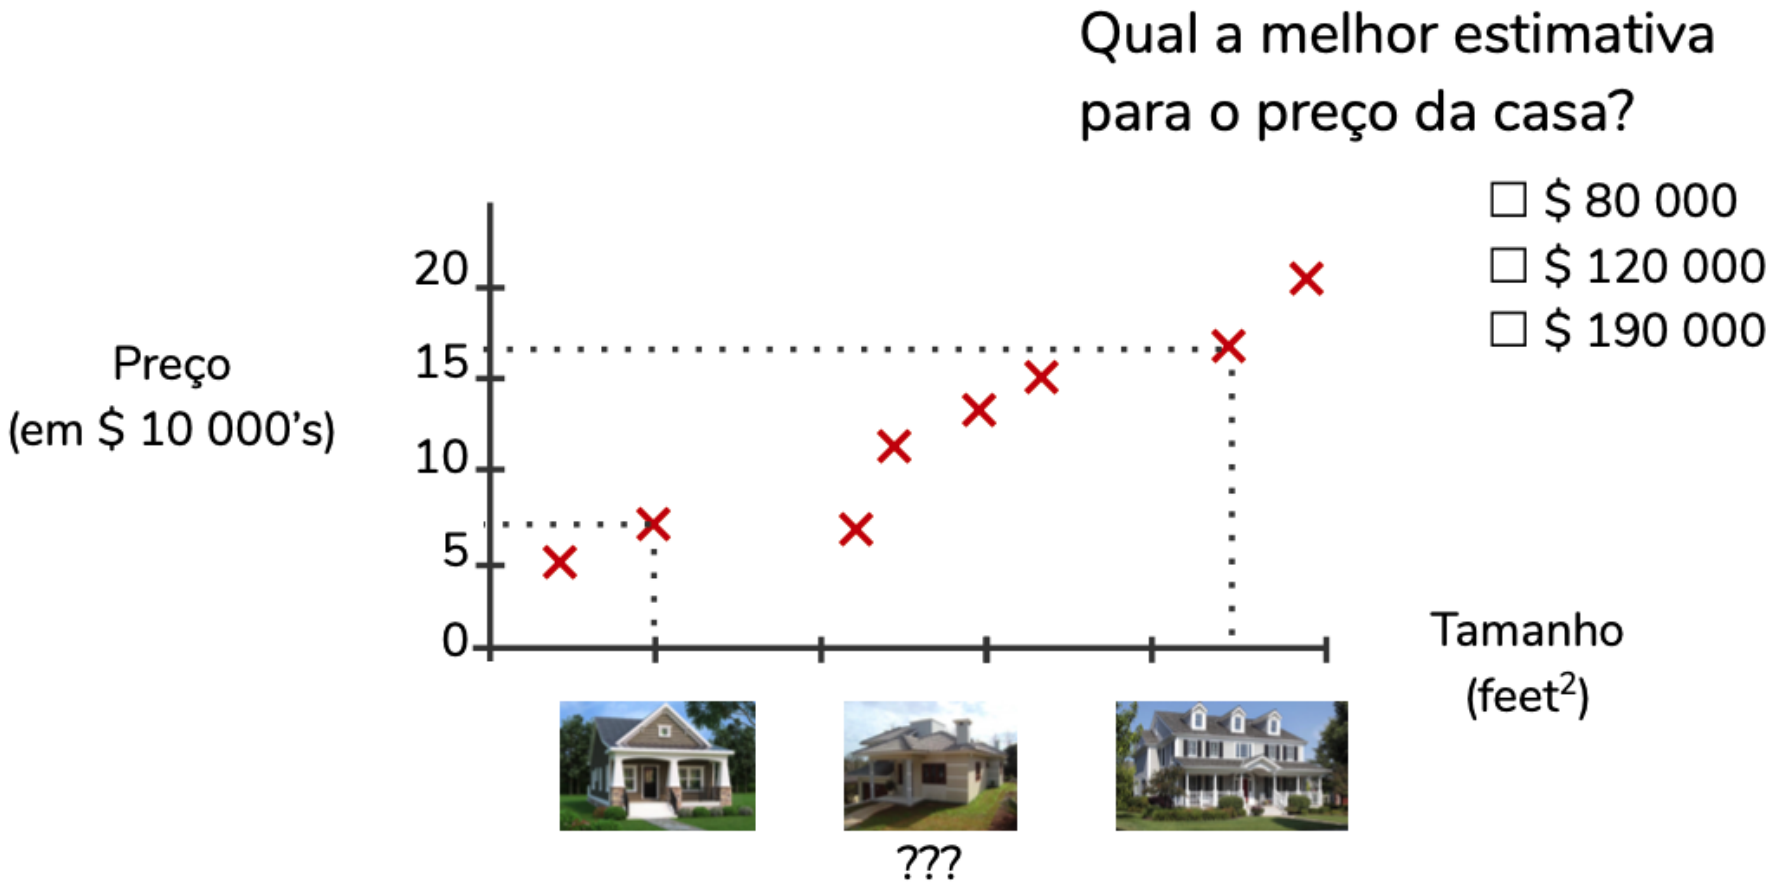
Predição de preço de imóveis (Regressão)



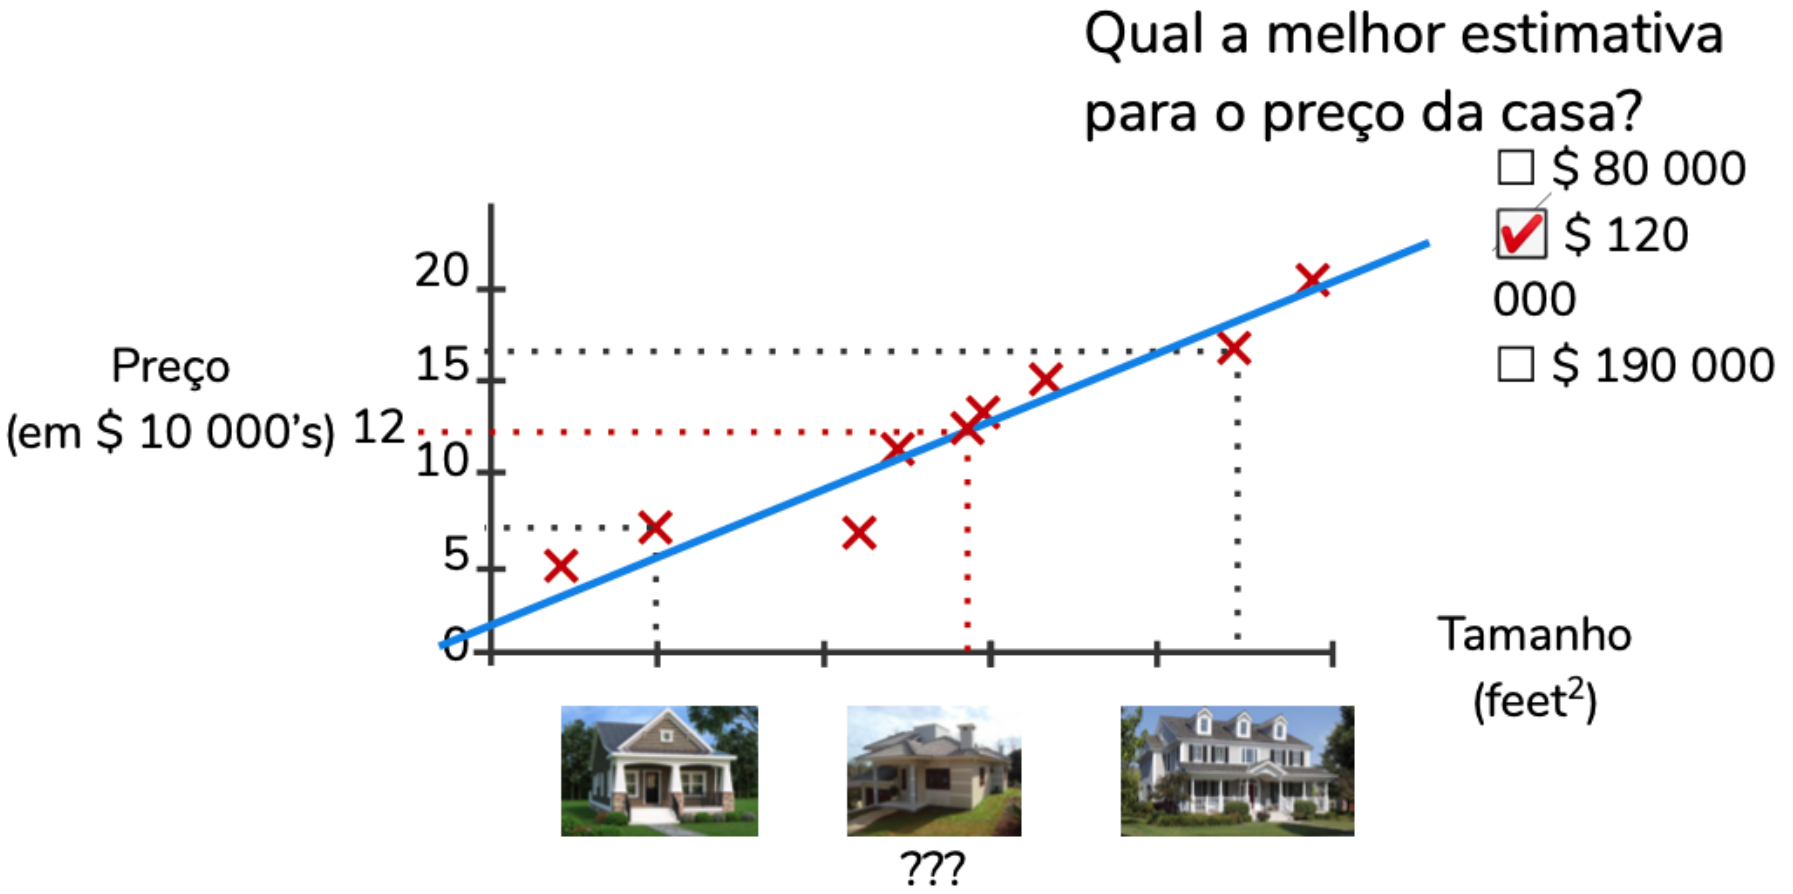
Predição de preço de imóveis (Regressão)



Predição de preço de imóveis (Regressão)



Predição de preço de imóveis (Regressão)

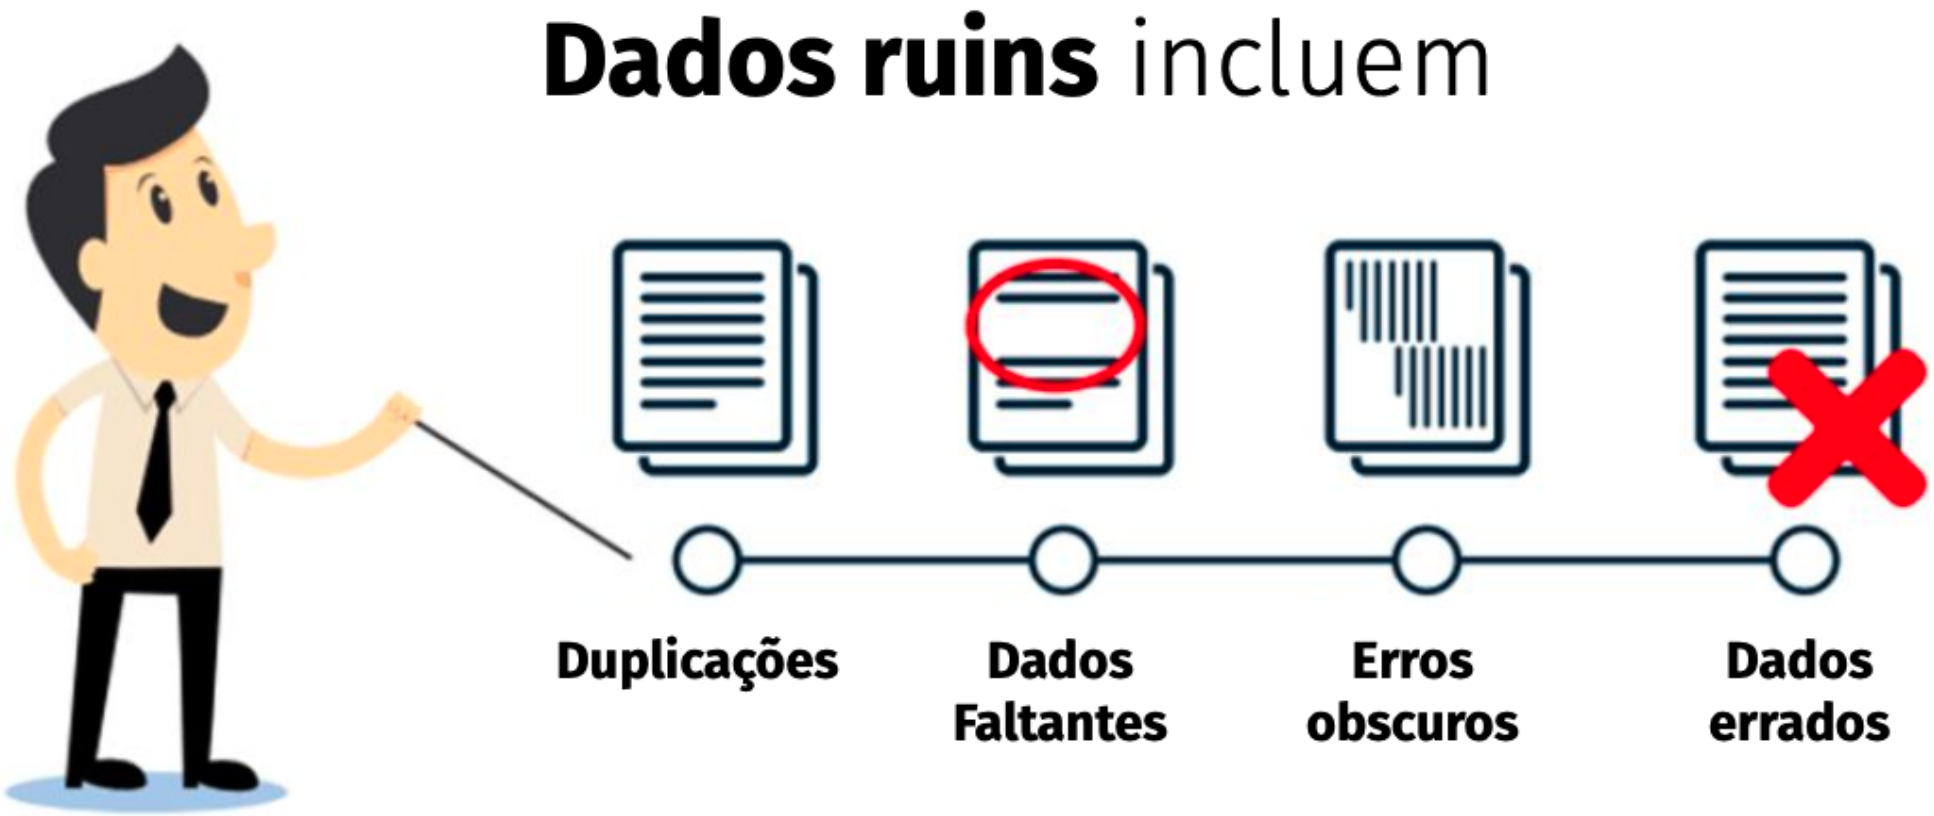


Principais desafios

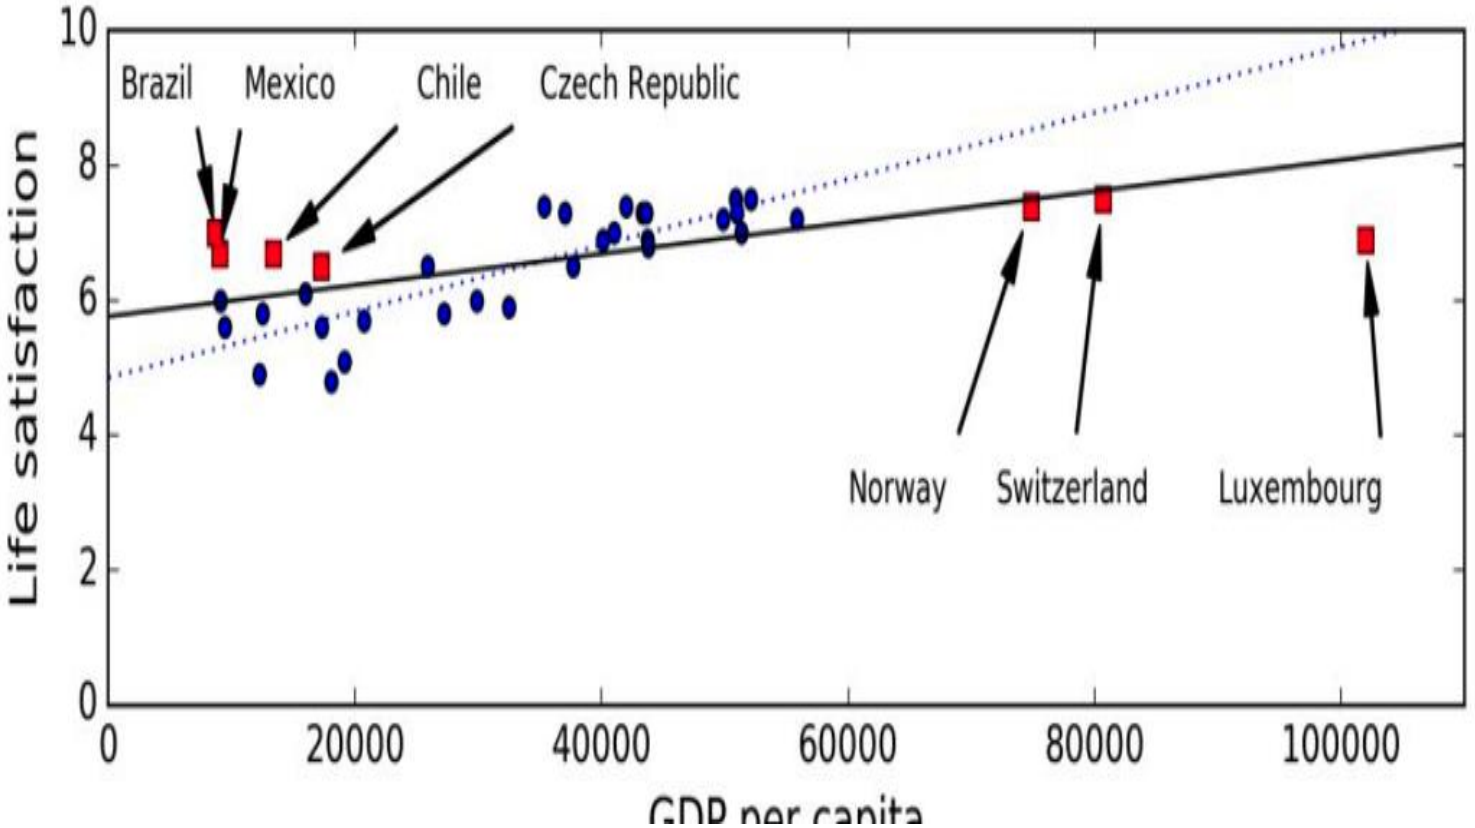
- “bad Data”
  - Quantidade insuficiente de dados de treinamento
  - Dados de treinamento não representativos
  - Dados de baixa qualidade
  - Features irrelevantes

- Bad algorithm
  - Modelo muito especializado (overfitting)
  - Modelo muito genérico (underfitting)
  - Modelo preconceituosos e injustos(unfair)

Dados ruins


Dados ruins incluem
Duplicações
Dados Faltantes
Erros obscuros
Dados errados

Dados não representativos



•**O modelo falha:** A linha pontilhada *não descreve bem* os países em vermelho.

- Países como Brasil, México e Chile têm uma satisfação *muito maior* do que o modelo (linha pontilhada) previa para seu nível de PIB.
- Países como Noruega, Suíça e Luxemburgo têm uma satisfação *menor* do que o modelo previa para seu altíssimo PIB.

A **linha preta sólida** mostra uma tendência mais "correta" se incluísse *todos* os dados (azuis e vermelhos) desde o início

Para generalizar bem, é essencial que os dados de treinamento representem os novos casos para os quais você deseja generalizar.

Dados com baixa qualidade

Obviamente que, se os seus dados de treinamento estão cheios de erros, outliers e ruído, o sistema terá dificuldade em detectar os padrões presentes e, provavelmente, não irá ter um bom desempenho



Features(características) irrelevantes

- Uma parte crítica para o sucesso de um projeto é obter um bom conjunto de características (*features*) para se realizar o treinamento
- Isso é chamado de engenharia de características e envolve:
  - Seleção de características: o processo de selecionar as features mais úteis entre as existentes para realizar o Treinamento
  - Extração de características: combinar features existentes para gerar features mais úteis/discriminativas



Principais desafios

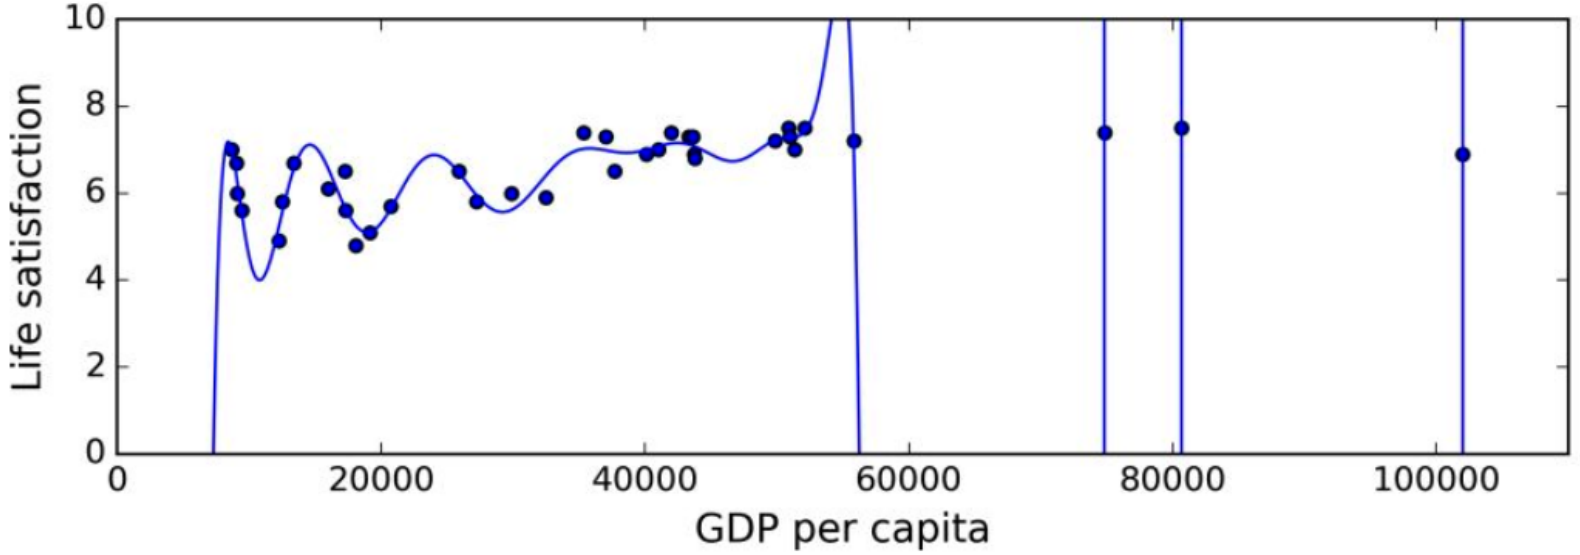
- “bad Data”
  - Quantidade insuficiente de dados de treinamento
  - Dados de treinamento não representativos
  - Dados de baixa qualidade
  - Features irrelevantes

- Bad algorithm
  - Modelo muito especializado (overfitting)
  - Modelo muito genérico (underfitting)
  - Modelo preconceituosos e injustos(unfair)



Overfitting

- Generalizar ao extremo é algo que nós humanos fazemos com bastante frequência, e infelizmente as máquinas podem cair na mesma armadilha se não formos cuidadosos
- Overfitting significa que o modelo tem um bom desempenho nos dados de treinamento, mas não generaliza.



Overfitting

Overfitting acontece quando o modelo é muito complexo em relação à quantidade e ao ruído dos dados de treinamento

As possíveis opções para lidar com overfit são:

- simplificar o modelo selecionando um com menos parâmetros, reduzindo o número de atributos nos dados de treinamento ou limitando o modelo,
- obter mais dados de treinamento,
- reduzir o ruído nos dados de treinamento

Underfitting

Uncontrário de overfitting

ocorre quando o modelo é muito simples para aprender a estrutura intrínseca dos dados

As principais opções para lidar com underfit são:

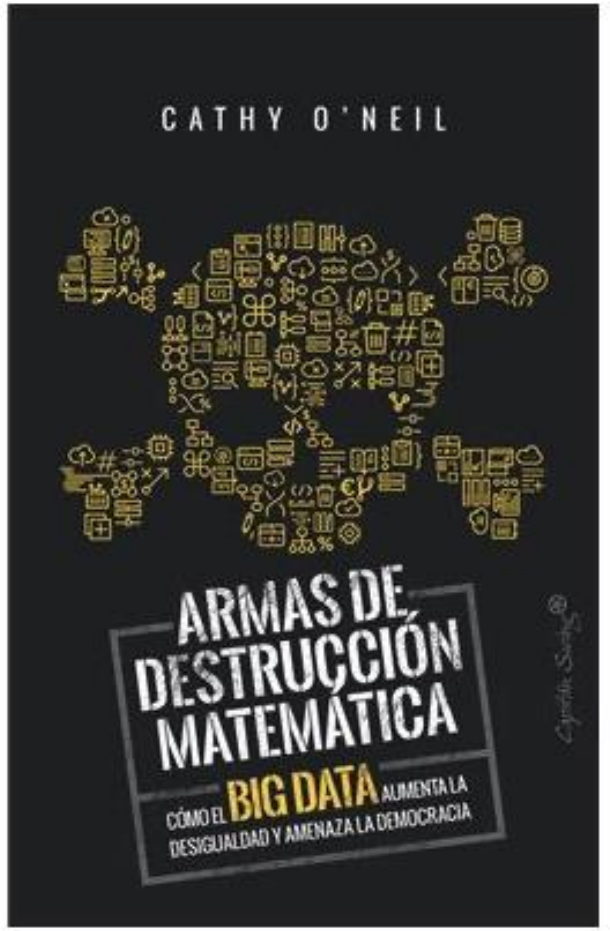
- selecionar um modelo mais poderoso, com mais parâmetros,
- fornecer features melhores para o algoritmo de aprendizado (engenharia de características),
- não limitar o aprendizado do modelo

Modelos preconceituosos

- Devemos desenvolver algoritmos que sejam
  - Justos
  - Explicáveis
  - Auditáveis
  - transparentes



o filme investiga como os algoritmos de inteligência artificial, muitas vezes tidos como neutros, na verdade perpetuam e até amplificam preconceitos e desigualdades sociais existentes



O'Neil argumenta que as WMDs perpetuam a injustiça sistêmica, reforçam o racismo e "aumentam a desigualdade", criando um "coquetel tóxico para a democracia" ao punir sistematicamente os pobres e marginalizados

Variáveis

Variável Independente (ou explicativa, preditora)

- É a variável que **controlamos ou observamos** para explicar ou prever outra
- Representa a **causa** ou o fator que influencia a outra variável
- Fica do lado direito da fórmula do modelo

◆ **Exemplo**: horas_estudo

Quanto mais horas a pessoa estuda, maior tende a ser sua nota.

Variável Dependente (ou resposta, regressanda)

- É a variável que **queremos prever ou explicar**
- Representa o **efeito** ou o resultado influenciado pela variável independente.
- Fica do lado esquerdo da fórmula do modelo.

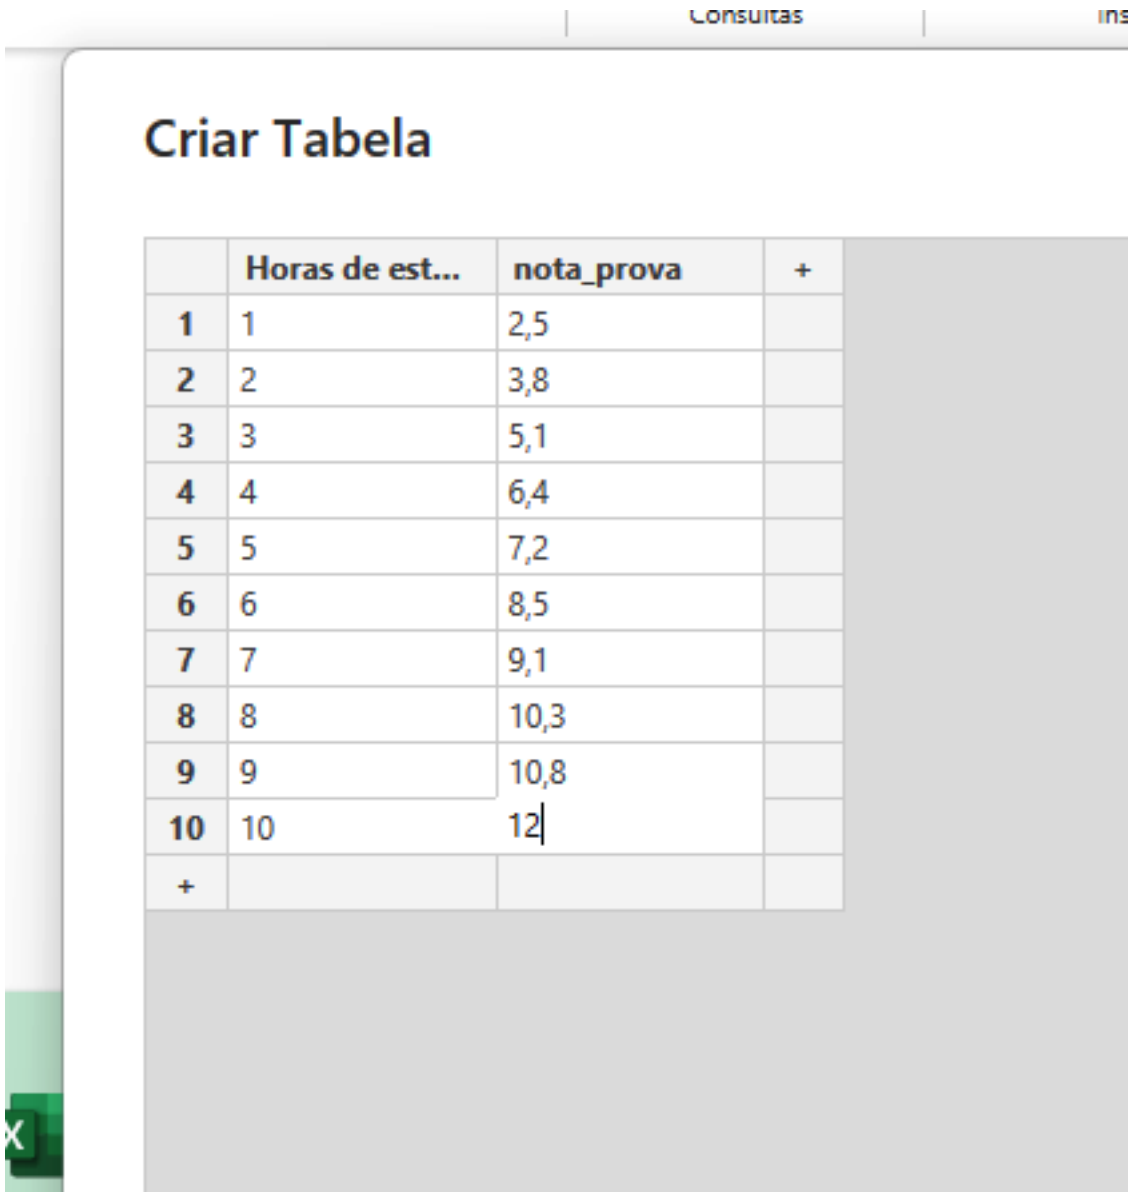
◆ **Exemplo**: nota_prova

A nota depende das horas de estudo.

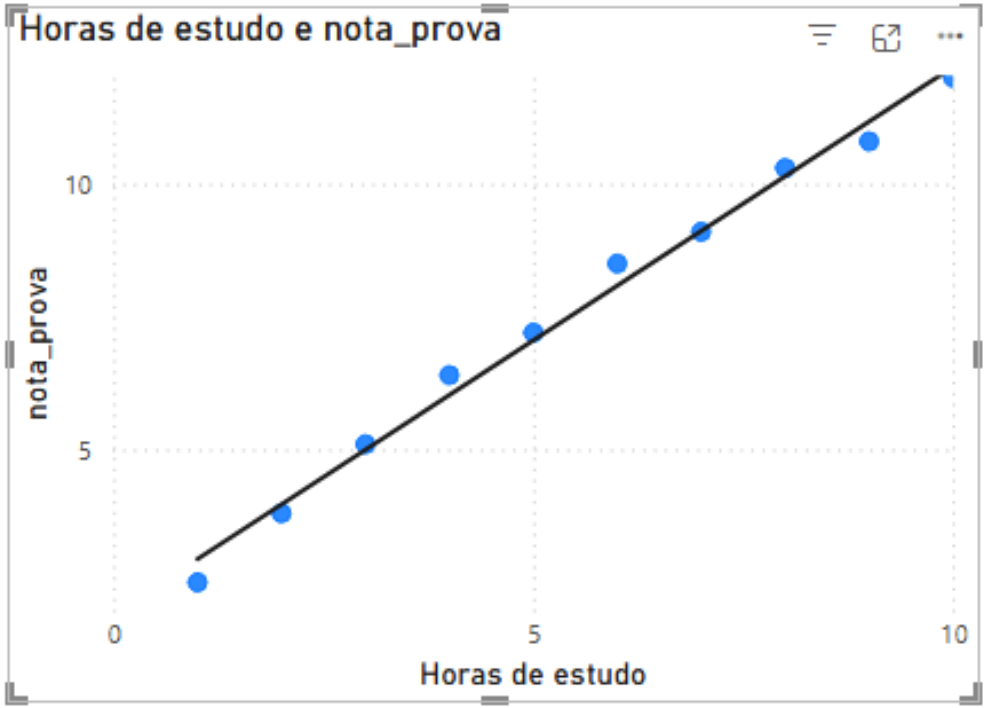
Regressão no PowerBi

- Crie a tabela (inserir dados):

```
horas_estudo,nota_prova
1,2.5
2,3.8
3,5.1
4,6.4
5,7.2
6,8.5
7,9.1
8,10.3
9,10.8
10,12.0
```



Regressão no Power BI



Criar o gráfico de dispersão com regressão

1. Vá até a aba **Visualizações**.
2. Selecione o visual de **“Gráfico de dispersão”**
3. Configure:
4. **Eixo X:** horas_estudo
5. **Eixo Y:** nota_prova
6. Clique com o botão direito no gráfico e selecione:
7. **Análise → Linha de tendência → Adicionar**

- Isso adiciona a **reta de regressão linear** sobre os pontos, usando o método matemático chamado Mínimos Quadrados.

Equação da regressão linear

- Medidas auxiliares:

```
Média_X = AVERAGE(Tabela[Hora de estudo])
Média_Y = AVERAGE(Tabela[nota_prova])
```

- Covariância:

```
Cov_XY =
VAR media_x = AVERAGE(Tabela[Horas de estudo])
VAR media_y = AVERAGE(Tabela[nota_prova])
RETURN
SUMX(
    Tabela,
    (Tabela[Horas de estudo] - media_x) * (Tabela[nota_prova] - media_y)
)
```

🔎 **Interpretação:**

Valor da Covariância	Interpretação
> 0	X e Y variam na **mesma direção**
< 0	X e Y variam em **direções opostas**
≈ 0	Pouca ou nenhuma relação linear entre X e Y

Equação da regressão linear

- Variância:

```
Var_X =
VAR media_x = AVERAGE(Tabela[Horas de estudo])
RETURN
SUMX(
    Tabela,
    POWER(Tabela[Horas de estudo] - media_x, 2)
)
```

🧠 **Interpretação:**

- **Variância = 0** → todos os valores são iguais à média (sem variação).
- **Variância maior** → dados mais espalhados (maior dispersão).
- Quanto maior a variância, **menos consistentes** são os valores da variável.

Equação da regressão linear

- Inclinação (coeficiente angular)

```
Inclinação = DIVIDE([Cov_XY], [Var_X])
```

- Intercepto (coeficiente linear)

```
Intercepto = [Média_Y] - [Inclinação] * [Média_X]
```

- Exibindo em um cartão

```
Equação =
"nota_prova = " &
ROUND([Intercepto], 2) & " + " &
ROUND([Inclinação], 2) & " * Hora de estudo"
```

Predição

- Predição da nota com base na hora de estudo

```
Nota_Prevista =
[Intercepto] + [Inclinação] * SELECTEDVALUE(Tabela[Hora de estudo])
```

Calculando R^2

- Média da variável dependente

```
Média_Y = AVERAGE(Tabela[nota_prova])
```

- Soma total dos quadrados

```
SStot =
VAR media_y = [Média_Y]
RETURN
SUMX(
    Tabela,
    POWER(Tabela[nota_prova] - media_y, 2)
)
```

Calculando R^2

- Soma dos quadrados dos resíduos

```
SSres =
SUMX(
    Tabela,
    POWER(Tabela[nota_prova] - [Nota_Prevista], 2)
)
```

- Calculando o R2

```
R2 = 1 - DIVIDE([SSres], [SStot])
```

Exercício: Treinamento físico x Desempenho

Treinamento (horas)	Desempenho (pontos)
1.5	15
2.0	18
2.5	20
3.0	22
3.5	24
4.0	27
4.5	28
5.0	30
5.5	32
6.0	33
6.5	35
7.0	37
7.5	39
8.0	40
8.5	42
9.0	43
9.5	44
10.0	45
10.5	47
11.0	48

- Inserir essa tabela no **Power BI**
- Criar as mesmas **medidas DAX**:
  - Média de X e Y
  - Covariância
  - Variância
  - Inclinação e Intercepto
  - Nota prevista
  - R^2 e Correlação
- Plotar os **gráficos comparando valores reais e previstos, além das medidas em cartões**